Started on	Thursday, 31 March 2022, 7:00 PM
State	Finished
Completed on	Thursday, 31 March 2022, 7:15 PM
Time taken	15 mins
Marks	4.00/16.00
Grade	**2.50** out of 10.00 (**25**%)

Question **1**

Incorrect

Mark 0.00 out of 1.00

Fie un strat liniar cu 2 intrari si 2 iesiri, care calculeaza urmatoarele iesiri:

$o_1 = w_{11} * x_1 + w_{21} * x_2$

$o_2 = w_{12} * x_1 + w_{22} * x_2$

Daca $x_1 = 1$ si $x_2 = 2$, iar **dE/do = (4, 3)** care sunt valorile gradientilor **dE/dw_{11}, dE/dw_{12}, dE/dw_{21} si dE/dw_{22}**

a. 4, 3, 4, 3 ✖

b. 4, 6, 3, 8

c. 1, 2, 1, 2

d. 4, 8, 3, 6

Your answer is incorrect.

The correct answer is:
4, 6, 3, 8

Question **2**

Incorrect

Mark 0.00 out of 1.00

Alegeți afirmația greșită:

a. Ieșirea unui funcții treaptă pentru intrarea [-1, 2, 0, 4, -3] este [-1, 1, 1, 1, -1] ✖

b. Ieșirea unui funcții sigmoid pentru intrarea [-1, 2, 0, 4, -3] este [0.26, 0.88, 0.5, 0.98, 0.04]

c. Ieșirea unei funcții ReLU pentru intrarea [-1, 2, 0, 4, -3] este [0, 2, 0, 4, 0]

d. Ieșirea unui funcții tanh pentru intrarea [-1, 2, 0, 4, -3] este [0.83, 0.16, 0, 0.22, -0.45]

Your answer is incorrect.

The correct answer is:
Ieșirea unui funcții tanh pentru intrarea [-1, 2, 0, 4, -3] este [0.83, 0.16, 0, 0.22, -0.45]

Question **3**

Correct

Mark 1.00 out of 1.00

Fie următoarea rețea neuronala cu doua intrări intrări binare x_1, x_2 și funcție de activare treaptă. Specificati care este funcția calculata.



a. NOT AND

b. OR

c. AND ✔

d. XOR

Your answer is correct.

The correct answer is:
AND

Question **4**

Incorrect

Mark 0.00 out of 1.00

Intr-o retea convolutionala, care sunt componentele care au parametrii care se invata (actualizeaza)?

- [x] a. Stratul Fully connected ✔
- [ ] b. Stratul de Pooling
- [x] c. Stratul de convolutie ✔
- [x] d. Functia RELU ✖
- [ ] e. Functia sigmoid

Your answer is incorrect.

The correct answers are:
Stratul de convolutie,

Stratul Fully connected

Question **5**

Incorrect

Mark 0.00 out of 1.00

În formula de actualizare a parametrilor unei rețele folosind gradient descent cu momentum, ce se întâmplă când *gamma* are valoarea 0?

Momentum based Gradient Descent Update Rule

$$v_t = \gamma * v_{t-1} + \eta \nabla w_t$$

$$w_{t+1} = w_t - v_t$$

Select one:

- a. Rețeaua învață foarte greu valorile optime ale parametrilor ✖
- b. Rețeaua învață mai repede valorile optime ale parametrilor
- c. Rețeaua nu învață valorile optime ale parametrilor
- d. Formula devine echivalentă cu formula pentru SGD simplu

Răspunsul dumneavoastră este incorect.

The correct answer is: Rețeaua nu învață valorile optime ale parametrilor

Question **6**

Incorrect

Mark 0.00 out of 1.00

Ce s-ar întâmpla într-o rețea neuronală artificială dacă am utiliza funcția de activare y = 2x, unde x este intrarea de pe un s acestuia?

Select one:

- a. Ponderile s-ar micșora considerabil. ✖
- b. Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor.
- c. Valorile de la output ar deveni foarte mari
- d. Ar fi imposibil ca rețeaua să mai învețe să rezolve o problemă de clasificare sau regresie

Răspunsul dumneavoastră este incorect.

The correct answer is: Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor.

Question **7**

Incorrect

Mark 0.00 out of 1.00

O rată de învățare foarte mare nu avantajează antrenarea unei rețele neuronale artificiale deoarece:

Select one:

- a. Ieșirile de pe fiecare strat vor avea valori foarte mari. ✖
- b. Reducem prea mult numărul de iterații necesari antrenării rețelei.
- c. La fiecare pas de optimizare ponderile vor fi modificate prea mult corespunzător cu batch-ul curent de exemple c cu restul setului de date).
- d. Derivatele în raport cu eroarea vor avea valori foarte mici.

Răspunsul dumneavoastră este incorect.

The correct answer is: La fiecare pas de optimizare ponderile vor fi modificate prea mult corespunzător cu batch-ul curent învățare (în raport cu restul setului de date).

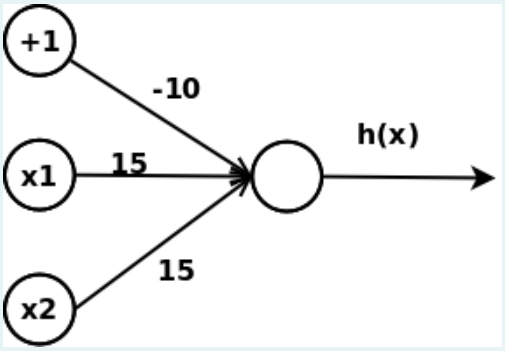
Question **8**

Incorrect

Mark 0.00 out of 1.00

Fie urmatoarea retea neurala simpla, avand doua intrari binare (x1 si x2) si o functie de activare treapta.

Indicati care este functia calculata.



- a. AND ✖
- b. XOR
- c. NOT OR
- d. OR

Your answer is incorrect.

The correct answer is:
OR

Question **9**

Correct

Mark 1.00 out of 1.00

Care este ieșirea unui neuron care are ponderile [3, -1, 2] și bias 2 pentru intrarea [7, 9, 10]?

- a. 34 ✔
- b. 30
- c. 32
- d. 37

Your answer is correct.

The correct answer is:
34

Question **10**

Incorrect

Mark 0.00 out of 1.00

Ce funcții de activare ați folosi într-o rețea pentru a putea obține valori negative în urma aplicării activării:

Select one or more:

- a. Logistică ✖
- b. Tangentă hiperbolică
- c. Leaky ReLU ✔
- d. ReLU ✖

Răspunsul dumneavoastră este incorect.

The correct answers are: Leaky ReLU, Tangentă hiperbolică

Question **11**

Incorrect

Mark 0.00 out of 1.00

Se dă următoarea arhitectură a unei rețele convoluționale:

Input(31 x 31 x 1) -> Conv1(c=5, k=3, p=1, s=1) -> ReLU1 -> Conv2(c=10, k=3, p=1, s=2) -> AvgPool2(k=2, s=2) -> ReLU2 -> Conv3(c=20, k=3, p=0, s=1) -> ReLU3 -> Output,

unde c - numar de canale, k - dimensiune kernel, p = padding, s = stride, iar inputul este dat in formatul H x W x C (height

Care este dimensiunea pentru outputul final, exprimat in format H x W x C?

- a. 16 x 16 x 20 ✖
- b. 6 x 6 x 20
- c. 15 x 15 x 20
- d. 15 x 15 x 1000
- e. 6 x 6 x 1000

Your answer is incorrect.

The correct answer is:
6 x 6 x 20

Question **12**

Correct

Mark 1.00 out of 1.00

Intr-o rețea perceptron, putem renunța la bias în calculul activării dacă îl considerăm ca pondere conectată la o falsă intrar constantă?

Select one:

- True ✔
- False

The correct answer is 'True'.

Question **13**

Incorrect

Mark 0.00 out of 1.00

Câți parametri sunt într-o rețea care respectă structura de mai jos, antrenată pe un set de date de imagini grayscale de dir

L0: Input

L1: Conv1(c=5, k=3, p=1, s=1)

L2: Relu

L3: Conv2(c=10, k=3, p=1, s=2)

L4: Relu

L5: AvgPool(k=2, s=2)

L6: Linearize

L7: Linear(640, 3)

L8: Softmax

L9: Output

a. 1999 ✖

b. 1218

c. 3201

d. 2415

e. 1965

Your answer is incorrect.

The correct answer is:
2415

Question **14**

Incorrect

Mark 0.00 out of 1.00

Care este motivul pentru care utilizăm activări neliniare în rețele neurale artificiale?

a. Activările trebuie limitate într-un domeniu ușor de gestionat (e.g. (-1,1) sau (0,1)) pentru a evita fenomenele de *vanishing/exploding gradients*.

b. Spațiile descrise de datele de intrare sunt întotdeauna neliniare.

c. Dacă s-ar utiliza doar activări liniare, prin compoziționalitate rețeaua ar echivala cu o funcție liniară.

d. Ieșirile rețelei trebuie să fie neliniare pentru a putea fi utilizate în calculul funcției de eroare.

Your answer is incorrect.

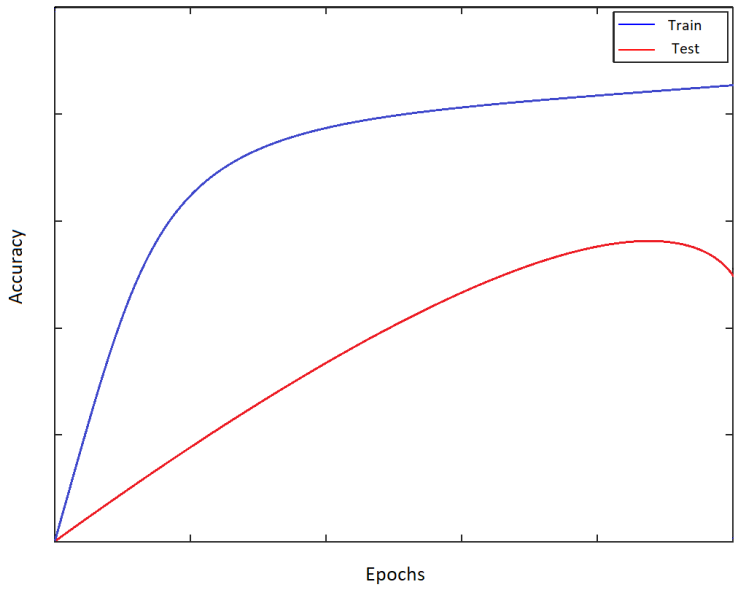
The correct answer is:
Dacă s-ar utiliza doar activări liniare, prin compoziționalitate rețeaua ar echivala cu o funcție liniară.

Question **15**

Correct

Mark 1.00 out of 1.00

Cum interpretați figura de mai jos?



Select one:

- a. Rețeaua intră în regim de overfit ✔
- b. Rețeaua are arhitectura potrivită pentru setul de date pe care este antrenată
- c. Rețeaua nu învață nicio caracteristică a datelor

Răspunsul dumneavoastră este corect.

The correct answer is: Rețeaua intră în regim de overfit

Question **16**

Incorrect

Mark 0.00 out of 1.00

Considerăm situația în care se antrenează un model folosind gradient descent, însă nu se ajunge la costul global minim. C motivul?

Select one:

- a. Funcția de cost este un polinom de grad > 2. ✖
- b. Funcția de cost nu este concavă.
- c. Funcția de cost nu este convexă.
- d. Funcția de cost nu ține cont de regularizare.

Răspunsul dumneavoastră este incorect.

The correct answer is: Funcția de cost nu este convexă.

◄ Laborator 4: Retele neurale

Jump to...

Started on	Wednesday, 8 April 2020, 2:03 PM
State	Finished
Completed on	Wednesday, 8 April 2020, 3:42 PM
Time taken	1 hour 39 mins
Marks	37.00/40.00
Grade	**9.25** out of 10.00 (**93**%)

Question **1**

Correct

Mark 1.00 out of 1.00

Ce presupune "lama lui Occam" in contextul arborilor de decizie?

Select one:

- a. Nu se poate aplica principiul în contextul arborilor de decizie
- b. Nu există mai mulți arbori corecți pentru aceeași problemă
- c. Dacă sunt mai mulți arbori de decizie corecți, se preferă cel mai simplu ✔
- d. Un arbore corect de decizie trebuie să cuprindă toate atributele din setul de date

Răspunsul dumneavoastră este corect.

The correct answer is: Dacă sunt mai mulți arbori de decizie corecți, se preferă cel mai simplu

Question **2**

Correct

Mark 1.00 out of 1.00

Se considera urmatorul set de exemple:

Nr	Culoare	Tip	Productie	Se fura?
1	Rosu	Sport	Proprie	Da
2	Rosu	Sport	Proprie	Da
3	Rosu	Sport	Proprie	Da
4	Galben	Sport	Proprie	Da
5	Galben	Sport	Import	Da
6	Galben	SUV	Import	Nu
7	Galben	SUV	Import	Nu
8	Galben	SUV	Proprie	Da
9	Rosu	SUV	Import	Nu
10	Rosu	Sport	Import	Da

Aplicand algoritmul de invatare utilizand arbori de decizie, care este înalțimea minimă a arborelui?

Select one:

- a. 2 ✔
- b. 1
- c. 3
- d. 4

Răspunsul dumneavoastră este corect.

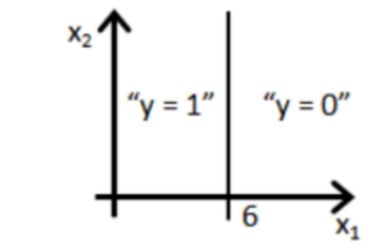
The correct answer is: 2

Question **3**

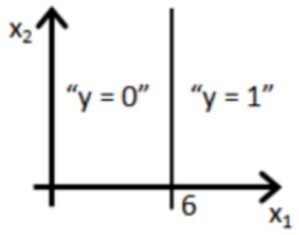
Correct

Mark 1.00 out of 1.00

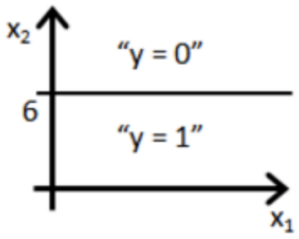
In urma antrenarii unei regresii liniare multi variabile, se obtine h(x) = -6 + 1*x_1+0*x_2. Care dintre figurile urmatoare este asociata acestei clasificari?



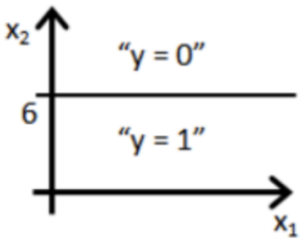
A.



B.



C.



D.

Select one:

- a. C
- b. B ✔
- c. A
- d. D

Răspunsul dumneavoastră este corect.

The correct answer is: B

Question **4**

Correct

Mark 1.00 out of 1.00

In urma antrenarii unui algoritm de invatare automata, observati ca acesta are o acuratete foarte buna pe setul de antrenare, insa mica pe setul de testare.

Care poate fi motivul? Si cum am putea rezolva ? (presupunand ca avem un clasificator bazat pe arbori de decizie)

Select one:

- a. Underfitting. Putem adauga mai multe date in setul de testare.
- b. Underfitting. Eliminam aleator un procent de date din setul de antrenare.
- c. Overfitting. Putem aplica prunning. ✔
- d. Overfitting. Adaugam mai multe atribute dupa care sa facem clasificarea

Răspunsul dumneavoastră este corect.

The correct answer is: Overfitting. Putem aplica prunning.

Question **5**

Incorrect

Mark 0.00 out of 1.00

Care este avantajul folosirii algoritmului ”iterarea valorilor” vs ”iterarea politicilor”?

Select one:

- a. Calculează o politică optimă mereu, lucru care nu e garantat de ”Iterarea politicilor” ✖
- b. Necesită un efort computațional mai mic
- c. Poate fi aplicat în probleme în care nu se cunoaște dinamica mediului
- d. Nu are avantaje

Răspunsul dumneavoastră este incorect.

The correct answer is: Necesită un efort computațional mai mic

Question **6**

Correct

Mark 1.00 out of 1.00

Pe un set de date cu atribute discrete se antrenează un arbore de decizie *T* prin algoritmul ID3, cu adancime maximă *h*.

Pe același set de date se antrenează un model RandomForest *M*.

Modelul *M* folosește weak-learners (i.e. arborii de decizie care alcatuiesc Pădurea Aleatoare) identici cu *T* (i.e. același criteriu de alegere a atributelor, aceeași adâncime maximă *h*).

Fiecare arbore din RandomForest este antrenat pe același set de date precum și folosind același set de atribute precum modelul *T*.

Modelul *M* astfel rezultat va avea:

Select one:

- a. Aceeași acuratețe ca *T* ✔
- b. Acuratețe mai bună ca *T*
- c. Acuratețe mai mică decât *T*

Răspunsul dumneavoastră este corect.

The correct answer is: Aceeași acuratețe ca *T*

Question **7**

Correct

Mark 1.00 out of 1.00

Un agent se mișcă într-un mediu 3x3 cu următoarele recompense:

	1	2	3
1	**0.5**	**0.5**	**0.5**
2	**-1**	**0.5**	**1**
3	**0.5**	**0.5**	**0.5**

Agentul poate executa acțiunile A1 (se mută la stânga cu probabilitatea 0.8 sau se mută în celula de sus cu probabilitatea 0.2) și A2 (se mută la dreapta cu probabilitatea 0.6, se mută în celula de sus cu probabilitatea 0.2 sau se mută în celula de jos cu probabilitatea 0.2). Care este utilitatea stării (2,2) dacă factorul de atenuare are valoarea 0.9 (calculați folosind ecuația Bellman pentru un pas)?

Select one:

- a. 1.22 ✔
- b. 0.72
- c. 0.5
- d. 1.14

Răspunsul dumneavoastră este corect.

The correct answer is: 1.22

Question **8**

Correct

Mark 1.00 out of 1.00

Procedura de cross-validation este folosită des pentru a găsi o valoare bună a hiperparametrilor unui model de învățare. În urma procedurii, se poate raporta o medie și o varianță a diferitelor modele (i.e. a instanțelor de model, pentru fiecare combinație de hiperparametrii).

Ce fel de modele vor fi preferate?

Select one:

- a. Modele cu medie mică și varianță mare
- b. Modele cu medie mică și varianță mică
- c. Modele cu medie mare și varianță mare
- d. Modele cu medie mare și varianță mică ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Modele cu medie mare și varianță mică

Question **9**

Correct

Mark 1.00 out of 1.00

Ce tip de regresie ar trebui folosita pentru o problema in care dorim sa impartim un set de date in 2 categorii? (presupunem ca dorim sa antrenam un algoritm pentru care avem setul de date de antrenare)

Select one:

- a. Regresie liniara deoarece datele pot fi separate cu ajutorul unei drepte
- b. Regresie liniara deoarece cele 2 categorii (din setul de antrenare) pot fi etichetate cu 0 si 1. In etapa de antrenare algoritmul va avea de gasit o dreapta care trece prin cele 2 puncte (0 si 1)
- c. Regresie logistica deoarece nu stim cum sa codificam "categoriile" in nume reale necesare regresiei liniare.
- d. Regresia logistica deoarece foloseste functia logistica pentru a modela probabilitatea ca un punct din setul de date sa se gaseasca intr-o anumita clasa. ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Regresia logistica deoarece foloseste functia logistica pentru a modela probabilitatea ca un punct din setul de date sa se gaseasca intr-o anumita clasa.

Question **10**

Correct

Mark 1.00 out of 1.00

Care este transformarea $\phi(q)$ care corespunde Kernelului

$K(a,b) = \phi^T(a)\,\phi(b) = a_1^2b_1^2 + 2a_1a_2b_1b_2 + a_2^2b_2^2$

Select one:

a. $[q_1^2 \;\; q_2^2 \;\; \sqrt{2}q_1q_2\,]$ ✔

b. $[q_1 \;\; q_2 \;\; \sqrt{2}q_1^2 \;\; \sqrt{2}q_2^2\,]$

c. $[1 \;\; q_1^2 \;\; q_2^2 \;\; \sqrt{2}q_1 \;\; \sqrt{2}q_2\,]$

d. $[q_1 \;\; q_2 \;\; q_1^2 \;\; q_2^2\,]$

e. $[1 \;\; q_1^2 \;\; q_2^2 \;\; \sqrt{2}q_1 \;\; \sqrt{2}q_2 \;\; \sqrt{2}q_1q_2\,]$

Răspunsul dumneavoastră este corect.

The correct answer is: $[q_1^2 \;\; q_2^2 \;\; \sqrt{2}q_1q_2\,]$

Question **11**

Correct

Mark 1.00 out of 1.00

Care este ecuația care definește dreapta pe care se află vectorii suport ai clasei pozitive după determinarea marginii în algoritmul SVM? (w' reprezintă transpusul lui w)

Select one:

a. w' * x + b = -1

b. w' * x + b = 0

c. w' * x + b > 1

d. w' * x + b = 1 ✔

Răspunsul dumneavoastră este corect.

The correct answer is: w' * x + b = 1

Question **12**

Correct

Mark 1.00 out of 1.00

Consideram urmatorul set de dat perechi (x,y):

(0,12) (1,13.5) (2,15) (3,16.5) (4,18) (5,19.5) (6,21)

Care functie descrie o regresie liniara pentru aceste date?

Select one:

a. y=0.6x+8

b. y=2.5x+12

c. y=1.5x+12 ✔

d. y=12x+5

Răspunsul dumneavoastră este corect.

The correct answer is: y=1.5x+12

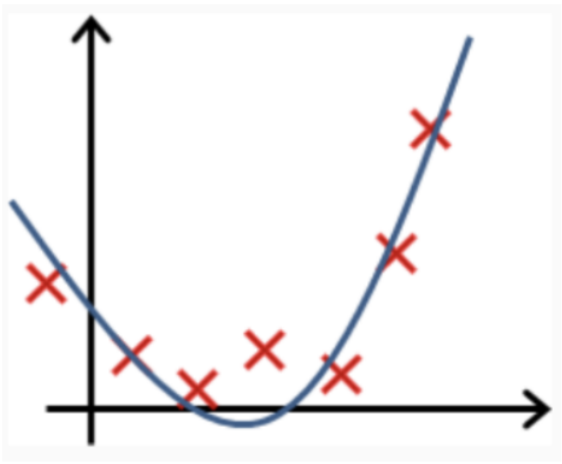
Question **13**

Correct

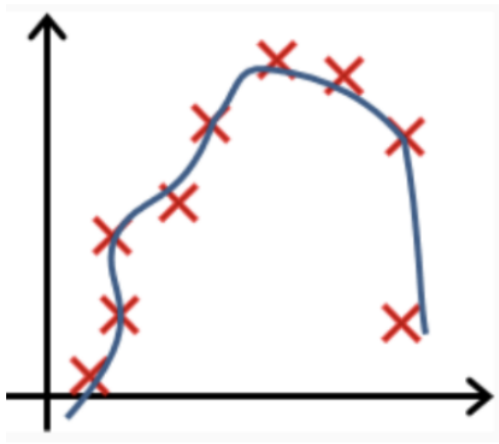
Mark 1.00 out of 1.00

In urma antrenarii unei regresii, care figura corespunde aparitiei underfitingului?

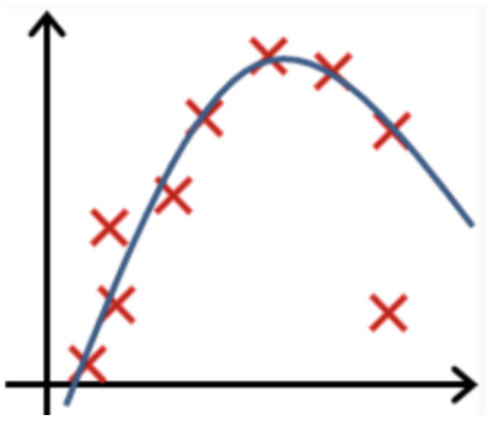
A.



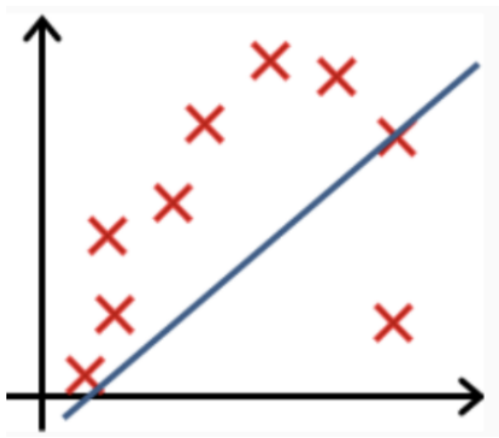
B.



C.



D.



Select one:

- a. A
- b. C
- c. B
- d. D ✔

Răspunsul dumneavoastră este corect.

The correct answer is: D

Question **14**

Correct

Mark 1.00 out of 1.00

Un set de date utilizat pentru învățare supervizată are o valoare mare a entropiei informaționale dacă:

Select one:

- a. Foarte multe dintre exemple aparțin unui număr mic de clase, în timp ce restul de clase au un număr mic de exemple.
- b. Toate exemplele fac parte din aceeași clasă
- c. Numărul de exemple din fiecare clasă este relativ similar ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Numărul de exemple din fiecare clasă este relativ similar

Question **15**

Correct

Mark 1.00 out of 1.00

Care dintre urmatoarele sunt bune practici pentru reducerea overfitting-ului?

(a) Utilizarea unei funcții de cost cu 2 componente, care include un regulator pentru a penaliza complexitatea modelului

(b) Utilizarea unui optimizator bun pentru a reduce erorile pe datele de antrenare

(c) Construirea unei structuri de subseturi de modele imbricate, antrenarea pe fiecare subset pornind de la cel mai mic, si oprirea cand eroarea de cross-validare incepe sa creasca

(d) Eliminarea aleatoare a 50% din datele de antrenare

Select one:

- a. (c)
- b. (a) si (c) ✔
- c. (a) si (b)
- d. (a) si (b) si (c)
- e. (b) si (c)

Răspunsul dumneavoastră este corect.

The correct answer is: (a) si (c)

Question **16**

Incorrect

Mark 0.00 out of 1.00

Arborii de decizie construiți cu algoritmul ID3 prezintă robustețe crescută la „outliers”? Care dintre răspunsuri este cel mai plauzibil?

Select one:

- a. Nu, pentru că ele (outliers) influențează sub-arborii generați ca fii ai unui nod test.
- b. Da, pentru că unele atribute nu sunt luate în considerare. ✖
- c. Nu, pentru că vom obține valori negative pentru câștigul informațional în cazul lor.
- d. Da, întrucât acest lucru este garantat prin calculul entropiei.

Răspunsul dumneavoastră este incorect.

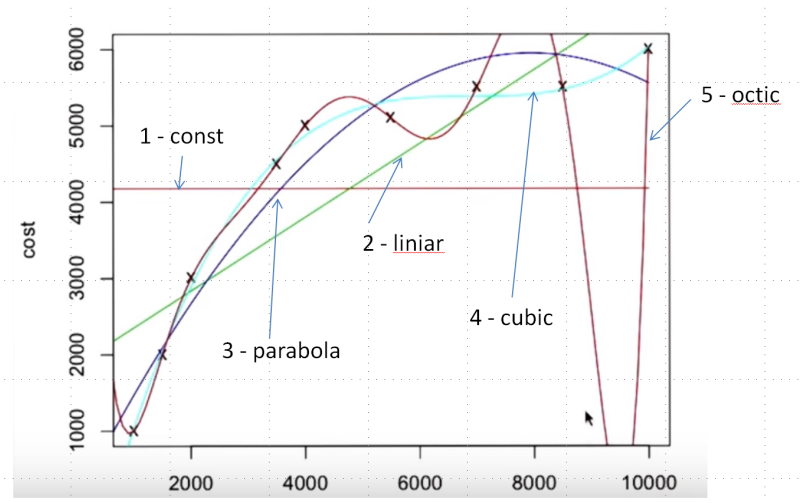
The correct answer is: Nu, pentru că ele (outliers) influențează sub-arborii generați ca fii ai unui nod test.

Question **17**

Correct

Mark 1.00 out of 1.00

Care curba trebuie aleasa pentru o buna predictie pe baza datelor existente in graficul urmator, folosind regresiei liniara?



Select one:

- a. 4 ✔
- b. 3
- c. 5
- d. 1
- e. 2

Răspunsul dumneavoastră este corect.

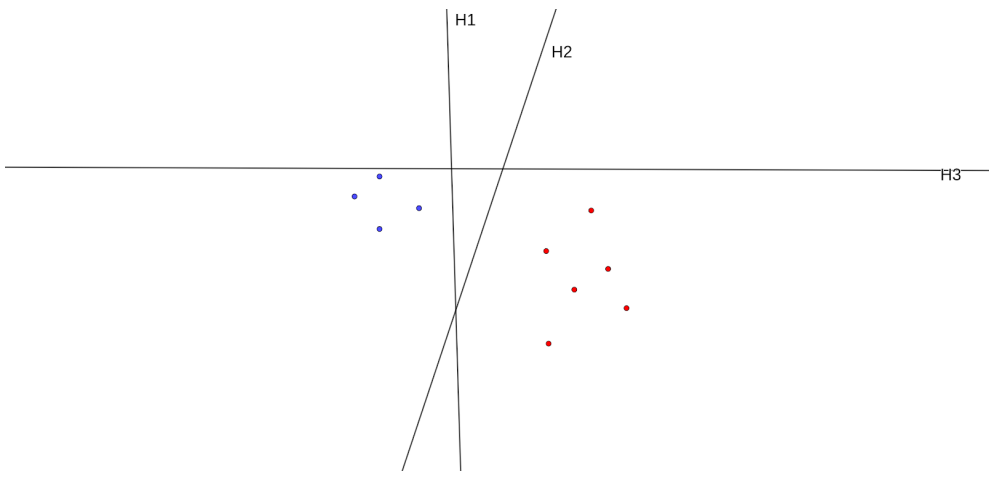
The correct answer is: 4

Question **18**

Correct

Mark 1.00 out of 1.00

Avem un set de date cu 2 clase -- punctele rosii si albastre. Punctele si posibile hiperplanuri de separare sunt plotate mai jos. Care ar fi cel mai bun hiperplan de separare (dintre cele 3: H1, H2, H3)?



Select one:

- a. H1
- b. H3
- c. Nu exista un hiperplan de separare bun
- d. H2 ✔

Răspunsul dumneavoastră este corect.

The correct answer is: H2

Question **19**

Correct

Mark 1.00 out of 1.00

Care dintre următoarele reprezintă criterii de oprire pentru construcția arborelui de decizie cu algoritmul ID3. Alegeți opțiunile corecte dintre:

1. Toate exemplele din subset fac parte din aceeași clasă
2. Câștigul informațional ajunge să fie negativ
3. Nu mai există atribute valide cu care să creăm un nod test
4. Adâncimea maximă este atinsă
5. Câștigul informațional depășește un anumit prag

Select one:

- a. 4 și 5
- b. 1, 3 și 4 ✔
- c. 1 și 4
- d. 1, 2 și 3
- e. 1

Răspunsul dumneavoastră este corect.

The correct answer is: 1, 3 și 4

Question **20**

Correct

Mark 1.00 out of 1.00

In cazul algoritmului C4.5 daca avem valori necunoscute pentru un atribut in anumie exemple de invatare trebuie sa

Select one:

- a. atribuim acelui atribut valoarea cu cea mai mare frecventa din exemplele de invatare ✔
- b. atribuim acelui atribut valoarea cu cea mai mica frecventa din exemplele de invatare

Răspunsul dumneavoastră este corect.

The correct answer is: atribuim acelui atribut valoarea cu cea mai mare frecventa din exemplele de invatare

Question **21**

Correct

Mark 1.00 out of 1.00

Fie un set de exemple cu N atribute boolene si clasificare in clasa si non-clasa. Cati arbori de decizie diferiti putem construi ?

Select one:

- a. 2**N+1
- b. 2**N ✔
- c. 2*N
- d. 2N+1

Răspunsul dumneavoastră este corect.

The correct answer is: 2**N

Question **22**

Correct

Mark 1.00 out of 1.00

Folosim o regresie liniara pentru prezicerea prețului batoanelor de ciocolată “ROM” care a fost antrenat pe factorii economici din România. Modelul obține rezultate foarte bune, însă după ce este rulat peste 5 ani acesta va avea rezultatele diferite. Care poate fi cauza?

Select one:

- a. Modelul trebuia antrenat de la început cu mai multe date
- b. Factorii economici se schimbă, iar modelul trebuie re-antrenat folosind date noi ✔
- c. Trebuia să folosim o regresie logistică pentru a putea modela parametrul de timp

Răspunsul dumneavoastră este corect.

The correct answer is: Factorii economici se schimbă, iar modelul trebuie re-antrenat folosind date noi

Question **23**

Correct

Mark 1.00 out of 1.00

Care dintre urmatoarele afirmatii este adevarata?

(a) O functie Kernel calculeaza un produs scalar intr-un un spatiu de dimensiune mai mare fata de spatiu de intrare

(b) Functia Kernel este o functie de similaritate

Select one:

- a. (a) si (b) ✔
- b. (a)
- c. Nici una
- d. (b)

Răspunsul dumneavoastră este corect.

The correct answer is: (a) si (b)

Question **24**

Correct

Mark 1.00 out of 1.00

Ce se intampla daca se alege viteza de invatare (parametrul α pentru algoritmul de gradient descent) foarte mica, respectiv foarte mare?

Select one:

- a. Nu conteza viteza de invatare, deoarece formula de actualizare a parametrilor nu tine cont de aceasta.
- b. foarte mica - algoritmul de invatare ar putea sa convearga prea lent spre o solutie
  foarte mare - algoritmul de invatare ar putea sa nu gaseasca solutia ✔
- c. foarte mica - algoritmul de invatare ar putea sa convearga repede spre o solutie.
  foarte mare - algoritmul de invatare ar putea sa convearga prea lent spre o solutie
- d. Nu se intampla nimic, viteza de invatare poate fi oricat deoarece algoritmul mereu va converge spre solutie in acelasi timp.

Răspunsul dumneavoastră este corect.

The correct answer is: foarte mica - algoritmul de invatare ar putea sa convearga prea lent spre o solutie
foarte mare - algoritmul de invatare ar putea sa nu gaseasca solutia

Question **25**

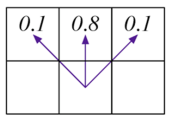
Correct

Mark 1.00 out of 1.00

Fie problema MDP. Se considera un grid cu 2 linii si 3 coloane, in care un agent se poate deplasa in directiile sus, jos, stanga, dreapta. Pentru fiecare stare recompensele sunt date in figura a). Deplasarea in grid va avea loc daca agentul ramane in grid. In caz contrar agentul va ramane pe loc. Deplasarea in directia aleasa se va face cu probabilitatea 0.8. Cu probabilitati 0.1, respectiv 0.1 agenul se va deplasa de-a lungul celor doua diagonale care incadreaza directia de deplasare aleasa (ca in figura b).

S1 (R=0)	S2 (R=0)	S3 (R=10)
S4 (R=0)	S5 (R=0)	S6 (R= -5)

a)



b)

Dupa un numar de episoade utilitatile starilor sunt: U(S1) = 5, U(S2) = 7, U(S3) = -3, U(S4) = 2, U(S5) = 4, U(S6) = =-6.

Care este utilitatea starii S5 pentru pasul urmator, avand factorul de atenuare = 0.9.

Select one:

- a. 4
- b. 5.22 ✔
- c. 5.4
- d. 2.57
- e. 0.7

Răspunsul dumneavoastră este corect.

The correct answer is: 5.22

Question **26**

Correct

Mark 1.00 out of 1.00

Avem urmatoarea matrice de confuzie pentru o problema de clasificare binara (pe coloane sunt valorile reale, iar pe linii sunt valorile prezise).

Care afirmatie este adevarata?

	Positive	Negative
Positive	23	1
Negative	12	556

Select one:

- a. Accuracy=557/556
- b. Precision=23/24 ✔
- c. Accuracy=568/592
- d. Recall=23/24

Răspunsul dumneavoastră este corect.

The correct answer is: Precision=23/24

Question **27**

Correct

Mark 1.00 out of 1.00

In urma antrenarii unui SVM, sunt gasiti 3 vectori suport.

Dupa ceva timp mai gasim inca un set de date cu aceleasi caracteristici si clase ca setul folosit initial (cele 2 seturi de date nu contin intrari identitce).

Antrenam SVM-ul folosind reuniunea celor 2 seturi de date (setul reunit este inca liniar separabil), insa in urma procesului vectorii suport nu se schimba.

Care afirmatie este adevarata?

Select one:

- a. antrenarea folosind doar al doilea set de date ar avea ca rezultat vectori suport diferiti ✔
- b. antrenarea SVM-ului folosind doar al doilea set de date va da mereu un hiperplan de separere diferit de cel initial
- c. performanta noului model e mai buna ca a celui antrenat doar pe setul initial de date

Răspunsul dumneavoastră este corect.

The correct answer is: antrenarea folosind doar al doilea set de date ar avea ca rezultat vectori suport diferiti

Question **28**

Correct

Mark 1.00 out of 1.00

Care dintre următoarele reprezintă presupunerea simplificatoare pe baza căreia operează clasificatorul Naive Bayes?

Select one:

- a. Atributele unui exemplu sunt considerate independente între ele ✔
- b. Distribuția din care sunt extrase datele este Bayesiană
- c. Distribuția din care sunt extrase datele este Gausiană
- d. Exemplele unui set de date sunt considerate independente între ele

Răspunsul dumneavoastră este corect.

The correct answer is: Atributele unui exemplu sunt considerate independente între ele

Question **29**

Correct

Mark 1.00 out of 1.00

Se dau următoarele două afirmații despre modelele de tip Gradient Boosted Trees.

1. Clasificatorii slabi (weak learners) sunt independenți unul de celălalt
2. Metoda Gradient Boosted Trees obține performanțe mai bune prin agregarea rezultatelor obținute de clasificatorii slabi (weak learners)

Care dintre cele două afirmații sunt adevărate:

Select one:

- a. 2 ✔
- b. 1 și 2
- c. Nici una
- d. 1

Răspunsul dumneavoastră este corect.

The correct answer is: 2

Question **30**

Incorrect

Mark 0.00 out of 1.00

Datele de antrenare au erori deci ceea ce modelam nu este f ci f+eps. Considerand posibilele surse de erori mentionate mai jos care credeti ca sunt cele mai importante in rezolvarea unei probleme prin regresie liniara ?

(a) Erori de la senzori

(b) Erori de la o sursa malitioasa care introduce special aceste erori

(c) Erori de transciere (ale operatorului)

(d) Influente ale modelului care nu sunt luate in considerare

Select one:

- a. (a) si (b)
- b. (a) si (b) si (c) si (d)
- c. (a) si (c) ✖
- d. (a) si (b) si (c)

Răspunsul dumneavoastră este incorect.

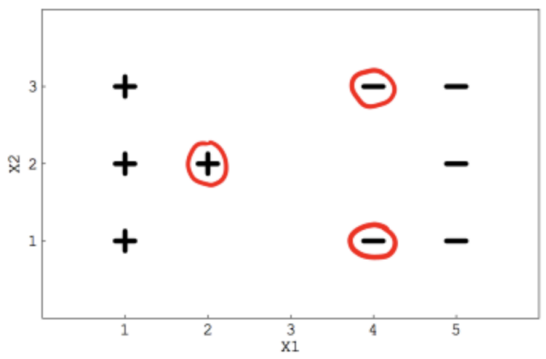
The correct answer is: (a) si (b) si (c) si (d)

Question **31**

Correct

Mark 1.00 out of 1.00

Dacă se elimina unul din punctele marcate cu rosu, hiperplanul de separare pentru un clasificator SVM se modifica?



Select one:

- a. Nu
- b. Da ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Da

Question **32**

Correct

Mark 1.00 out of 1.00

Care este diferența principală între clasele bagging și boosting ale algoritmilor de tip ensemble?

Select one:

- a. Spre deosebire de bagging, metodele de boosting folosesc clasificatori slabi
- b. Clasificatorii metodelor de boosting sunt antrenați independent, în timp ce clasificatorii metodelor de bagging sunt antrenați iterativ
- c. Spre deosebire de boosting, metodele de bagging folosesc clasificatori slabi
- d. Clasificatorii metodelor de bagging sunt antrenați independent, în timp ce clasificatorii metodelor de boosting sunt antrenați iterativ ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Clasificatorii metodelor de bagging sunt antrenați independent, în timp ce clasificatorii metodelor de boosting sunt antrenați iterativ

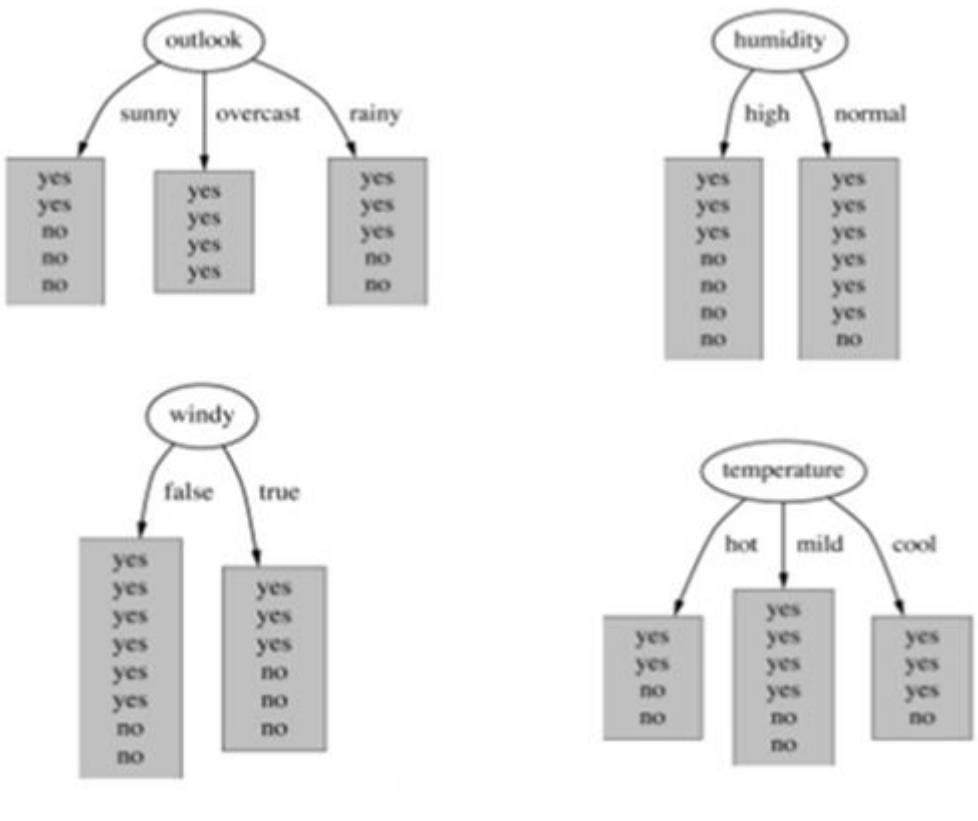
Question **33**

Correct

Mark 1.00 out of 1.00

Se antrenează un arbore de decizie având "maximum information gain" (câștigul maxim informațional, bazat pe diferenta de entropie) drept criteriu de selecție a atributelor.

Considerând acest criteriu și următoarea situație de antrenare (cf. imaginii), care va fi atributul selectat pentru a "împărți" nodul curent:



Select one:

- a. Humidity
- b. Temperature
- c. Windy
- d. Outlook ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Outlook

Question **34**

Correct

Mark 1.00 out of 1.00

In cazul antrenarii regresiei liniare folosind urmatorul set de date (x: intrare, y: iesire), specificati care este valoare J(0, 1), unde $J(\theta_0, \theta_1)$ este functia de eroare pătratică pentru modelul de regresie liniară.

x	y
3	4
2	1
4	3
0	1

Select one:

- a. 0.5 ✔
- b. 1

Răspunsul dumneavoastră este corect.

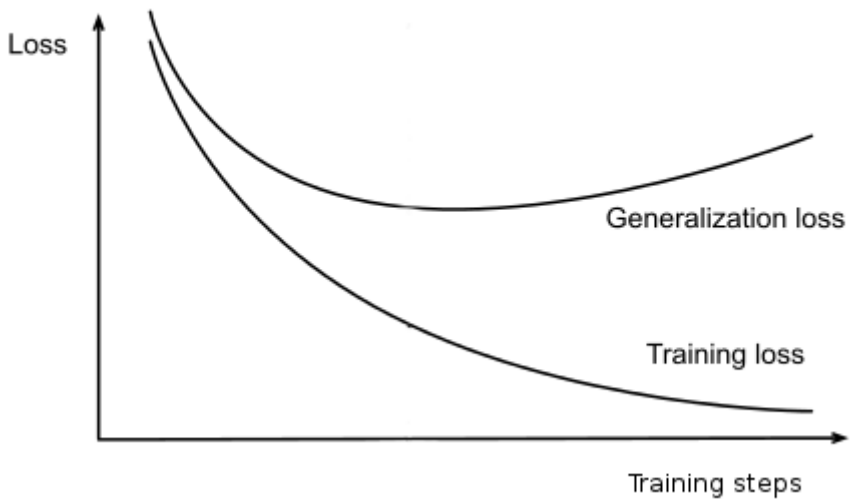
The correct answer is: 0.5

Question **35**

Correct

Mark 1.00 out of 1.00

Curbele de învățare ale unui arbore de decizie arată ca în figura de mai jos



unde la fiecare pas de antrenare modelul vede mai mult din date.

Ce afirmație este adevărată cu privire la regimul de performanță în care a ajuns modelul?

Select one:

- a. Modelul este în regim de underfitting (sub-potrivire)
- b. Modelul este în regim de overfitting (supra-potrivire) ✔
- c. Modelul este în regim optim

Răspunsul dumneavoastră este corect.

Modelul este in regim de overfitting fiindca pe masura ce antrenarea progreseaza, eroarea pe train scade (modelul devine mai specific pe datele de antrenare), dar eroarea pe test/generalizare creste.

The correct answer is: Modelul este în regim de overfitting (supra-potrivire)

Question **36**

Correct

Mark 1.00 out of 1.00

Regularizarea regresiilor liniare și logistice presupune

Select one:

- a. Selectarea acelor atribute ale datelor de intrare care sunt mai informative
- b. Adăugarea unui termen în funcția de cost care penalizează ponderile cu valori mari ✔
- c. Creșterea dimensiunii setului de antrenare prin adăugarea de noi exemple
- d. Transformarea spațiului de intrare într-unul mai complex

Răspunsul dumneavoastră este corect.

The correct answer is: Adăugarea unui termen în funcția de cost care penalizează ponderile cu valori mari

Question **37**

Correct

Mark 1.00 out of 1.00

In regresia logistica se folosesc:

(a) Distributie Bernoulli

(b) Distributie categoriala

(c) Distributie binomiala

(d) Distributie multinomiala

Select one:

- a. (a) + (b)
- b. (c) + (d)
- c. (b) + (c)
- d. (a) + (b) + (c)
- e. (a) + (c) ✔

Răspunsul dumneavoastră este corect.

The correct answer is: (a) + (c)

Question **38**

Correct

Mark 1.00 out of 1.00

Dorim sa rezolvam o problema de clasificare binara. Avem 2 clase, fiecare clasa cu 500 de exemple. Datele sunt liniar separabile.

Care este numarul maxim si minim de vectori suport?

Select one:

- a. minim - 1000, maxim - 1000
- b. minim - 250, maxim - 500
- c. minim - 500, maxim - 500
- d. minim - 2, maxim - 1000 ✔

Răspunsul dumneavoastră este corect.

The correct answer is: minim - 2, maxim - 1000

Question **39**

Correct

Mark 1.00 out of 1.00

Intr-un arbore de decizie pentru clasificarea unor exemple care contin atribute cu valori continue, are sens sa repetam pe o anumita ramura a arborelui (cale de la radacina la o frunza) un acelasi atribut ?

Select one:

- True ✔
- False

The correct answer is 'True'.

Question **40**

Correct

Mark 1.00 out of 1.00

Dorim să prezicem prețul unui apartament din zona Pipera. Pentru a face acest lucru ce putem folosi dintre:

Select one:

- a. Regresie liniară sau logistică
- b. Arbori de decizie
- c. Regresie logistică
- d. Regresie liniară sau arbori de decizie
- e. Regresie liniară ✔

Răspunsul dumneavoastră este corect.

The correct answer is: Regresie liniară

◄ Test Curs 6 - RL

Jump to...

Laborator 7 - Q-Learning ►

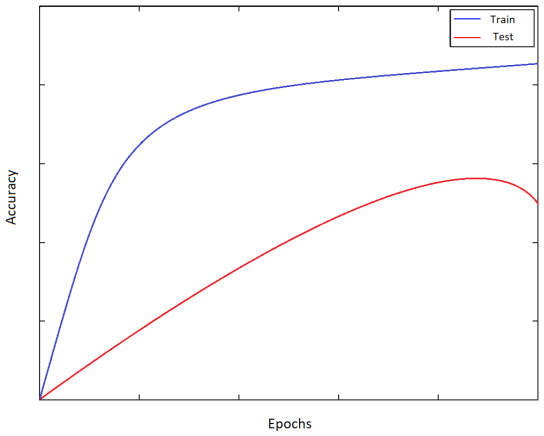
Examen ML(backup)

vezi si:

Partial ML

scris:

Cum interpretați figura de mai jos?



Alegeți o opțiune:

a. Rețeaua are arhitectura potrivită pentru setul de date pe care este antrenată

b. Rețeaua intră în regim de overfit

c. Rețeaua nu învață nicio caracteristică a datelor

În care din următoarele cazuri nu ați opta pentru utilizarea unui algoritm genetic:

Select one:

a. Problema are puține variabile care trebuie optimizate

b. Problema conține atât variabile continue cât și discretă

c. Nu există o soluție exactă pentru problemă

D. Functia de fitness este complexa si necesita mult efort computațional pentru a fi calculata

În cazul unui algoritm genetic cu o populație formată dintr-un singur individ, se pot obține indivizi noi în populatie folosind:

Alegeți o opțiune:

a. Recombinare urmată de mutație

b. Numai recombinare

Care dintre următoarele condiții au ca efect obținerea aceluiași rezultat pentru algoritmii Q-Learning si SARSA în privința valorilor Q estimate?

1. Un mediu determinist
2. Un mediu nedeterminist, dar unde tranziția între stări se face complet uniform
3. O metodă de explorare a acțiunilor într-o stare care este lacomă (greedy)
4. O rată de învățare egală cu zerou

Alegeți o opțiune:
a. 4

b. 3
c. 3 si 4
d. 2, 3 si 4
e. 1 si 4
f. 1, 3 si 4

As mentioned earlier, Q-learning and SARSA are very similar algorithms, and in fact, Q-learning is sometimes called SARSA-max. When the agent's policy is simply the greedy one (that is, it chooses the highest-valued action from the next state no matter what), Q-learning and SARSA will produce the same results.

Cred ca c. 3 (si 4?) -- da. Ca pe slide 30

In practical terms, under the ε-greedy policy, Q-Learning computes the difference between Q(s,a) and the maximum action value, while SARSA computes the difference between Q(s,a) and the weighted sum of the average action value and the maximum:

Q-Learning: $Q(s_{t+1},a_{t+1}) = max_a Q(s_{t+1},a)$

SARSA: $Q(s_{t+1},a_{t+1}) = \varepsilon \cdot mean_a Q(s_{t+1},a) + (1-\varepsilon) \cdot max_a Q(s_{t+1},a)$

(cred ca 3 si 4)

Cred ca si 4, ca daca lr e 0 nu invata nimic si au aceleasi valori

Fie următoarea populație de 5 stringuri, unde fiecare string reprezintă codificarea în binar a unui număr natural. Considerând funcția de selecție F = x / 100 + #1(x), care sunt indivizii aleși în pasul de selecție, utilizând metoda atribuire fitness proporțională?
Observație: #1(x) întoarce numărul de ”1” din reprezentarea în binar a lui x

Indivizi:
32: ”0100000”
95: ”1011111”
10: ”0001010”
73: ”1001001”
65: ”1000001”

Alegeți o opțiune:
a. 95, 73
b. 95, 95, 73
c. 32, 10, 95, 73, 65
d. 65, 95, 73

Considerăm situația în care se antrenează un model folosind gradient descent, însă nu se ajunge la costul global minim. Care ar putea fi motivul?

Select one:

a. Funcția de cost nu este concavă.

b. Funcția de cost nu ține cont de regularizare.

c. Funcția de cost nu este convexă.

d. Funcția de cost este un polinom de grad > 2.

Se considera o rețea neuronala cu doua iesiri care realizeaza o clasificare binara. Care dintre următoarele funcții de activare este recomandat a fi utilizata pentru stratul de ieșire.

Alegeți o opțiune:

a. sigmoid

b. ReLU

c. Leaky ReLU

Alegeți valoarea de adevăr pentru fiecare dintre următoarele propoziții:

i) Algoritmul Q-learning este de tipul on-policy

ii) Procesele de decizie Markov cu valori mici ale factorilor de atenuare accentuează recompensele pe termen scurt

Select one:

a. Fals, adevărat

b. Fals, fals

c. Adevărat, adevărat

d. Adevărat, fals

Considerăm situația în care se antrenează un model folosind gradient descent. La un moment dat derivată funcției de cost ajunge să fie 0, însa nu avem nicio informație despre funcția de cost. Ce se poate spune cu siguranță?

Alegeți o opțiune:

a. Funcția a ajuns într-un minim sau maxim global.

b. Nici o afirmație nu este adevărată (pe celălalt drive e asta... așa e, am pus eu greșit, sorry).

c. A fost găsit un minirata dem local.

d. A fost găsit un maxim global.

Straturile de tip Average Pool sunt utilizate în arhitecturile de rețele neuronale artificiale adânci cu scopul de a
Alegeți o opțiune:
a. Reduce dimensiunea activărilor de la ieșirea unui strat înainte de a fi trimis stratului următor
b. Reduce zgomotul din rețea prin efectuarea mediei activărilor **(asta?)**
c. Întări corelațiile care se întâmplă la nivel local.

d. Îmbunătăți calitatea informației care este propagată prin rețea.

Care din următoarele stringuri nu este un rezultat posibil care se poate obține pentru individul ”1934523107” după o operație de crossover, cu crossover point la 70% din lungimea individului?

Alegeți o opțiune:

a. 1934523107

b. 1934523813

c. 1034523207

d. 1984528107

Ce s-ar întâmpla într-o rețea neuronală artificială dacă am utiliza funcția de activare y = 2x, unde x este intrarea de pe un strat și y este ieșirea acestuia?

Alegeți o opțiune:

a. Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor.

b. Ponderile s-ar micșora considerabil.

c. Ar fi imposibil ca rețeaua să mai învețe să rezolve o problemă de clasificare sau regresie

d. Valorile de la output ar deveni foarte mari

Câți parametrii trebuie să învețe un layer de Average Polling cu dimensiunea kernel-ului de 2 și pas de 2?

Alegeți o opțiune:

a. 4

b. 2

c. 0

d. 3

Care dintre următoarele metode ajută la reducerea procesului de “overfitting”?

Alegeți o opțiune:

a. Folosim un model cu mai mulți parametri.

b. Utilizăm metode de regularizare.

c. Reducem rata de învățare pe parcusul antrenării.

d. Utilizăm un set aleator (redus) de feature-uri din setul de antrenare. **(de ce nu asta?)**

În algoritmul Q-Learning, care este efectul unei rate de învățare (learning rate) scăzute și a unui factor de atenuare (discount factor) ridicat:

Alegeți o opțiune:

a. Agentul prețuieste mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

b. Agentul prețuieste mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv

c. Agentul prețuieste mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

d. Agentul prețuieste mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv

Q-Learning este o instanță a TD(0).

Selectați o opțiune:

Adevărat

Fals

MSE (Mean Squared Error)Care dintre următoarele funcții de eroare ați utiliza pentru o rețea pe care o antrenați într-o problemă de regresie?

1. **Negative Log Likelihood**
2. **b. Binary Cross-Entropy**
3. **c. Multi-Class Cross-Entropy**

4. d. MSE (Mean Squared Error) e in intrebare

Ce funcții de activare ați folosi într-o rețea pentru a putea obține valori negative în urma aplicării activării:

Alegeți una sau mai multe opțiuni:

a. ReLU

b. Leaky ReLU

c. Tangentă hiperbolică

d. Logistică

Cum se poate preveni problema *vanishing gradients* în rețelele neurale adânci?

Alegeți o opțiune:

a. Prin creșterea numărului de parametri în straturi

b. Prin introducerea de conexiuni reziduale între straturi

c. Prin adăugarea mai multor straturi convoluționale în rețea

În formula de actualizare a parametrilor unei rețele folosind gradient descent cu momentum, ce se întâmplă când *gamma* are valoarea 1 și *eta* are valoarea 0?

Momentum based Gradient Descent Update Rule

$$v_t = \gamma * v_{t-1} + \eta \nabla w_t$$
$$w_{t+1} = w_t - v_t$$

Select one:
a. Formula devine echivalentă cu formula pentru SGD simplu
b. Rețeaua nu învață valorile optime ale parametrilor (cred + 1 + 1 +1)
c. Rețeaua învață foarte greu valorile optime ale parametrilor
d. Rețeaua învață mai repede valorile optime ale parametrilor

Câți parametri sunt într-o rețea care respectă structura de mai jos, antrenată pe setul de date MNIST (28x28x1):

L0: Input

L1: Conv1(c=5, k=5, p=2, s=1)

L2: MaxPool(k=2, s=2)

L3: Conv2(c=5, k=3, p=1, s=1)

L4: AvgPool(k=2, s=2)

L5: ReLU

L6: Output

Alegeți o opțiune:

a. 12

b. 245

c. 350

d. 170

Cum se reprezintă o politică?

Alegeți o opțiune:

a. O funcție care asociază valori (utilități) pentru fiecare pereche (stare, acțiune)

b. O funcție pentru asocieri stare - acțiune (https://stackoverflow.com/questions/46260775/what-is-a-policy-in-reinforcement-learning)

c. O listă cu acțiuni

d. O funcție pentru asocieri stare - utilitate

Fie următoarea rețea neuronala cu doua intrări intrări binare x_1, x_2 și funcție de activare treaptă. Specificati care este funcția calculata.



Alegeți o opțiune:

a. OR

b. NOT AND

c. XOR

d. AND (cred) <-+ 1 + 1 +1 100%

X1 x2 -> g(z)

0 0 -> 0

0 1 -> 0

1 0 -> 0

1 1 -> 1 deci AND

Fie un strat de convolutie cu intrarea de dimensiune (7x7), filtru de dimensiune (3x3), stride = 1 (se ingnora a treia dimensiune, nu exista padding). Specificati dimensiunea ieșirii stratului convolutional.

Alegeți o opțiune:

a. 7x7

b. 3x3

c. 5x5

Care dintre următoarele procedee au ca efect reducerea variabilității valorilor de actualizare a ponderilor (Δw) în timpul procesului de stochastic gradient descent (SGD)?

1. Reducerea dimensiunii batch-urilor
2. Reducerea ratei de învățare
3. Creșterea dimensiunii batch-urilor
4. Creșterea ratei de învățare

Alegeți o opțiune:

a. 1 si 4

b. 2

c. 3 si 4

d. 4

e. 2 si 3 (cred + 1) (+1)

f. 1

g. 1 si 2

h. 3

PARTEA II

Un algoritm genetic folosește cromozomi de forma x = abcdefgh, cu o lungime fixă de 8 gene (de la a la h).
Fiecare genă constă într-un număr din intervalul [0 .. 9]. Funcția de fitness a unui individ x se calculează prin
f(x) = (a+b) - (c+d) + (e+f) - (g+h).
Fie populația de invidizi dată prin:

O1: 8 7 1 2 3 5 3 2
O2: 6 5 9 2 1 2 3 2
O3: 2 7 1 2 6 2 0 1
O4: 5 8 3 4 3 9 4 2

Care este fitness-ul populației noi formate din (Onew1, Onew2, Onew3 și Onew4)? Este el mai mare decât fitness-ul populației anterioare?

Răspunsul
Care este individul cu fitness maximal si care este aceasta? Specificati raspunsul sub forma <nume_individ>:<valoare fitness>.

Răspunsul
Încrucișați indivizii O1 și O4 prin 2-point crossover, cu tăiere după genele b și f.

Scrieți indivizii rezultanți (Onew3 și Onew4) sub forma indicată în populație.

Răspunsul
Care este valoarea maximală de fitness care poate fi atinsă de un individ prin funcția f?

Răspunsul
Incrucișați primii doi indivizi în ordinea fitness-ului prin crossover single point (recombinare binară cu punct de recombinare la 50% din lungimea cromozomului).
Scrieți indivizii rezultanți (Onew1 și Onew2) sub forma indicată în populație (e.g. Onew1: a b c d e f g h).

Fie un set de 8 indivizi avand următoarele valori de fitness asociate

#Ind	1	2	3	4	5	6	7	8
Fit.	17	5	13	15	12	8	6	24

Cei 4 indivizi alesi conform unei proceduri de *selectie universala stohastica* (unde primul pointer are valoarea 0.1) sunt:

1 4 5 8

eu cred ca e 1 3 6 8 +1

Cei 4 indivizi alesi conform unei proceduri de *selectie pe baza de ruleta* cu extragerile aleatoare (0.1, 0.7, 0.5, 0.3) sunt:

1 3 5 8
eu cred ca e 1 4 5 8 +1

1 3 5 7

Se da următoarea reprezentare a valorilor Q pentru fiecare din acțiunile *A = {sus, jos, stânga, dreapta}*, asociate unei stări marcate prin simbolul ♦ în tabelul de mai jos.

Care va fi distribuția peste setul de acțiuni A atunci când agentul folosește metoda ε-greedy (cu ε = 0.1), și atunci când folosește o metodă de explorare ponderata (unde convertirea la probabilități se face prin operație de mediere ponderata a valorilor Q)?

Exprimați răspunsul ca tuplu de patru valori în ordinea (sus, jos, stanga, dreapta), cu precizie la a treia zecimală, prin rotunjire in jos.

	13.4	
2.4	♦	2.4
	12.1	

ε-greedy = (sus: 0.925, jos: 0.025, stanga: 0.025, dreapta: 0.025) (cred!!!)

explorare-ponderata = (sus: 0.442 jos: 0.399, stanga: 0.079, dreapta: 0.079) (cred!!!)

Se dă următoarea arhitectură a unei rețele convoluționale:
Input(64 x 64 x 3) -> Conv1(c=8, k=5, p=0, s=1) -> ReLU1 -> Conv2(c=16, k=3, p=1, s=1) -> Pool2(k=2, s=2) -> ReLU2 -> Conv3(c=32, k=3, p=0, s=1) -> ReLU3 -> Output,

unde c - numar de canale, k - dimensiune kernel, p = padding, s = stride, iar inputul este dat in formatul H x W x C (height, width, channels).

Care este dimensiunea pentru outputul final, exprimata in format (H, W, C)

Răspunsul

Alege..(28, 28, 32)144(32, 32, 32)(30, 30,

32)57600115272
(28, 28, 16)

Care este numărul total de ponderi aferente stratului convolutional Conv2

Răspunsul

Alege...(28, 28, 32)144(32, 32, 32)(30, 30, 32)57600
1152
72(28, 28, 16)

Teste de curs

SVM

1. Se considera un SVM cu Kernel polinomial de grad 2 care se aplica pe un set de date si se obtine o acuratete de 100%. Daca se creste gradul polinomului Kernel ce se va intampla?
a. Nu se va observa nici o modificare
b. Cresterea complexitatii va duce la underfitting
c. SVM-ul nu mai poate clasifica
d. Cresterea complexitatii va duce la overfitting

2. Avem o problema de clasificare cu 4 clase si utilizam un SVM cu metoda One-vs-all. De cate ori trebuie sa antrenam modelul?
a. 1
b. 2
c. 3
d. 4

3. Se antreneaza un SVM care obtine o acuratete foarte mare pentru un anumit set de date de antrenare si o acuratete mica pentru datele de validare. Care din urmatoarele afirmatii este adevarata?
a. Este un exemplu de overfitting
b. Sunt prea multe exemple de test
c. Sunt prea multe exemple de antrenare
d. Este un exemplu de underfitting

4. Odata ce aflam multiplicatorii Lagrange, cum se poate executa clasificarea?
a. Nu putem face clasificare
b. Se calculeaza b si apoi se calculeaza functia de clasificare pe baza lui b si a exemplelor de invatare
c. Se calculeaza functia de clasificare pe baza multiplicatorilor Lagrange si a exemplelor de invatare
d. Se calculeaza b si apoi se calculeaza w pe baza lui b

5. Numarul de exemple de test necesare pentru a obtine rezultate semnificativ statistice intr-o clasificare cu SVM trebuie sa fie:
a. nu depinde de rata de eroare
b. mare daca rata de eroare este mica
c. mare daca rata de eroare este mare

6. Cum afecteaza distanta dintre punctele exemple pozitive si punctele exemple negative marginea de separare?

a. Cu cat sunt mai departe unele de altele cu atat marginea de separare este mai mare
b. Nu afecteaza marginea de seprare
c. Cu cat sunt mai departe unele de altele cu atat marginea de separare este mai mica

7. Cum afecteaza distanta dintre punctele exemple pozitive si punctele exemple negative ponderile vectorilor suport?
a. Cu cat sunt mai departe unele de altele cu atat ponderile sunt mai mari
b. Distanta nu afecteaza ponderile
c. Cu cat sunt mai departe unele de altele cu atat ponderile sunt mai mici

8. Cea mai buna margine de separare este cea mai lata. Pentru a maximiza aceasta margine trebuie:
a. Sa se maximizeze functia Lagrange in raport cu w si b
b. Sa se maximizeze functia Lagrange in raport cu alfa
c. Sa se maximizeze w si b
d. Sa se minimizeze functia Lagrange in raport cu alfa

9. O buna practica pentru a evita overfitting-ul este:
a. Se foloseste o functie de optimizare mai buna
b. Se utilizeaza un parametru pentru a controla marginea soft
c. Nu exista buna practica
d. Se elimina aleator 50% din exemplele de antrenare

10. Vectorii suport sunt punctele (corespunzatoare exemplelor de invatare)
a. aflate in exteriorul marginii de separare a exemplelor
b. aflate in interiorul marginii de separare a exemplelor
c. corespund numai exemplelor pozitive
d. aflate pe extremitatea marginii de separare a exemplelor
e. corespund numai exemplelor negative

Curs 5 - Reinforcement Learning

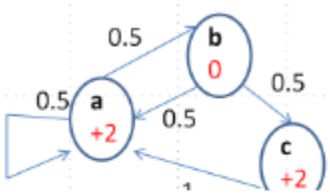
1. Care este diferenta intre un proces de decizie Markov (MDP) si un sistem Markov cu recompensa (MS)
a. MDP implica alegerea unei actiuni de catre agent pe cand MS nu
b. Intr-un MDP recompensa este atenuata pe masura functionarii agentului pe cand intr-un MS aceasta nu se atenueaza
c. In MDP agentul se deplaseaza intr-un mediu nedeterminist pe cand in MS mediul este determinist
d. Nu este nici o diferenta

2. Care este diferenta principala intre un proces de decizie Markov (MDP) si un agent RL? Bifati raspunsul corect.

a. In MDP agentul calculeaza utilitatile pe cand in RL agentul calculeaza recompense
b. In MDP mediul este determinist pe cand in RL mediul este nedeterminist
c. In MDP agentul are un model complet al mediului pe cand in RL agentul nu are un astfel de model

3. Ce valori se determina prin algoritmul de iterare a valorii?
a. actiunile agentului
b. utilitatea starilor
c. modelul de tranzitie al mediului
d. recompensa starilor

4. Se considera urmatorul sistem Markov cu factor de atenuare de 1/2
Care sunt valorile utilitatilor starilor (Ua, Ub, Uc) folosind Value Iteration (iterarea valorii) la momentul t=2 (functionarea incepe la momentul t=1)?



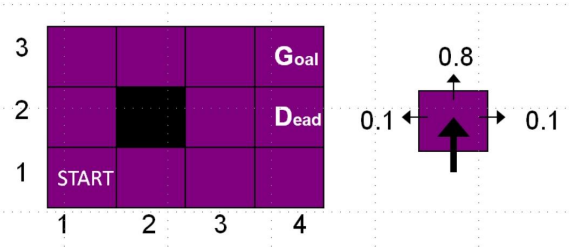
/mod/quiz/review.php?attempt=32565

Learning: Attempt review

a. (2 , 0 , 2)
b. (0 , 0 , 0)
c. (2.5 , 1 , 2) -> de ce nu (2.5 , 1 , 3)?
d. (3 , 1, 2.5)
e. (2.5 , 1.5 , 1.5)

5. Un agent RL parcurge urmatoarea secventa de stari
S1(R=1) -> S2(R=0) -> S3(R=2) -> S1(R=1) -> S3(R=2)
si obtine pentru fiecare stare recompensele indicate in paranteza. Factorul de atenuare este 1/2. Care este utilitatea estimata de agent pentru starea S1 in urma acestei explorari a mediului?
a. 15/8 -> de ce nu 14/8?
b. 7/4
c. 1/2
d. 11/4
e. 15/4

6. Fie urmatorul grid in mediu nedeterminist in care agentul se poate misca SUS, JOS, STANGA, DREAPTA. In urma unei miscari agentul ajunge in pozitia dorita cu o probabilitate de 0.8 si cu probabilitati de 0.1, 0.1 in pozitii aflate cu 90 de grade la stanga, respectiv dreapta pozitiei dorite. Daca deplasarea nu se poate face intr-o pozitie agentul ramane in acea pozitie cu probabilitatea 0.8, si 0.1, 0.1 se deplaseaza 90 de grade stanga, dreapta fata de pozitia dorita.
Considerand ca agentul porneste din starea START si urmeaza cea mai scurta secventa de actiuni care il duce in starea GOAL, care este probabilutatea de a ajunge in starea GOAL?



a. 0.32776
b. 0.0008
c. 0.32768 -> asta e marcat ca fiind gresit in testul vechi
d. 0.4096

7. Care din urmatoarele ecuatii corespunde modelului orizontului infinit atenuat?

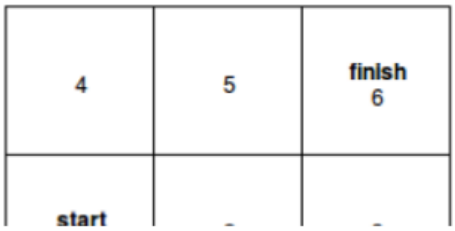
a. $U(S_t) = (\Sigma_{t=0,\infty} \delta^t R(S_t))$ ✔
b. $U(S_t) = (\Sigma_{t=0,\infty} R(S_t))$
c. $U(S_t) = (\Sigma_{t=0,n} R(S_t))$

Curs 6 - RL

1. Care din urmatoarele afirmatii este adevarata?
a. In Q-learning, politica este greedy, in SARSA politica nu este greedy
b. In Q-learning, politica nu este greedy, in SARSA politica nu este greedy
c. In Q-learning, politica nu este greedy, in SARSA politica este greedy

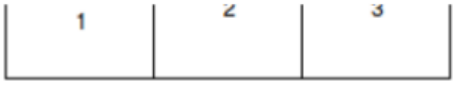
2. Metoda Temporal Difefrenec Learning este o metoda:
a. Model free si agent activ
b. Model based si agent activ
c. Model free si agent pasiv
d. Model based si agent pasiv

3. Fie urmatorul grid in care agentul parcurge episoade de la start la finish. Daca ajunge la finish se pozitioneaza din nou la start si reia episodul. In casuta finish recompensa este +10, in toate celelate stari recompensa este -1. Modelul mediului este deterministic.
Agentul se deplaseaza in grid up, down, left, right. Agentul incepe la start si la un moment dat are valorile Q din tabela de mai jos. Agentul are o politica greedy si un factor de atenuare de 0.9



mod/quiz/review.php?attempt=49488&cmid=1645

iew



Q(1,up)=4			Q(1,right)=3
Q(2,up)=6		Q(2,left)=3	Q(2,right)=8
Q(3,up)=9		Q(3,left)=7	
	Q(4,down)=2		Q(4,right)=5
	Q(5,down)=6	Q(5,left)=5	Q(5,right)=8

Care este urmatoarea valoare a lui Q(3,left)?
a. 6
b. 0.9
c. 1
d. 6.2
e. 7. 2

4. In Q learning agentul
a. invata si are un model al mediului

b. invata si nu are un model al mediului
c. nu invata si are un model al mediului

Curs 7-8

1. O retea care clasifica exemplele in mai multe clase, iar in setul de antrenare un exemplu poate apartine mai multor clase, foloseste pe ultimul nivel functia de activare softmax.
True
False

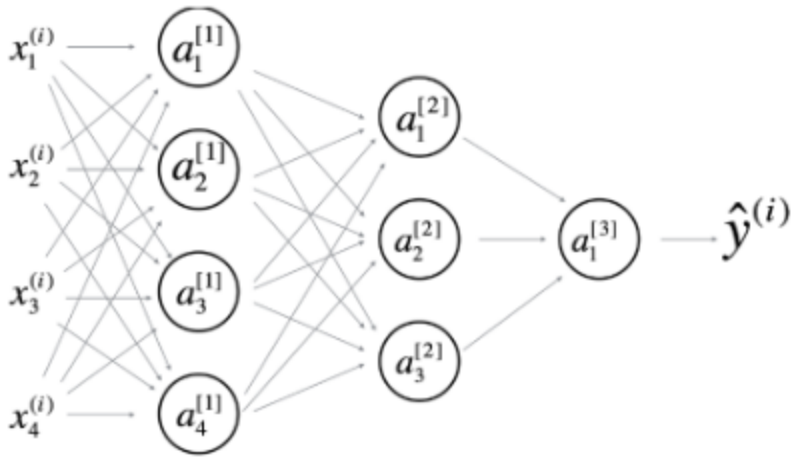
2. Intr-o retea cu mai multe straturi ce functie de activare se foloseste in general pe ultimul nivel?
a. ReLU
b. sigmoid
c. Leaky ReLU

3. In functionarea perceptronului ponderile se actualizeaza
a. proportional cu o valoare aleatoare mica
b. proportional cu intrarile
c. proportional cu intrarile si cu diferenta intre iesirea retelei si iesirea dorita

4. De ce este utila vectorizarea in calculul retelelor neurale?
a. Asa se spune dar nu este sigur ca este adevarat
b. Se lucreaza mai bine cu vectori si matrici
c. Elimina cicluri for

5. In regresia logistica in retea pentru m exemple de ce dwk nu este indexat dupa exemple?
a. Valoarea lui dwk este cumulativa
b. Derivata unei singure valori este relevanta
c. Se calculeaza o singura derivata

6. Fie urmatoarea retea



Care sunt dimensiunile matricilor:
(i) W[1], b[1]
(ii) W[2], b[2]
(iii) W[3], b[3]
In raspunsuri se specifica (numar linii, numar coloane) pt fiecare matrice

a. (i) (3,4) (4,1)
(ii) (3,1) (3,1)
(iii) (3,1) (1,1)
b. (i) (4,4) (3,4)
(ii) (3,4) (4,1)
(iii) (3,4) (4,1)
c. (i) (4,4) , (4,1)
(ii) (3,4), (3,1)
(iii) (1,3) (1,1)

7. Straturile mai adanci dintr-o retea calculeaza, in mod tipic,
a. caracteristici cu un grad de complexitate mai mare decat cele calculate in straturile mai putin adanci
b. caracteristici cu acelasi grad de complexitate ca cele calculate in straturile mai putin adanci
c. caracteristici cu un grad de complexitate mai mic decat cele calculate in straturile mai putin adanci

8. Care dintre urmatoarele formule este o implementare corecta a forward propagation pentru un nivel l, cu l intre 1 si L ?

a. $Z^{[l]} = W^{[l-1]}A^{[l]} + b^{[l-1]}$
$A^{[l]} = g^{[l]}(Z^{[l]})$

b. $Z^{[l]} = W^{[l]}A^{[l-1]} + b^{[l]}$
$A^{[l]} = g^{[l]}(Z^{[l]})$ ✔

c. $Z^{[l]} = W^{[l]}A^{[l]} + b^{[l]}$
$A^{[l+1]} = g^{[l]}(Z^{[l]})$

d. $Z^{[l]} = W^{[l]}A^{[l]} + b^{[l]}$
$A^{[l+1]} = g^{[l+1]}(Z^{[l]})$

9. O functie convexa are intotdeauna mai multe puncte de optiom locale
True
False

10. O retea de tip perceptron poate clasifica corect
a. orice date de intrare
b. date de intrare liniar separabile
c. date de intrare convexe

11. In backpropagation intr-o retea cu 2 straturi, fct sigmoid si vectorizare, dZ[2] se calculeaza dupa formula

a. $dA^{[1]} * g^{[1]'}(Z^{[1]})$

b. $W^{[2]T} * g^{[1]'}(Z^{[1]})$

c. $(1/m)\ sum_oriz(dZ^{[2]})$

d. $A^{[2]} - Y$ ✔

Lucrare 1

1. In regresia logistica se folosesc:
(a) Distributie Bernoulli
(b) Distributie categoriala
(c) Distributie binomiala
(d) Distributie multinomiala

a. (a) + (b) + (c)
b. (b) + (c)
c. (a) + (c)
d. (c) + (d)
e. (a) + (b)

2. Care dintre următoarele reprezintă presupunerea simplificatoare pe baza căreia operează clasificatorul Naive Bayes?
a. Distribuția din care sunt extrase datele este Bayesiană
b. Exemplele unui set de date sunt considerate independente între ele
c. Atributele unui exemplu sunt considerate independente între ele
d. Distribuția din care sunt extrase datele este Gausiană

3. In cazul algoritmului C4.5 daca avem valori necunoscute pentru un atribut in anumie exemple de invatare trebuie sa
a. atribuim acelui atribut valoarea cu cea mai mare frecventa din exemplele de invatare
b. atribuim acelui atribut valoarea cu cea mai mica frecventa din exemplele de invatare

4. Dorim sa rezolvam o problema de clasificare binara. Avem 2 clase, fiecare clasa cu 500 de exemple. Datele sunt liniar separabile.
Care este numarul maxim si minim de vectori suport?
a. minim - 250, maxim - 500
b. minim - 500, maxim - 500
c. minim - 1000, maxim - 1000
d. minim - 2, maxim - 1000

5. Un agent se mișcă într-un mediu 3x3 cu următoarele recompense:

	1	2	3
1	**0.5**	**0.5**	**0.5**
2	**-1**	**0.5**	**1**
3	**0.5**	**0.5**	**0.5**

Agentul poate executa acțiunile A1 (se mută la stânga cu probabilitatea 0.8 sau se mută în celula de sus cu probabilitatea 0.2) și A2 (se mută la dreapta cu probabilitatea 0.6, se mută în celula de sus cu probabilitatea 0.2 sau se mută în celula de jos cu probabilitatea 0.2). Care este

utilitatea stării (2,2) dacă factorul de atenuare are valoarea 0.9 (calculați folosind ecuația Bellman pentru un pas)?
a. 1.14
b. 1.22
c. 0.72
d. 0.5

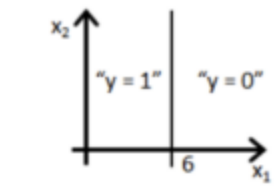
U(s) = max_a [R(s, a) + atenuare * sum_s' T(s, a, s') * U(s')
A1: U(2, 2) = 0.5 + 0.9 * (0.8 * (-1) + 0.2 * 0.5) = 0.5 - 0.9 * 0.7
A2: U(2, 2) = 0.5 + 0.9 * (0.6 * 1 + 0.2 * 0.5 + 0.2 * 0.5) = 0.5 + 0.9 * 0.8 = 1.22

6. Consideram urmatorul set de dat perechi (x,y):
(0,12) (1,13.5) (2,15) (3,16.5) (4,18) (5,19.5) (6,21)
Care functie descrie o regresie liniara pentru aceste date?
a. y=2.5x+12
b. y=1.5x+12
c. y=12x+5
d. y=0.6x+8

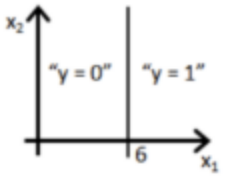
y = ax + b
(0, 12) => b = 12
(1, 13.5) => a = 1.5

7. Fie un set de exemple cu N atribute boolene si clasificare in clasa si non-clasa. Cati arbori de decizie diferiti putem construi ?
a. 2**N+1
b. 2N**
c. 2*N
d. 2N+1

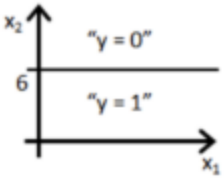
8. In urma antrenarii unei regresii liniare multi variabile, se obtine h(x) = -6 + 1*x1+0*x2. Care dintre figurile urmatoare este asociata acestei clasificari?



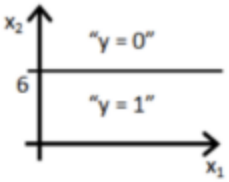
A.



B.



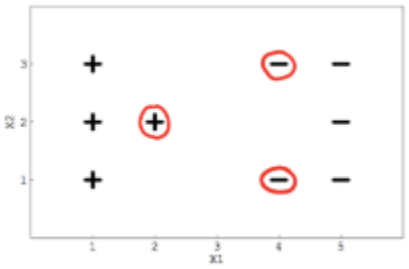
C.



D.

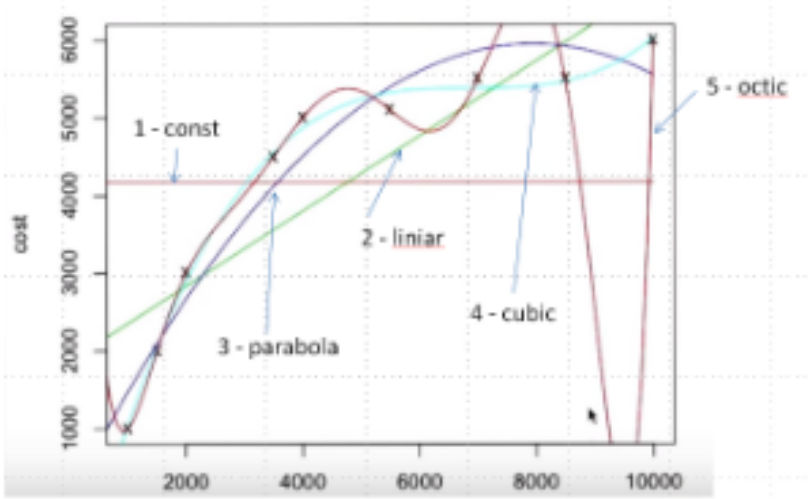
a. C
b. D
c. A
d. B

9. Dacă se elimina unul din punctele marcate cu rosu, hiperplanul de separare pentru un clasificator SVM se modifica?



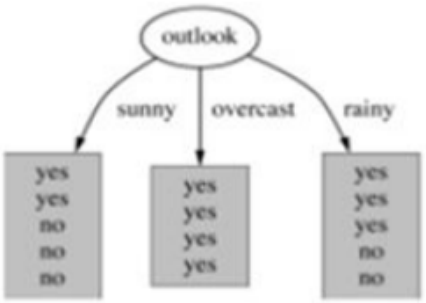
a. Da
b. Nu

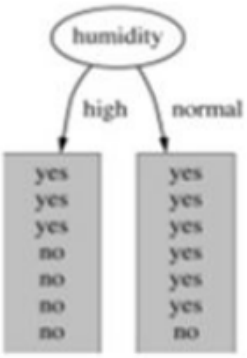
10. Care curba trebuie aleasa pentru o buna predictie pe baza datelor existente in graficul urmator, folosind regresiei liniara?

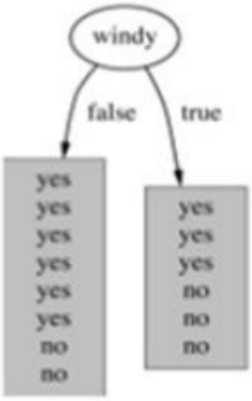


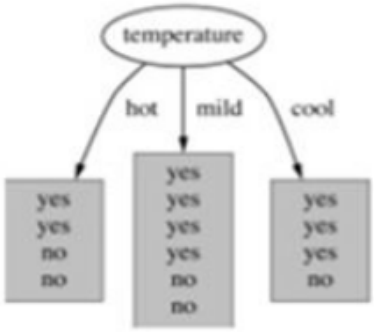
a. 2
b. 3
c. 1
d. 4
e. 5

11. Se antrenează un arbore de decizie având “maximum information gain” (câștigul maxim informațional, bazat pe diferenta de entropie) drept criteriu de selecție a atributelor. Considerând acest criteriu și următoarea situație de antrenare (cf. imaginii), care va fi atributul selectat pentru a “împărți” nodul curent:









a. Outlook
b. Temperature
c. Windy
d. Humidity

12. Ce tip de regresie ar trebui folosita pentru o problema in care dorim sa impartim un set de date in 2 categorii? (presupunem ca dorim sa antrenam un algoritm pentru care avem setul de date de antrenare)
a. Regresie liniara deoarece datele pot fi separate cu ajutorul unei drepte
b. Regresie logistica deoarece nu stim cum sa codificam "categoriile" in nume reale necesare regresiei liniare.
c. Regresia logistica deoarece foloseste functia logistica pentru a modela probabilitatea ca un punct din setul de date sa se gaseasca intr-o anumita clasa.
d. Regresie liniara deoarece cele 2 categorii (din setul de antrenare) pot fi etichetate cu 0 si 1. In etapa de antrenare algoritmul va avea de gasit o dreapta care trece prin cele 2 puncte (0 si 1)

13. Care dintre următoarele reprezintă criterii de oprire pentru construcția arborelui de decizie cu algoritmul ID3. Alegeți opțiunile corecte dintre:
1. Toate exemplele din subset fac parte din aceeași clasă
2. Câștigul informațional ajunge să fie negativ
3. Nu mai există atribute valide cu care să creăm un nod test
4. Adâncimea maximă este atinsă

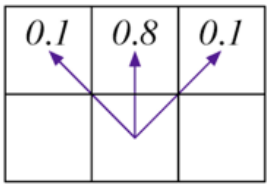
5. Câștigul informațional depășește un anumit prag

a. 4 și 5
b. 1
c. 1, 3 și 4
d. 1 și 4
e. 1, 2 și 3

14. Fie problema MDP. Se considera un grid cu 2 linii si 3 coloane, in care un agent se poate deplasa in directiile sus, jos, stanga, dreapta. Pentru fiecare stare recompensele sunt date in figura a). Deplasarea in grid va avea loc daca agentul ramane in grid. In caz contrar agentul va ramane pe loc. Deplasarea in directia aleasa se va face cu probabilitatea 0.8. Cu probabilitati 0.1, respectiv 0.1 agenul se va deplasa de-a lungul celor doua diagonale care incadreaza directia de deplasare aleasa (ca in figura b).

S1 (R=0)	S2 (R=0)	S3 (R=10)
S4 (R=0)	S5 (R=0)	S6 (R= -5)

a)



b)

Dupa un numar de episoade utilitatile starilor sunt: U(S1) = 5, U(S2) = 7, U(S3) = -3, U(S4) = 2, U(S5) = 4, U(S6) = =-6.
Care este utilitatea starii S5 pentru pasul urmator, avand factorul de atenuare = 0.9.
a. 2.57
b. 0.7
c. 5.4
d. 4
e. 5.22

U^k(Si) = ri + atenuare * sum_j P_ij * U(Sj)^(k - 1)
U(S5) = 0 + 0.9 * (0.8 * U(2) + 0.1 * U(S1) + 0.1 * U(S3)) = 0.9 * (0.8 * 7 + 0.1 * 5 + 0.1 * (-3)) = 0.9 * (5.6 + 0.5 - 0.3) = 0.9 * 5.8 = 5.22

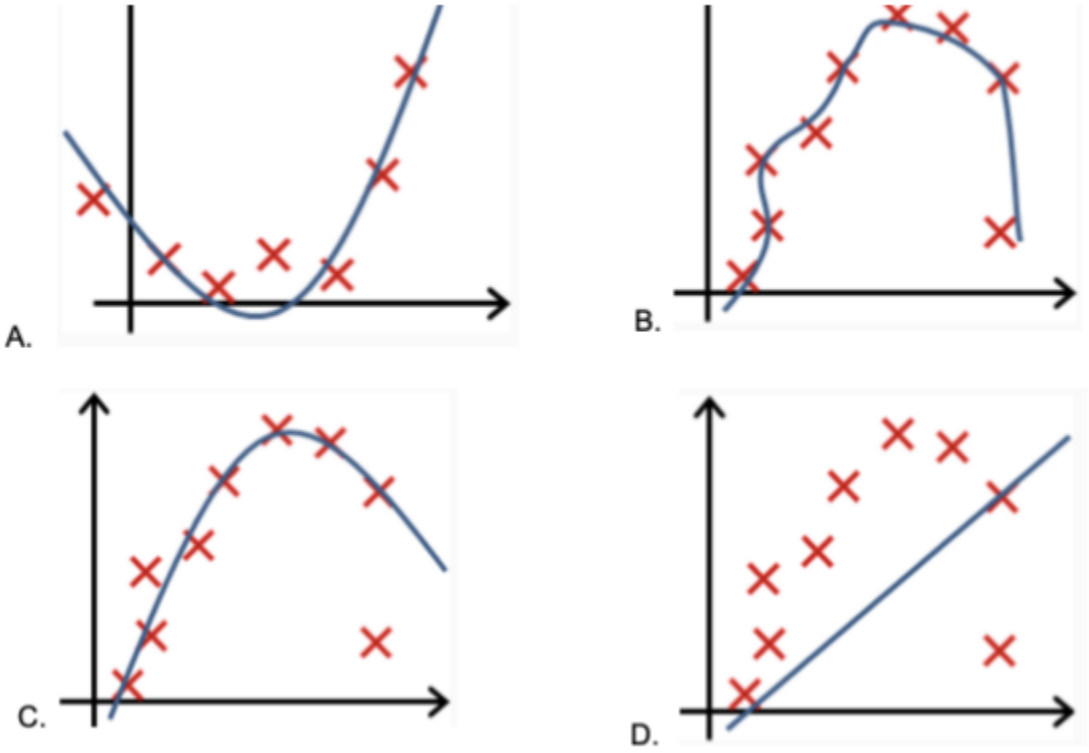
15. Care este diferența principală între clasele bagging și boosting ale algoritmilor de tip ensemble?
a. Clasificatorii metodelor de boosting sunt antrenați independent, în timp ce clasificatorii metodelor de bagging sunt antrenați iterativ
b. Spre deosebire de boosting, metodele de bagging folosesc clasificatori slabi
c. Spre deosebire de bagging, metodele de boosting folosesc clasificatori slabi
d. Clasificatorii metodelor de bagging sunt antrenați independent, în timp ce clasificatorii metodelor de boosting sunt antrenați iterativ

16. Datele de antrenare au erori deci ceea ce modelam nu este f ci f+eps. Considerand posibilele surse de erori mentionate mai jos care credeti ca sunt cele mai importante in rezolvarea unei probleme prin regresie liniara?
(a) Erori de la senzori
(b) Erori de la o sursa malitioasa care introduce special aceste erori
(c) Erori de transcriere (ale operatorului)
(d) Influente ale modelului care nu sunt luate in considerare

a. (a) si (b)
b. (a) si (c)
c. (a) si (b) si (c) si (d)
d. (a) si (b) si (c)

17. Un set de date utilizat pentru învățare supervizată are o valoare mare a entropiei informaționale dacă:
a. Foarte multe dintre exemple aparțin unui număr mic de clase, în timp ce restul de clase au un număr mic de exemple.
b. Toate exemplele fac parte din aceeași clasă
c. Numărul de exemple din fiecare clasă este relativ similar

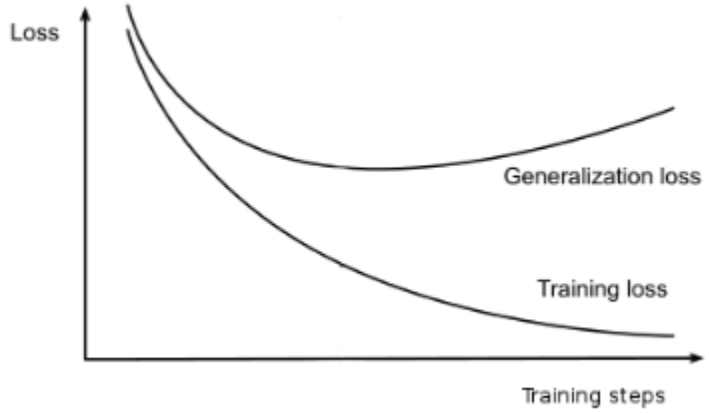
18. In urma antrenarii unei regresii, care figura corespunde aparitiei underfitingului?



a. D
b. A
c. B

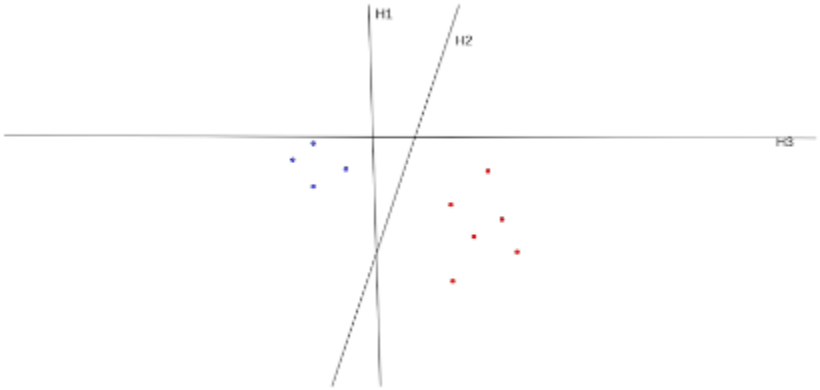
d. C

19. Curbele de învățare ale unui arbore de decizie arată ca în figura de mai jos
unde la fiecare pas de antrenare modelul vede mai mult din date.
Ce afirmație este adevărată cu privire la regimul de performanță în care a ajuns modelul?



a. Modelul este în regim optim
b. Modelul este în regim de underfitting (sub-potrivire)
c. Modelul este în regim de overfitting (supra-potrivire)

20. Avem un set de date cu 2 clase -- punctele rosii si albastre. Punctele si posibile hiperplanuri de separare sunt plotate mai jos. Care ar fi cel mai bun hiperplan de separare (dintre cele 3: H1, H2, H3)?



a. Nu exista un hiperplan de separare bun
b. H2
c. H3
d. H1

21. Pe un set de date cu atribute discrete se antrenează un arbore de decizie T prin algoritmul ID3, cu adancime maximă h.
Pe același set de date se antrenează un model RandomForest M.

Modelul M folosește weak-learners (i.e. arborii de decizie care alcatuiesc Pădurea Aleatoare) identici cu T (i.e. același criteriu de alegere a atributelor, aceeași adâncime maximă h). Fiecare arbore din RandomForest este antrenat pe același set de date precum și folosind același set de atribute precum modelul T.
Modelul M astfel rezultat va avea:
a. Aceeași acuratețe ca T
b. Acuratețe mai bună ca T
c. Acuratețe mai mică decât T

22. Se dau următoarele două afirmații despre modelele de tip Gradient Boosted Trees.
1. Clasificatorii slabi (weak learners) sunt independenți unul de celălalt
2. Metoda Gradient Boosted Trees obține performanțe mai bune prin agregarea rezultatelor obținute de clasificatorii slabi (weak learners)
Care dintre cele două afirmații sunt adevărate:
a. 2
b. 1 și 2
c. 1
d. Nici una

23. Regularizarea regresiilor liniare și logistice presupune
a. Selectarea acelor atribute ale datelor de intrare care sunt mai informative
b. Transformarea spațiului de intrare într-unul mai complex
c. Creșterea dimensiunii setului de antrenare prin adăugarea de noi exemple
d. Adăugarea unui termen în funcția de cost care penalizează ponderile cu valori mari

24. Care dintre urmatoarele afirmatii este adevarata?
(a) O functie Kernel calculeaza un produs scalar intr-un un spatiu de dimensiune mai mare fata de spatiu de intrare
(b) Functia Kernel este o functie de similaritate

a. (a) si (b)
b. (a)
c. (b)
d. Nici una

25. In urma antrenarii unui SVM, sunt gasiti 3 vectori suport.
Dupa ceva timp mai gasim inca un set de date cu aceleasi caracteristici si clase ca setul folosit initial (cele 2 seturi de date nu contin intrari identitce).
Antrenam SVM-ul folosind reuniunea celor 2 seturi de date (setul reunit este inca liniar separabil), insa in urma procesului vectorii suport nu se schimba.
Care afirmatie este adevarata?
a. performanta noului model e mai buna ca a celui antrenat doar pe setul initial de date
b. antrenarea folosind doar al doilea set de date ar avea ca rezultat vectori suport diferiti

c. antrenarea SVM-ului folosind doar al doilea set de date va da mereu un hiperplan de separare diferit de cel initial

26. Procedura de cross-validation este folosită des pentru a găsi o valoare bună a hiperparametrilor unui model de învățare. În urma procedurii, se poate raporta o medie și o varianță a diferitelor modele (i.e. a instanțelor de model, pentru fiecare combinație de hiperparametrii).
Ce fel de modele vor fi preferate?
a. Modele cu medie mare și varianță mică
b. Modele cu medie mică și varianță mare
c. Modele cu medie mică și varianță mică
d. Modele cu medie mare și varianță mare

27. Se considera urmatorul set de exemple:

Nr	Culoare	Tip	Productie	Se

nod/quiz/review.php?attempt=57365&cmid=17251

review

				fura?
1	Rosu	Sport	Proprie	Da
2	Rosu	Sport	Proprie	Da
3	Rosu	Sport	Proprie	Da
4	Galben	Sport	Proprie	Da
5	Galben	Sport	Import	Da
6	Galben	SUV	Import	Nu
7	Galben	SUV	Import	Nu
8	Galben	SUV	Proprie	Da
9	Rosu	SUV	Import	Nu
10	Rosu	Sport	Import	Da

Aplicand algoritmul de invatare utilizand arbori de decizie, care este înalțimea minimă a arborelui?
a. 4
b. 1
c. 3
d. 2

28. Avem urmatoarea matrice de confuzie pentru o problema de clasificare binara (pe coloane sunt valorile reale, iar pe linii sunt valorile prezise).
Care afirmatie este adevarata?

	Positive	Negative

Positive	23	1
Negative	12	556

a. Accuracy=557/556
b. Recall=23/24
c. Precision=23/24
d. Accuracy=568/592

Precision = TP / (TP + FP) = 23 / (23 + 1) = 23 / 34
Recall = TP / (TP + FN) = 23 / (23 + 12) = 23 / 35
Accuracy = (TP + TN) / (TP + FP + FN + TN) = (23 + 556) / (23 + 1 + 12 + 556) = 579 / 592

29.

Care este transformarea $\phi(q)$ care corespunde Kernelului

$K(a,b) = \phi^T(a)\,\phi(b) = a_1^2b_1^2 + 2a_1a_2b_1b_2 + a_2^2b_2^2$

a. $[1 \quad q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 \quad \sqrt{2}q_2]$

b. $[q_1^2 \quad q_2^2 \quad \sqrt{2}q_1q_2]$ ✔

c. $[q_1 \quad q_2 \quad q_1^2 \quad q_2^2]$

d. $[q_1 \quad q_2 \quad \sqrt{2}q_1^2 \quad \sqrt{2}q_2^2]$

e. $[1 \quad q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 \quad \sqrt{2}q_2 \quad \sqrt{2}q_1q_2]$

30. Intr-un arbore de decizie pentru clasificarea unor exemple care contin atribute cu valori continue, are sens sa repetam pe o anumita ramura a arborelui (cale de la radacina la o frunza) un acelasi atribut?
True
False

31. In cazul antrenarii regresiei liniare folosind urmatorul set de date (x: intrare, y: iesire), specificati care este valoare J(0, 1), unde $J(\theta, \theta)$ este functia de eroare pătratică pentru modelul de regresie liniară.

x	y
3	4
2	1
4	3
0	1

a. 1
b. 0.5

h_θ(x) = 0 + 1 * x = x
J(θ, θ) = 1/2n * sum_i (h(xi) - yi)^2 = 1/ 8 * (1 + 1 + 1 + 1) = 0.5

32. Care este ecuația care definește dreapta pe care se află vectorii suport ai clasei pozitive după determinarea marginii în algoritmul SVM? (w' reprezintă transpusul lui w)
a. w' * x + b = -1
b. w' * x + b = 1
c. w' * x + b > 1
d. w' * x + b = 0

33. Dorim să prezicem prețul unui apartament din zona Pipera. Pentru a face acest lucru ce putem folosi dintre:
a. Regresie logistică
b. Arbori de decizie
c. Regresie liniară sau logistică
d. Regresie liniară
e. Regresie liniară sau arbori de decizie

34. Care este avantajul folosirii algoritmului ”iterarea valorilor” vs ”iterarea politicilor”?
a. Necesită un efort computațional mai mic
b. Calculează o politică optimă mereu, lucru care nu e garantat de ”Iterarea politicilor”
c. Poate fi aplicat în probleme în care nu se cunoaște dinamica mediului
d. Nu are avantaje

35. Ce presupune ”lama lui Occam” in contextul arborilor de decizie?
a. Un arbore corect de decizie trebuie să cuprindă toate atributele din setul de date
b. Nu există mai mulți arbori corecți pentru aceeași problemă
c. Nu se poate aplica principiul în contextul arborilor de decizie
d. Dacă sunt mai mulți arbori de decizie corecți, se preferă cel mai simplu

36. Care dintre urmatoarele sunt bune practici pentru reducerea overfitting-ului?
(a) Utilizarea unei funcții de cost cu 2 componente, care include un regulator pentru a penaliza complexitatea modelului
(b) Utilizarea unui optimizator bun pentru a reduce erorile pe datele de antrenare

(c) Construirea unei structuri de subseturi de modele imbricate, antrenarea pe fiecare subset pornind de la cel mai mic, si oprirea cand eroarea de cross-validare incepe sa creasca
(d) Eliminarea aleatoare a 50% din datele de antrenare

a. (c)
b. (a) si (c)
c. (a) si (b)
d. (b) si (c)
e. (a) si (b) si (c)

37. Folosim o regresie liniara pentru prezicerea prețului batoanelor de ciocolată “ROM” care a fost antrenat pe factorii economici din România. Modelul obține rezultate foarte bune, însă după ce este rulat peste 5 ani acesta va avea rezultatele diferite. Care poate fi cauza?
a. Factorii economici se schimbă, iar modelul trebuie re-antrenat folosind date noi
b. Trebuia să folosim o regresie logistică pentru a putea modela parametrul de timp
c. Modelul trebuia antrenat de la început cu mai multe date

38. Arborii de decizie construiți cu algoritmul ID3 prezintă robustețe crescută la „outliers”? Care dintre răspunsuri este cel mai plauzibil?
a. Nu, pentru că vom obține valori negative pentru câștigul informațional în cazul lor.
b. Da, întrucât acest lucru este garantat prin calculul entropiei.
c. Da, pentru că unele atribute nu sunt luate în considerare.
d. Nu, pentru că ele (outliers) influențează sub-arborii generați ca fii ai unui nod test.

39. In urma antrenarii unui algoritm de invatare automata, observati ca acesta are o acuratete foarte buna pe setul de antrenare, insa mica pe setul de testare.
Care poate fi motivul? Si cum am putea rezolva ? (presupunand ca avem un clasificator bazat pe arbori de decizie)
a. Underfitting. Eliminam aleator un procent de date din setul de antrenare.
b. Underfitting. Putem adauga mai multe date in setul de testare.
c. Overfitting. Putem aplica prunning.
d. Overfitting. Adaugam mai multe atribute dupa care sa facem clasificarea

40. Ce se intampla daca se alege viteza de invatare (parametrul α pentru algoritmul de gradient descent) foarte mica, respectiv foarte mare?
a. foarte mica - algoritmul de invatare ar putea sa conveaarga prea lent spre o solutie
foarte mare - algoritmul de invatare ar putea sa nu gaseasca solutia
b. foarte mica - algoritmul de invatare ar putea sa conveaarga repede spre o solutie.
foarte mare - algoritmul de invatare ar putea sa conveaarga prea lent spre o solutie
c. Nu se intampla nimic, viteza de invatare poate fi oricat deoarece algoritmul mereu va converge spre solutie in acelasi timp.
d. Nu conteza viteza de invatare, deoarece formula de actualizare a parametrilor nu tine cont de aceasta.

Lucrare 2

Partea 1

1. Ce funcții de activare ați folosi într-o rețea pentru a putea obține valori negative în urma aplicării activării
a. Logistică
b. Tangentă hiperbolică
c. Leaky ReLU
d. ReLU

2. Fie urmatoarea retea neuronala cu doua intrari binare x1, x2 si functie de activare treapta. Specificati care este functia calculata.



a. NOT AND
b. XOR
c. OR
d. AND

0, 0 => -30 + 0 * 20 + 0 * 20 = -30 < 0 => 0
0, 1 / 1, 0 => -30 + 0 * 20 + 1 * 20 = -10 < 0 => 0
1, 1 => -30 + 1 * 20 + 1 * 20 = 10 > 0 => 1

3. Câți parametri sunt într-o rețea care respectă structura de mai jos, antrenată pe setul de date MNIST (28x28x1):

2x
L0: Input
L1: Conv1(c=5, k=5, p=2, s=1)
L2: MaxPool(k=2, s=2)
L3: Conv2(c=5, k=3, p=1, s=1)
L4: AvgPool(k=2, s=2)

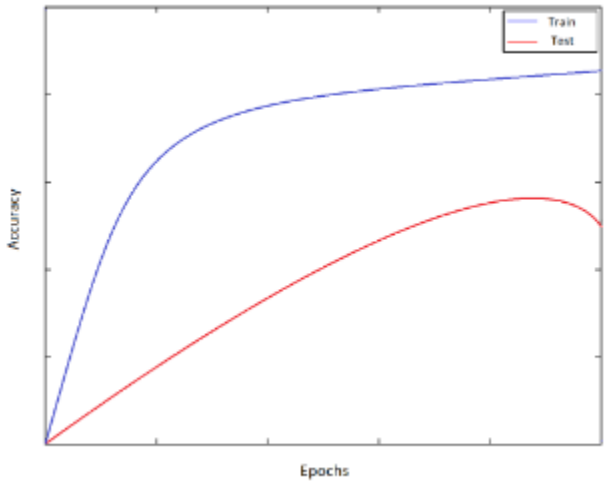
L5: ReLU
L6: Output
a. 12
b. 245
c. 170
d. 350

Layere cu parametri: Conv1, Conv2
Conv1: 1 * c1 * k1^2 = 125
Conv2: c1 * c2 * k2^2 = 225
=> 350

4. Alegeți valoarea de adevăr pentru fiecare dintre următoarele propoziții:
i) Algoritmul Q-learning este de tipul on-policy
ii) Procesele de decizie Markov cu valori mici ale factorilor de atenuare accentuează recompensele pe termen scurt
a. Adevărat, adevărat
b. Adevărat, fals
c. Fals, fals
d. Fals, adevărat

5. Câți parametrii trebuie să învețe un layer de Average Polling cu dimensiunea kernel-ului de 2 și pas de 2?
a. 2
b. 4
c. 3
d. 0

6. Cum interpretați figura de mai jos?



a. Rețeaua nu învață nicio caracteristică a datelor

b. Rețeaua are arhitectura potrivită pentru setul de date pe care este antrenată
c. Rețeaua intră în regim de overfit

7. În care din următoarele cazuri nu ați opta pentru utilizarea unui algoritm genetic:
a. Funcția de fitness este complexă și necesită mult efort computațional pentru a fi calculată
b. Nu există o soluție exactă pentru problemă
c. Problema conține atât variabile continue cât și discrete -> asta era pusa in test dar mi se pare fututa
d. Problema are puține variabile care trebuie optimizate

8. Ce s-ar întâmpla într-o rețea neuronală artificială dacă am utiliza funcția de activare y = 2x, unde x este intrarea de pe un strat și y este ieșirea acestuia?
a. Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor.
b. Ar fi imposibil ca rețeaua să mai învețe să rezolve o problemă de clasificare sau regresie
c. Valorile de la output ar deveni foarte mari
d. Ponderile s-ar micșora considerabil.

9. Se considera o rețea neuronala cu doua iesiri care realizeaza o clasificare binara. Care dintre următoarele funcții de activare este recomandat a fi utilizata pentru stratul de ieșire.
a. ReLU
b. Leaky ReLU
c. sigmoid

10. Considerăm situația în care se antrenează un model folosind gradient descent, însă nu se ajunge la costul global minim. Care ar putea fi motivul?
a. Funcția de cost nu ține cont de regularizare.
b. Funcția de cost este un polinom de grad > 2.
c. Funcția de cost nu este concavă.
d. Funcția de cost nu este convexă.

11. În algoritmul Q-Learning, care este efectul unei rate de învățare (learning rate) scăzute și a unui factor de atenuare (discount factor) ridicat:
a. Agentul prețuieste mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv
b. Agentul prețuieste mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator
c. Agentul prețuieste mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv
d. Agentul prețuieste mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

12. Fie un strat de convolutie cu intrarea de dimensiune (7x7), filtru de dimensiune (3x3), stride = 1 (se ingnora a treia dimensiune, nu exista padding). Specificati dimensiunea ieșirii stratului convolutional.
a. 5x5
b. 7x7
c. 3x3

Hout = (Hin + 2p - d * (k - 1) - 1) / s + 1 = ((7 - (3 - 1) - 1) / 1 + 1 = 5

13. Fie următoarea populație de 5 stringuri, unde fiecare string reprezintă codificarea în binar a unui număr natural. Considerând funcția de selecție F = x / 100 + #1(x), care sunt indivizii aleși în pasul de selecție, utilizând metoda atribuire fitness proporțională?
Observație: #1(x) întoarce numărul de ”1” din reprezentarea în binar a lui x
Indivizi:
32: ”0100000”
95: ”1011111”
10: ”0001010”
73: ”1001001”
65: ”1000001”
a. 32, 10, 95, 73, 65
b. 95, 95, 73
c. 95, 73
d. 65, 95, 73

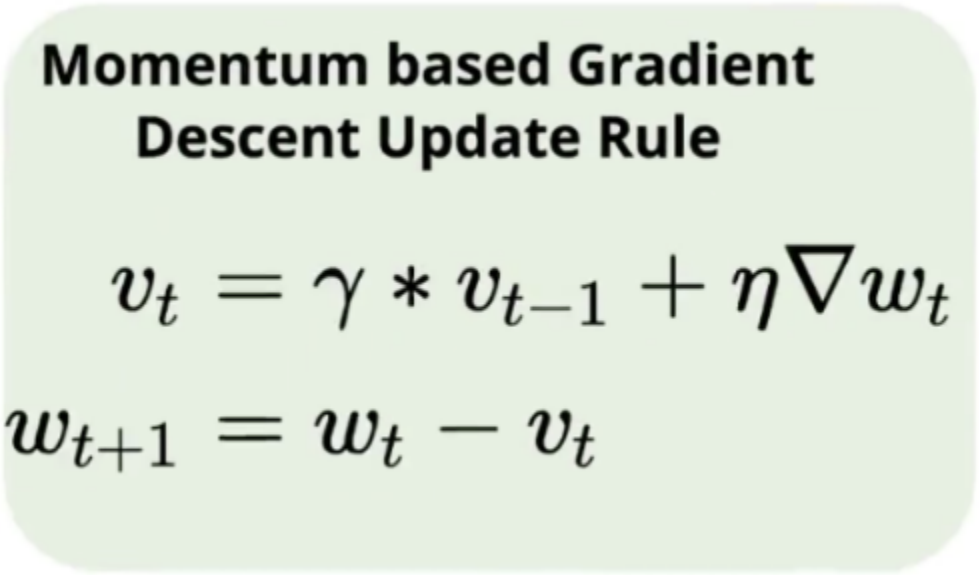
32 => 32 / 100 + 1 = 1.32
95 => 95 / 100 + 6 = 6.95
10 => 10 / 100 + 2 = 2.1
73=> 73 / 100 + 3 = 3.73
65 => 65 / 100 + 2 = 2.65
Avg = (1.32 + 6.95 + 2.1 + 3.73 + 2.65) / 5 = 16.75 / 5 = 3.35 => pastram 95 si 73
95 => 6.95 / 3.35 = 2 ori
73 => 3.73 / 3.35 = 1

14. Cum se poate preveni problema vanishing gradients în rețelele neurale adânci?
a. Prin creșterea numărului de parametri în straturi
b. Prin introducerea de conexiuni reziduale între straturi
c. Prin adăugarea mai multor straturi convoluționale în rețea

15. Straturile de tip Average Pool sunt utilizate în arhitecturile de rețele neuronale artificiale adânci cu scopul de a
a. Întări corelațiile care se întâmplă la nivel local.
b. Reduce dimensiunea activărilor de la ieșirea unui strat înainte de a fi trimis stratului următor
c. Îmbunătăți calitatea informației care este propagată prin rețea.

d. Reduce zgomotul din rețea prin efectuarea mediei activărilor

16. În formula de actualizare a parametrilor unei rețele folosind gradient descent cu momentum, ce se întâmplă când gamma are valoarea 1 și eta are valoarea 0?



a. Rețeaua nu învață valorile optime ale parametrilor
b. Rețeaua învață foarte greu valorile optime ale parametrilor
c. Rețeaua învață mai repede valorile optime ale parametrilor
d. Formula devine echivalentă cu formula pentru SGD simplu

17. Care din următoarele stringuri nu este un rezultat posibil care se poate obține pentru individul ”1934523107” după o operație de crossover, cu crossover point la 70% din lungimea individului?
a. 1984528107
b. 1034523207
c. 1934523813
d. 1934523107

1934523---107

18. Considerăm situația în care se antrenează un model folosind gradient descent. La un moment dat derivata funcției de cost ajunge să fie 0, însa nu avem nicio informație despre funcția de cost. Ce se poate spune cu siguranță?
a. Funcția a ajuns într-un minim sau maxim global.
b. A fost găsit un minim local.
c. A fost găsit un maxim global.
d. Nici o afirmație nu este adevărată.

19. Care dintre următoarele metode ajută la reducerea procesului de “overfitting”?
a. Utilizăm un set aleator (redus) de feature-uri din setul de antrenare.
b. Folosim un model cu mai mulți parametri.
c. Utilizăm metode de regularizare.
d. Reducem rata de învățare pe parcusul antrenării.

20. Care dintre următoarele condiții au ca efect obținerea aceluiași rezultat pentru algoritmii Q-Learning si SARSA în privința valorilor Q estimate?
1. Un mediu determinist
2. Un mediu nedeterminist, dar unde tranziția între stări se face complet uniform
3. O metodă de explorare a acțiunilor într-o stare care este lacomă (greedy)
4. O rată de învățare egală cu zero

a. 3
b. 1, 3 si 4
c. 3 si 4
d. 4
e. 1 si 4
f. 2, 3 si 4

21. Care dintre următoarele procedee au ca efect reducerea variabilității valorilor de actualizare a ponderilor (Δw) în timpul procesului de stochastic gradient descent (SGD)?
1. Reducerea dimensiunii batch-urilor
2. Reducerea ratei de învățare
3. Creșterea dimensiunii batch-urilor
4. Creșterea ratei de învățare

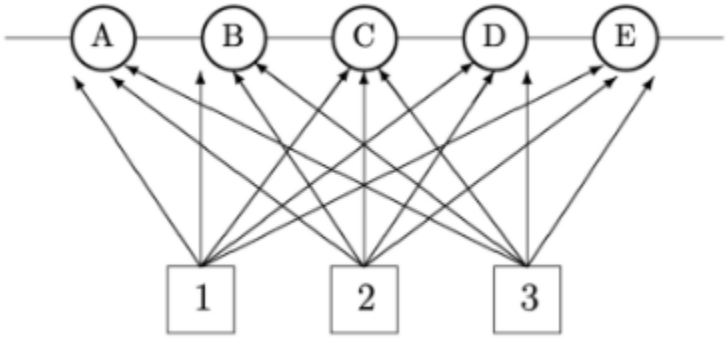
a. 1 si 4
b. 4
c. 3 si 4
d. 1
e. 3
f. 2 si 3
g. 1 si 2
h. 2

22. Cum se reprezintă o politică?
a. O funcție pentru asocieri stare - acțiune
b. O funcție pentru asocieri stare - utilitate
c. O funcție care asociază valori (utilități) pentru fiecare pereche (stare, acțiune)
d. O listă cu acțiuni

23. În cazul unui algoritm genetic cu o populație formată dintr-un singur individ, se pot obține indivizi noi în populatie folosind:
a. Recombinare urmată de mutație
b. Numai recombinare

24. MSE (Mean Squared Error)Care dintre următoarele funcții de eroare ați utiliza pentru o rețea pe care o antrenați într-o problemă de regresie?
a. Multi-Class Cross-Entropy
b. Negative Log Likelihood
c. Binary Cross-Entropy
d. MSE (Mean Squared Error)

25. Pentru urmatoarea retea SOM, care are 5 noduri (A - E) si 3 intrari. Reteaua clasifica avioane pe baza valorilor celor trei intrari: 1 (dimensiune avion), 2 (numar maxim pasageri), 3 (viteza maxima posibila). Care este numarul maxim de tipuri de avioane ce pot fi clasificate?



a. 4
b. 2
c. 5
d. 3

26. Q-Learning este o instanță a TD(0).
True
False

Partea 2

1. Q-learning

Se da următoarea reprezentare a valorilor Q pentru fiecare din acțiunile A = {sus, jos, stânga, dreapta}, asociate unei stări marcate prin simbolul ♦ în tabelul de mai jos.

Care va fi distribuția peste setul de acțiuni A atunci când agentul folosește metoda ε-greedy (cu ε = 0.1), și atunci când folosește o metodă de explorare ponderata (unde convertirea la probabilități se face prin operație de mediere ponderata a valorilor Q)?
Exprimați răspunsul ca tuplu de patru valori în ordinea (sus, jos, stanga, dreapta), cu precizie la a treiazecimală, prin rotunjire in jos.

13.4
2.4 ♦ 2.4
12.1

2. Retele neurale

Se dă următoarea problemă de clasificare binară.



Se presupune cunoscut faptul că un clasificator liniar (e.g. regresie logistică, SVM cu kernel liniar), NU poate clasifica în mod corect setul de antrenare reprezentat mai sus.
Considerați o rețea neurală de tip feed-forward configurată în modul următor:
Input -> [strat liniar] -> activare liniara -> [strat liniar] -> activare liniara -> [strat liniar] -> activare logistică-> Output
Este această configurație de rețea capabilă să învețe o clasificare 100% corectă a problemei date? Justificați.

Raspuns de anul trecut (1/1):
Stratul si functia de activare sunt liniare, deci rezultatele vor fi doar combinatii liniare ale intrarilor, care stim deja ca nu pot fi clasificate corect. Nu este. Pentru a clasifica corect, ar trebui sa introducem o functie non-liniara.

Raspuns dintr-un doc:
Nu, pentru a rezolva problema este nevoie de un clasificator non-liniar care sa separe corecte datele de intrarea.

3. AG

Un algoritm genetic folosește cromozomi de forma x = abcdefgh, cu o lungime fixă de 8 gene (de la a la h). Fiecare genă constă într-un număr din intervalul [0 .. 9]. Funcția de fitness a unui individ x se calculează prin f(x) = (a+b) - (c+d) + (e+f) - (g+h).
Fie populația de invidizi dată prin:
O1: 8 7 1 2 3 5 3 2
O2: 6 5 9 2 1 2 3 2

O3: 2 7 1 2 6 2 0 1
O4: 5 8 3 4 3 9 4 2

Care este individul cu fitness maximal si care este aceasta? Specificati raspunsul sub forma<nume_individ>:<valoare fitness>.
O1:15

f(O1) = (8 + 7) - (1 + 2) + (3 + 5) - (3 + 2) = 15 - 3 + 8 - 5 = 15
f(O2) = (6 + 5) - (9 + 2) + (1 + 2) - (3 + 2) = 11 - 11 + 3 - 5 = -2
f(O3) = (2 + 7) - (1 + 2) + (6 + 2) - (0 + 1) = 9 - 3 + 8 - 1 = 13
f(O4) = (5 + 8) - (3 + 4) + (3 + 9) - (4 + 2) = 13 - 7 + 12 - 6 = 12
f(old_pop) = 15 - 2 + 13 + 12 = 38

Încrucișați indivizii O1 și O4 prin 2-point crossover, cu tăiere după genele b și f.
Scrieți indivizii rezultanți (Onew3 și Onew4) sub forma indicată în populație.
Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 2
Ox: **a b** c d e f **g h**
O1: **8 7** 1 2 3 5 **3 2**
O4: 5 8 **3 4 3 9** 4 2
=> 8 7 + 3 4 3 9 + 3 2 = **8 7 3 4 3 9 3 2**
5 8 + 1 2 3 5 + 4 2 = **5 8 1 2 3 5 4 2**

Care este fitness-ul populației noi formate din (Onew1,Onew2, Onew3 și Onew4)? Este el mai mare decâtfitness-ul populației anterioare?
f(new_pop)=55, DA

f(Onew1) = (8 + 7) - (1 + 2) + (6 + 2) - (0 + 1) = 19
f(Onew2) = (2 + 7) - (1 + 2) + (3 + 5) - (3 + 2) = 9
f(Onew3) = (8 + 7) - (3 + 4) + (3 + 9) - (3 + 2) = 15 - 7 + 12 - 5 = 15
f(Onew4) = (5 + 8) - (1 + 2) + (3 + 5) - (4 + 2) = 13 - 3 + 8 - 6 = 12
f(new_pop) = 19 + 9 + 15 + 12 = 55

Care este valoarea maximală de fitness care poate fi atinsă de un individ prin funcția f?
F_max = (9 + 9) - (0 + 0) + (9 + 9) - (0 + 0) = **36**

Incrucișați primii doi indivizi în ordinea fitness-ului prin crossover single point (recombinare binară cu punct de recombinare la 50% din lungimea cromozomului).
Scrieți indivizii rezultanți (Onew1 și Onew2) sub forma indicată în populație (e.g. Onew1: a b c d e f g h).
Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2

O1: **8 7 1 2** 3 5 3 2
O3: 2 7 1 2 **6 2 0 1**

4. Q-learning

Se considera stările (s_1, s_2, s_3, s_4); în fiecare stare poate fi executată una din acțiunile (a_1, a_2, a_3). După aplicarea algoritmului Q-learning, pentru un număr de episoade, se obțin următoarele valorile Q(stare, acțiune):

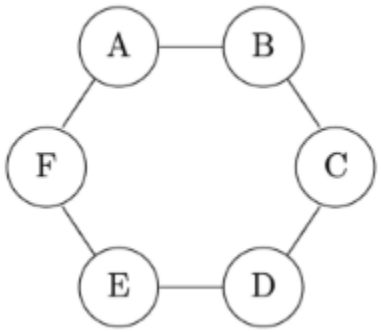
	$s = s_1$	$s = s_2$	$s = s_3$	$s = s_4$
$a = a_1$	0.1	0.2	0.3	0.4
$a = a_2$	0.5	0.6	0.7	0.8
$a = a_3$	0.9	1.0	1.1	1.2

In continuare, agentul porneste din starea s_3 si executa acțiunea a_1. El va primi recompensa 1 și va trece în starea s_2. În aceasta stare el va alege sa execute acțiunea a_2, prin care va ajunge în starea s_4, iar recompensa primită va fi 0. Calculati modificările pentru Q(stare, actiune) prin executarea acestor acțiuni ($\alpha = 0.2$, $\delta = 0.9$).

Raspuns (1/1):
Q(s3, a1) = 0.3 + 0.2 * (1 + 0.9 * 1 - 0.3) = 0.62 Q(s2, a2) = 0.6 + 0.2 * (1 + 0.9 * 1.2 - 0.6) = 0.896

5. SOM

Pentru urmatoarea retea SOM cu 6 noduri (A-F) si 2 intrari (x1, x2 - intrarile nu sunt specificate in figura) ponderile asociate fiecarui nod sunt w1 si w2. Se considera valoarea (2, -4) aplicata pe intrari. Se utilizeaza distanta euclidiana, specificati care sunt nodurile pentru care se vor actualiza ponderile (se considera o vecinatate cu raza = 1).



Node	A	B	C	D	E	F
w_1	-1	0	3	-2	3	4
w_2	2	4	-2	-3	2	-1

Raspuns (1/1):
Punctul x, y = (2, -4)
D(x, A) = (w1 - x) ^ 2 + (w2 - y) ^ 2 = 3^2 + 6^2 = 9 + 36 = 45
D(x, B) = 2 ^ 2 + 8 ^ 2 = 4+ 64 = 68
D(x, C) = 1^2 + 2^2 = 5
D(x, D) = 4^2 + 1^2 = 17
D(x, E) = 1^2 + 6^2 = 37
D(x, F) = 2^2 + 3^2 = 13

Se observa ca cel mai apropiat punct este C. R = 1, deci se vor actualiza sunt nodurile cu distanta < 1 fata de C, adica B si D, si nodul C

6. Retele convolutionale

Se dă următoarea arhitectură a unei rețele convoluționale:
Input(64 x 64 x 3) -> Conv1(c=8, k=5, p=0, s=1) -> ReLU1 -> Conv2(c=16, k=3, p=1, s=1) -> Pool2(k=2, s=2) -> ReLU2 -> Conv3(c=32, k=3, p=0, s=1) -> ReLU3 -> Output,
unde c - numar de canale, k - dimensiune kernel, p = padding, s = stride, iar inputul este dat in formatul H x W x C (height, width, channels).
Care este numărul total de ponderi aferente stratului convolutional Conv2
1152

c1 * c2 * k2^2 = 8 * 16 * 3^2 = 1152

Care este dimensiunea pentru outputul final, exprimata in format (H, W, C)
(28, 28, 32)

Input -> Conv1 -> Conv2 -> Pool2 -> Conv3
(64, 64, 3) -> (60, 60, 8) -> (60, 60, 16) -> (30, 30, 16) -> (28, 28, 32)

Hc1 = (Hc0 + 2p1 - d1 * (k1 - 1) - 1) / s1 + 1 = 64 - (5 - 1) = 60
Hc2 = (Hc1 + 2p2 - d2 * (k2 - 1) - 1) / s2 + 1 = 60 + 2 - (3 - 1) = 60
Hp2 = (Hc2 + 2pp2 - dp2 * (kp2 - 1) - 1) / sp2 + 1 = (60 - (2 - 1) - 1) / 2 + 1 = 58 / 2 + 1 = 30
Hc3 = (Hp2 + 2p3 - d3 * (k3 - 1) - 1) / s3 + 1 = 30 - (3 - 1) = 28

7. AG

Fie un set de 8 indivizi avand următoarele valori de fitness asociate

#Ind	1	2	3	4	5	6	7	8
Fit.	17	5	13	15	12	8	6	24

Cei 4 indivizi alesi conform unei proceduri de selectie universala stohastica (unde primul pointer are valoarea 0.1) sunt:
1,3,6,8

NPointer = 4
Distanta intre pointeri = 1 / NPointer = 1 / 4 = 0.25
P1 = 0.1 => 8
P2 = 0.35 => 1
P3 = 0.6 => 3
P4 = 0.85 => 6

F_tot = 17 + 5 + 13 + 15 + 12 + 8 + 6 + 24 = 100

8: [0, 0.24)
1: [0.24, 0.41)
4: [0.41, 0.56)
3: [0.56, 0.69)
5: [0.69, 0.81)
6: [0.81, 0.89)
7: [0.89, 0.95)
5: [0.95, 1)

Cei 4 indivizi alesi conform unei proceduri de selectie pe baza de ruleta cu extragerile aleatoare (0.1, 0.7, 0.5, 0.3) sunt:
1,4,5,8

P1 = 0.1 => 8
P2 = 0.7 => 5
P3 = 0.5 => 4
P4 = 0.3 => 1

F_tot = 17 + 5 + 13 + 15 + 12 + 8 + 6 + 24 = 100
8: [0, 0.24)
1: [0.24, 0.41)
4: [0.41, 0.56)
3: [0.56, 0.69)
5: [0.69, 0.81)
6: [0.81, 0.89)
7: [0.89, 0.95)
5: [0.95, 1)

Alte docuri

https://docs.google.com/document/d/1-MWB_t14EUTrWrE5KOm6CzzgFSuIYI54wlqnf_UVzrs/edit

1. invatarea pac.ce inseamna o ipoteza de invatare aproximativ corect,
ce inseamna o ipoteza de invatare probabil aproximativ corecta. Explicati semnificatia celor 2 notiuni pentru invatarea automata si explicati diferentele intre acestea.

2. Intr-o retea de tip SOM(Self organizing maps) , nu numai unitatea castigatoare este mutata catre exemplu dar si unitatile din vecinatatea acesteia. De ce este acest aspect important in metoda de invatare?

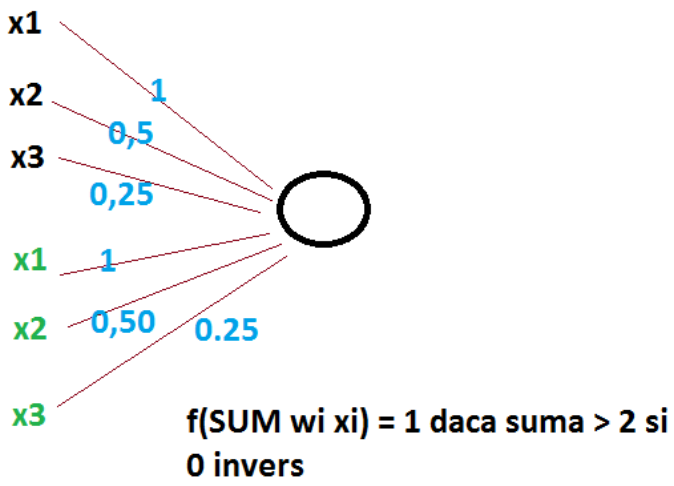
3. Sa se proiecteze o retea neurala care spune daca suma a 2 cifre(0<=cifra <=7) este mai mare ca 8.
R:

x1 ---(w1 = 1)---> |
|-> ** O = 9 ** -----> ** y = f(w1 * x1 + w2 * x2 - O) **
x2 ---(w2 = 1)---> |

f(x) = 1, pentru x > 0
0, altfel

O este “theta”, x1/2 sunt intrari, ce este intre “**” sunt neuroni

Î: Theta nu ar trebui sa fie 8 conform cerintei?
R: Pai zice > 8, nu >= 8.
Î: Domeniul cifrei conteaza la ceva?
R: DA / daca era binar



4. Care e conditia de convergenta la algoritmul de invatare al perceptronului? Dar la Hopfield?
R: In cazul perceptronului, invatarea se opreste atunci cand eroare este 0, cand diferenta dintre iesirea oferita de perceptron si valorile dorite pentru diverse intrari sunt identice. (Cand toate exemplele sunt clasificate corect)
Reteaua Hopfield converge atunci cand se ajunge intr-un minim local energetic, cand niciun neuron nu doreste sa isi schimbe starea. *Adica atunci cand iesirea fiecarui neuron la momentul t+1 este aceeasi ca cea la momentul t, nu? DA :)*

(liniar separabilitatea)(adica se updateaza weights-urile pana cand se ajunge la o clasificare corecta sau numarul iteratiei a ajuns la o valoare maxima?) Dar la Hopfield? (wij==wji) (Conditia de convergenta la Hopfield nu este cumva ca sablonul la momentul viitor (t+1) sa fie acelasi ca sablonul la momentul t? curs 4, pag 28)
Cred ca intrebarea se refera cand stim ca ar converge dinainte de rulare. In acest caz, la perceptron sigur e corecta liniar separabilitatea.

Atunci la Hopfield inseamna ca el converge daca M<0.138*N? (curs 4, pag 30) M=nr de clase, N=numarul de input-uri

Stai sa vad ce sunt M si N si wtf. CONCLUZIE: cred ca da

La Hopfield converge daca functia de energie e functie Lyapunov (iar Hopfield a demonstrat ca asta se intampla daca w_ii = 0 oricare i si w_ij = w_ji oricare i, j)

5. Care este legatura intre stabilizarea unei retele Hopfield si un proces de cautare?
R: Pentru a cauta un anumit sablon intr-o retea neurala Hopfield deja antrenata, se initializeaza starea neuronilor conform sablonului dorit si se lasa ca reteaua sa se stabilizeze. Starea finala a neuronilor este sablonul rezultat in urma cautarii.

Pentru regasirea unui sablon, este suficient sa se specifice numai o parte a acestuia, iar reteaua gaseste automat intreg sablonul.
Totusi, una dintre limitarile majore ale alg. hopfield este cazul in care un sablon are mai multe valori identice cu un alt sablon in exemple, caz in care sablonul poate fi instabil = reteaua converge spre o stare diferita de cea asociata sablonului.

Procesul de relaxare paralela a retelei pentru a atinge o stare stabila poate fi vazut ca un proces de cautare in spatiul starilor stabile ale retelei.O configuratie de intrare va forta reteaua sa ajunga intr-o stare stabila ce reprezinta un minim local , starea stabila cea mai apropiata.

6. Care este conditia de convergenta in cazul unei retele backpropagation ?
R: Eroarea sa fie 0.
Aici cred ca nu e bine. Se ajunge la convergenta cand eroarea nu se mai schimba (gradientii la iesire devin 0). => Mult mai bine așa; dacă ar fi eroarea 0, se poate să nu se ajungă niciodată în acel **punct** și nu se va mai opri. :)

perceptron: set de invatare sa fie liniar separabil;
backpropagation: ? (eroarea cu care se intoarce sa fie minima?)

7. Care sunt aplicatiile cele **mai importante** ale unei retele Hopfield si pe ce principii se bazeaza acestea ?
R: Recunoasterea de **patternuri**, problema comis voiajorului (*sa fim seriosi, problema comis voiajorului nu* **se** *rezolva cu Hopfield like*). Suntem, dar si decana a fost cand a bagat problema in **curs** :P (realizeaza o aproximare, in cel mai bun caz :)))
(Cele doua aplicatii ale retelei **Hopfield** au fost luate dintr-un paper.)

Aplicatia cea mai importanta a unei retele Hopfield este intelegerea memoriei umane (http://en.wikipedia.org/wiki/Hopfield_network).
Aplicații unde este căutată soluția de cost minim.

8. Retea, ponderi, functie de activ**are pentru:**

x1	**x2**	**y**
1	0	1

0 1 1
0 0 1
1 1 0

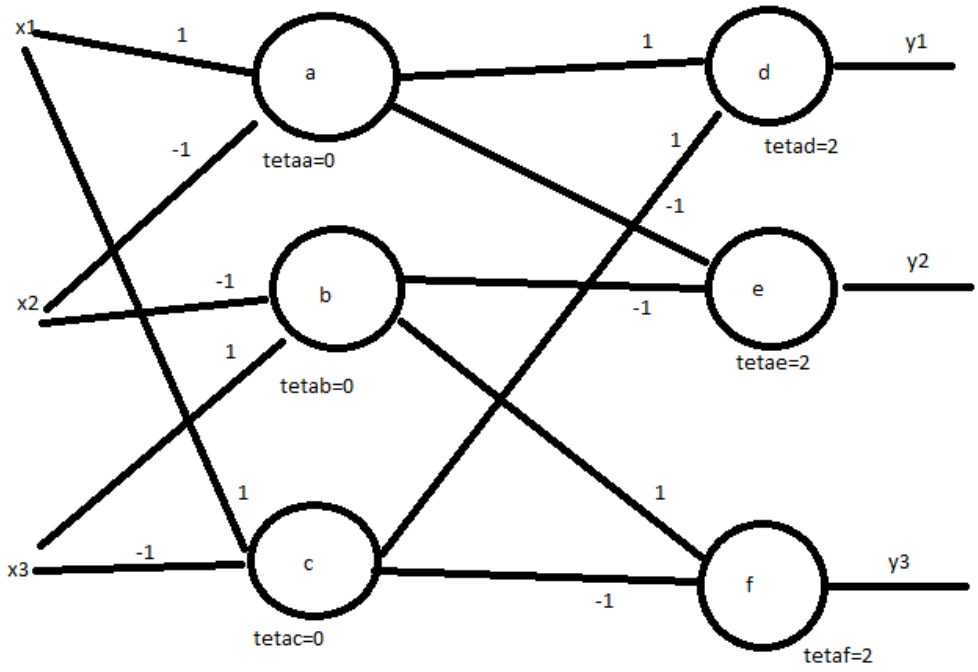
=> NAND
h = x1 * w1 + x2 * w2 - O
f(h) = y
f(w1 - O) = 1
f(w2 - O) = 1
f(- O) = 1
f(w1 + w2 - O) = 0
f(x) = 1, x > 0 altfel 0

w1 - O > 0
w2 - O > 0
0 > O
w1 + w2 - O < 0
=> 3 valori care merg sunt w1 = -2, w2 = -2 si O = -3

R: w1/2 = 1;
f(x1,x2) = (w1x1 + w2x2) < 2 ??
Asta nu e nand? mie asa mi se pare. Si ar fi w1 - 1; w2 -1.5 si teta -2

Un singur perceptron cu 2 intrari. w1 = -2; w2 = -2; teta = -3; f(x) = 1 daca x > teta si invers fx = 0;

9. Sa se construiasca o retea neurala cu 3 intrari si 3 iesiri, care sa afle maximul intrarilor.



Explicatii:

-neuronul a cu wx1=1 si wx2=-1 si teta=0 are iesirea 1 daca x1>x2 si -1 altfel

-neuronul b cu wx2=-1 si wx3=1 si teta=0 are iesirea 1 daca x3>x2 si -1 altfel

-neuronul c cu wx1=1 si wx3=-1 si teta=0 are iesirea 1 daca x1>x3 si -1 altfel

-neuronul d cu wa=1 si wc=1 si teta=2 are functia de AND(a, c), deci e activat cand max=x1

-neuronul e cu wa=-1 si wb=-1 si teta=2 are functia de AND(~a, ~b), deci e activat cand max=x2

-neuronul f cu wb=1 si wc=-1 si teta=2 are functia de AND(b, ~c), deci e activat cand max=x3

Exemplu: input: X=[0.3 0.5, -0.2]. Output: Y=[0, 1, 0]

10. Care este numarul de neuroni necesari pentru o retea cu n noduri de intrare si n noduri de iesire ?
R: n? cel putin n

Minim n ca sa fie n iesiri diferite… Confirmare, pls?

11. Indicati o retea neurala care sa poate sa reproduca litera C.
R: perceptron / hopfield.

Cursul 5, slide-ul 15 contine neuronul care se leaga la pixeli. In matrice sunt puse ponderile, iar teta = nr min de pixeli care trebuie sa faca match ca reteaua sa intoarca un raspuns pozitiv.

Număr de neuroni și dispunerea lor
- Hopfield

- Pe straturi

Apoi pentru fiecare neuron W-ul asociat.

Ex: Perceptron. Presupunem ca avem 9 pixeli:
xxx
x00
Xxx
Intrarile sunt fiecare pixel + o intrare legata la un -1 (adica omega din exemplul de mai jos)
Pentru pixelii care sunt 0 -> ponderea e -100
Pentru pixelii care sunt 1 -> ponderea e 1
Functia de activare este functia treapta (0 x < 0 else 1)

Ca sa dea 1 doar daca pixelii sunt aprinsi in forma de C, punem la legatura cu 1 -6
Astfel:
-Un pixel aprins gresit -> pondere negativa
-Toti pixelii aprinsi corect, iesirea este 7 - 6 = 1
-Un pixel din cei corecti stins, iesirea este 6 - 6 = 0

12. Dati ex unde si in ce alg de invatare si cum se aplica euristica de alegere a ipotezei de invatare.

13. Descrieti structura si modul de functionare al unui LSC. (ce e aia? :)))

14. Construiti o retea perceptron care sa reprezinte functia SI logic, SAU logic, etc .

15. Asta e rezultatul cerintei (deduceti voi cerinta).

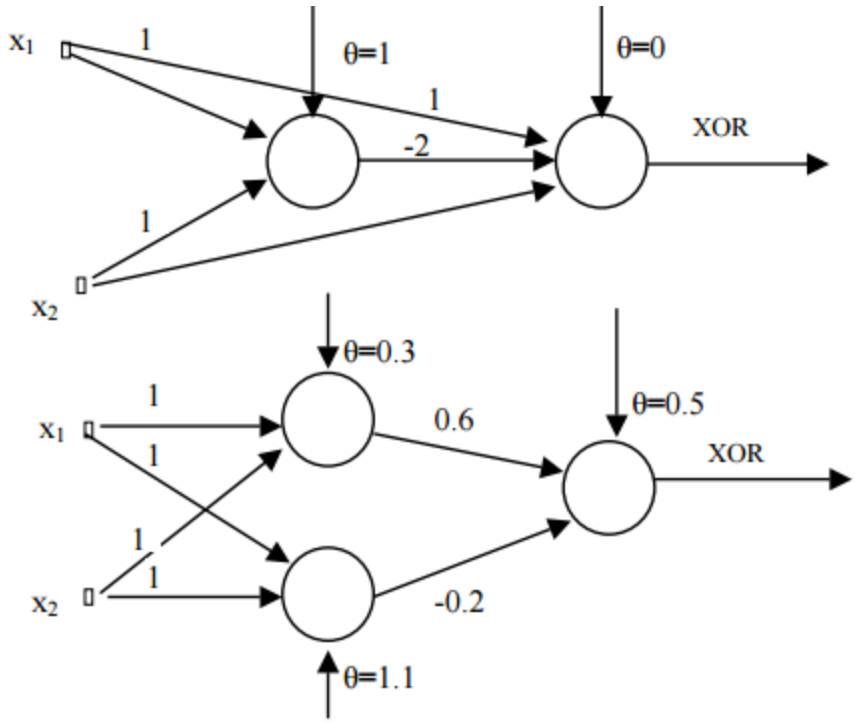
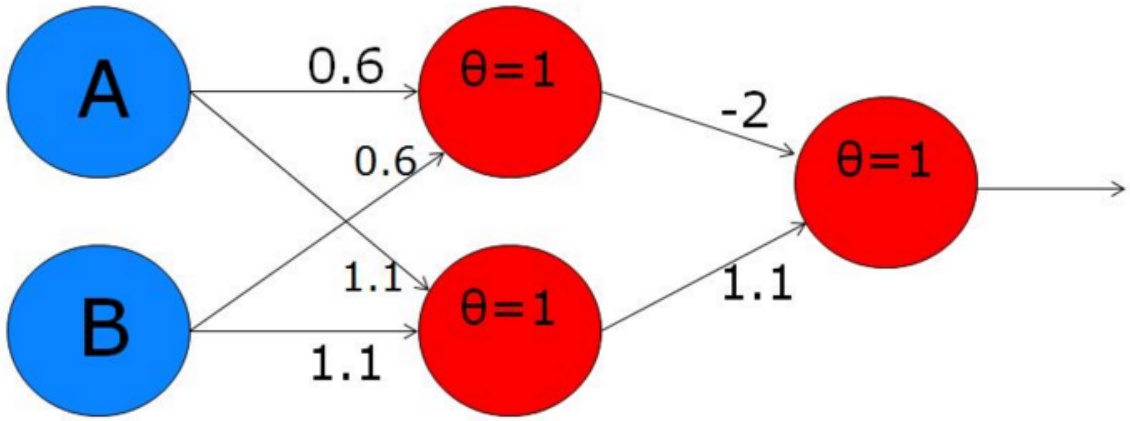
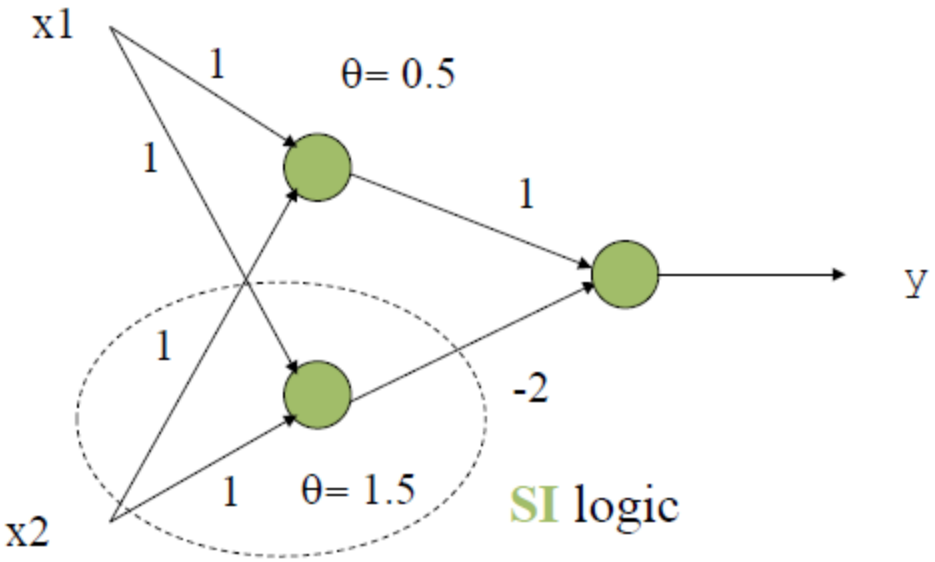


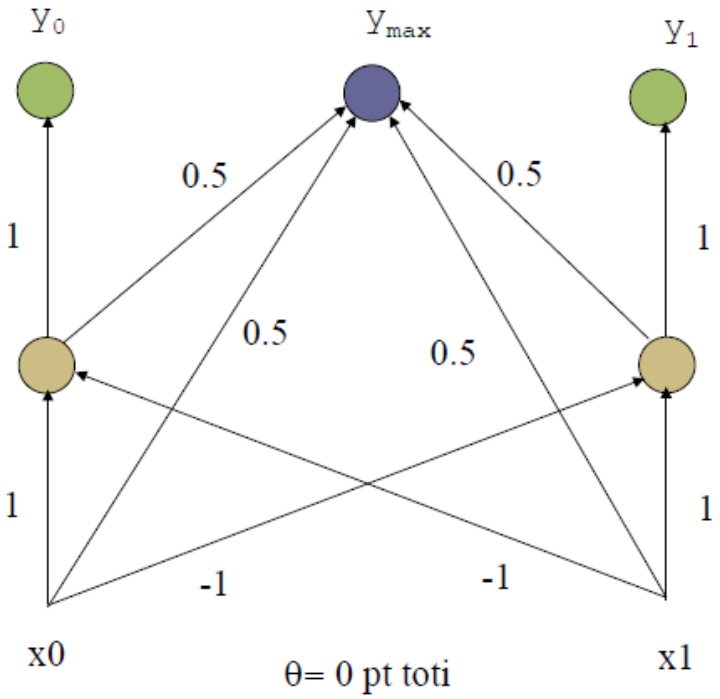
Fig.3 Două rețele pentru învățarea funcției logice XOR





Asta de Si logic e bun??? cat e teta pt stratul de iesire?
Desenul este pentru XOR. Teta pt stratul de iesire este 0.

Retea care selecteaza maximum a doua intrari reale



- $f_3(t) = t$

- f_1 functie de transfer treapta

- $f_2(t) =$ t daca $t \geq 0$
  -t daca $t < 0$

16. Sa se proiecteze o retea neurala care are la intrare un numar intre 0-20 si se activeaza la iesire pentru un numar >9 (sau cu doua iesiri, a doua iesire va avea un numar >9). Intrari, iesiri, algoritm, functie de transfer, valoare threshold.

O intrare cu ponderea 1
Threshold = -9.ceva
x - 9 > 0 cand x > 9 deci functia treapta

Nu stiu daca am inteles la partea a doua dar (ia un numar mai mare ca noua si scoate un numar mai mare ca noua) (ponderea e 1 functia de transfer e f(x) = x threshold e 0)

17. selectie ruleta, se selectau 4 părinti dintr-un eșantion de indivizi cu fitness 5,10, 15, 20.care este numarul estimat de selectii ale individului cu fitness 5?

Nr Individ	**1**	**2**	**3**	**4**
Fitness	**5**	**10**	**15**	**20**
Probabilitate	**0.1**	**0.2**	**0.3**	**0.4**

p(alegere 1) = 0.1 + 0.9 * 0.1 + 0.9^2 * 0.1 + 0.9^3 * 0.1 = 0.3439, da' asta n-are treaba cu problema

18. Pentru un algoritm genetic cu indivizi reprezentati real, care utilizeaza recombinarea discreta (discrete recombination) se dau:

individual1: 13 2 10 4
individual2: 20 40 60 50
sample1: 2 2 1 1
sample2: 1 2 1 2 (sample 1 si sample 1 generate aleator)

Sa se indice doi descendenti (offspring1 si offspring2) subiniind in fiecare descendent valorile care provin din individual1. Justificati pe scurt cum ati obtinut descendentii.

individual1: 13 2 10 4
individual2: 20 40 60 50
sample1: 2 2 1 1
sample2: 1 2 1 2

offspring 1 (pt sample1) 20 40 10 4
offspring 2 (pt sample2) 13 40 10 50

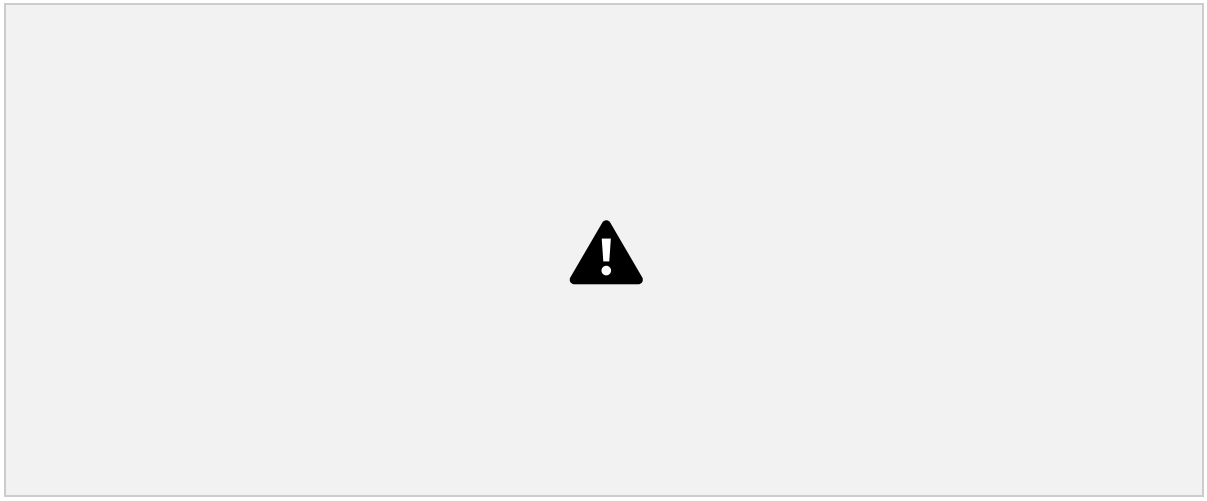
In recombinarea reala **discreta**, unde sample are 1, se ia din primul individ, unde are 2 se ia din al doilea.

19. Intr-un alg genetic se considera urmatorii 2 parinti: p1: 128 255 50 17 2 si p2: 123 4 344 280 12. Construiti cei 2 copii obtinuti prin recombinare reala discreta avand sample1: 2 2 1 1 2 si sample 2: 1 2 1 1 2. Justificati pe scurt cum ati obtinut descendentii.

p1:	128	255	50	17	2
p2:	123	4	344	280	12
sample1:	2	2	1	1	2
sample2:	1	2	1	1	2

offspring1: 123 4 50 17 12
offspring2: 128 4 50 17 12

In recombinarea reala **discreta**, unde sample are 1, se ia din primul individ, unde are 2 se ia din al doilea.



2Examen MeLeu :))

Suntem toti BO$$I

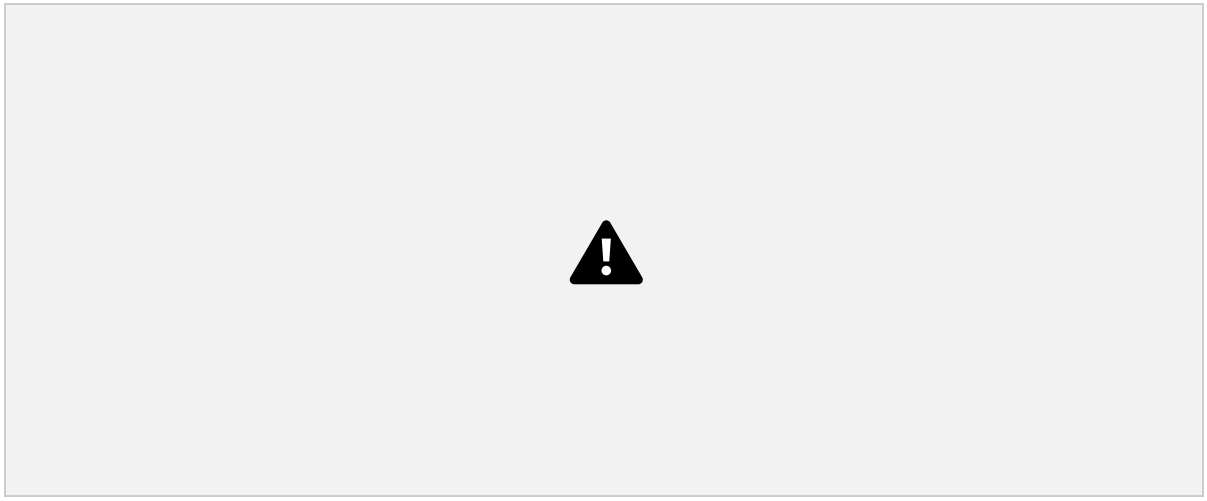
Scris:

PARTEA II

Multumim echipa ! gg

Vezi si:

https://docs.google.com/document/d/1xZjh8t6MCFfluHtmHGcYtZ03863zrw_ZkHnGDsY7b74/edit



Un algoritm genetic folosește cromozomi de forma *x = abcdefgh*, cu o lungime fixa de 8 gene (de la a la h).

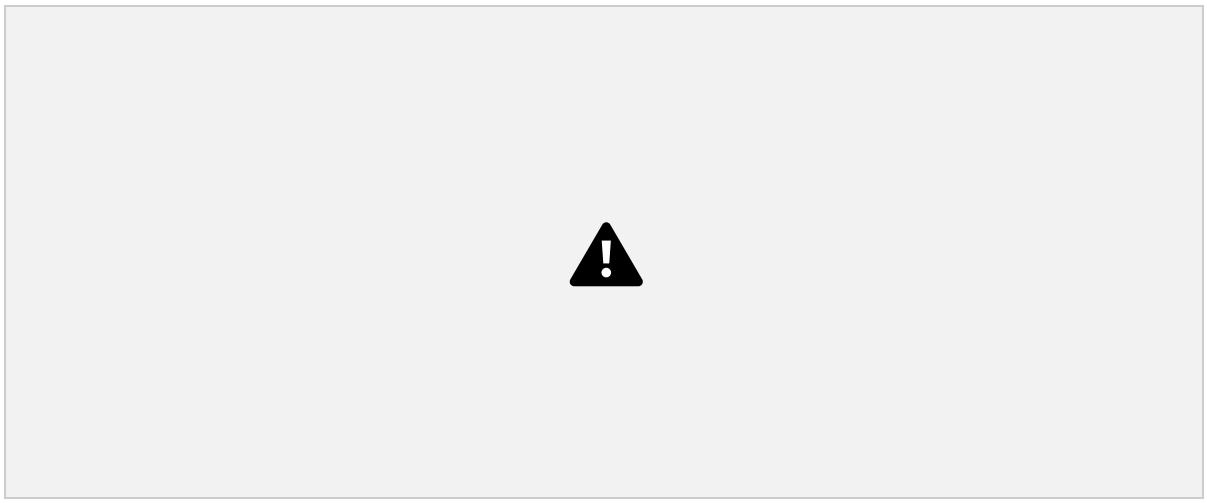
Fiecare genă constă într-un număr din intervalul [0 .. 9]. Funcția de fitness a unui individ x se calculează prin

f(x) = (a+b) - (c+d) + (e+f) - (g+h).

Fie populația de invidizi dată prin:

- O1: 8 7 1 2 3 5 3 2
- O2: 6 5 9 2 1 2 3 2
- O3: 2 7 1 2 6 2 0 1
- O4: 5 8 3 4 3 9 4 2

Incrucișați primii doi indivizi în ordinea fitness-ului prin crossover single point (recombinare binară cu punct de recombinare la 50% din lungimea cromozomului). Scrieți indivizii rezultanți (Onew1 și Onew2) sub forma indicată în populație (e.g. Onew1: a b c d e f g h).	Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2
Care este fitness-ul populației noi formate din (Onew1, Onew2, Onew3 și Onew4)? Este el mai mare decât fitness-ul populației anterioare?	f(new_pop)=55, DA
Încrucișați indivizii O1 și O4 prin 2-point crossover, cu tăiere după genele b și f. Scrieți indivizii rezultanți (Onew3 și Onew4) sub forma indicată în populație.	Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 2
Care este individul cu fitness maximal si care este aceasta? Specificati raspunsul sub forma <nume_individ>:<valoare fitness>.	O1:15
Care este valoarea maximală de fitness care poate fi atinsă de un individ prin funcția *f*?	36



1. Fie un set de 8 indivizi avand următoarele valori de fitness asociate

#Ind	1	2	3	4	5	6	7	8
Fit.	17	5	13	15	12	8	6	24

Cei 4 indivizi alesi conform unei proceduri de *selectie pe baza de ruleta* cu extragerile aleatoare (0.1, 0.7, 0.5, 0.3) sunt:

Răspunsul

Alege..

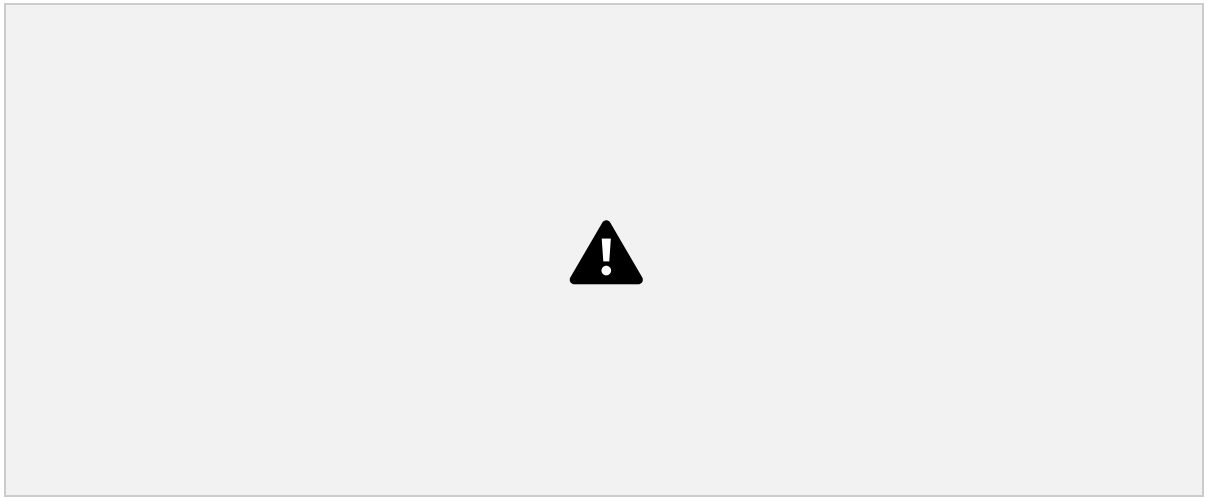
4,5,6,8

1,3,4,8

1,3,6,8

1,3,5,8

1,4,5,8

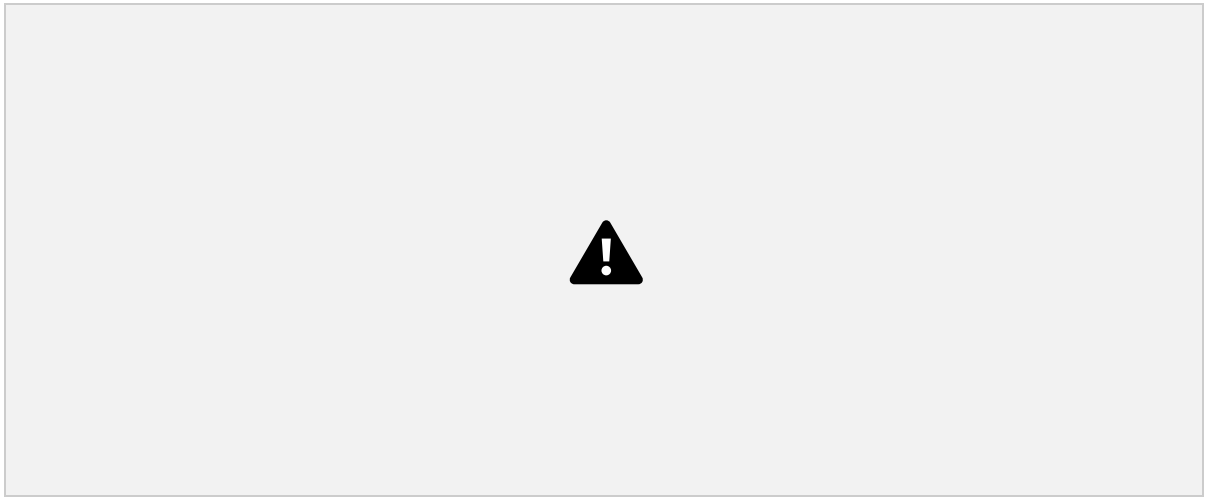


Cei 4 indivizi alesi conform unei proceduri de *selectie universala stohastica* (unde primul pointer are valoarea 0.1) sunt: 1,3,6,8

3. Se dă următoarea arhitectură a unei rețele convoluționale:

Input(64 x 64 x 3) -> Conv1(c=8, k=5, p=0, s=1) -> ReLU1 -> Conv2(c=16, k=3, p=1, s=1) -> Pool2(k=2, s=2) -> ReLU2 -> Conv3(c=32, k=3, p=0, s=1) -> ReLU3 -> Output,

unde c - numar de canale, k - dimensiune kernel, p = padding, s = stride, iar inputul este dat in formatul H x W x C (height, width, channels).



Care este numărul total de ponderi aferente stratului convolutional Conv2

Răspunsul

Alege...72 (28, 28, 16)57600(32, 32, 32)(28, 28, 32)(30, 30, 32)144 1152 144

Care este dimensiunea pentru outputul final, exprimata in format (H, W, C)

Răspunsul

Alege...72 (28, 28, 16)57600(32, 32, 32)(28, 28, 32)(30, 30, 32)144 1152 (28, 28, 32)

5. Se dă următoarea problemă de clasificare binară.



Se presupune cunoscut faptul că un clasificator liniar (e.g. regresie logistică, SVM cu kernel liniar), *NU poate* clasifica în mod corect setul de antrenare reprezentat mai sus.

Considerați o rețea neurală de tip feed-forward configurată în modul următor:

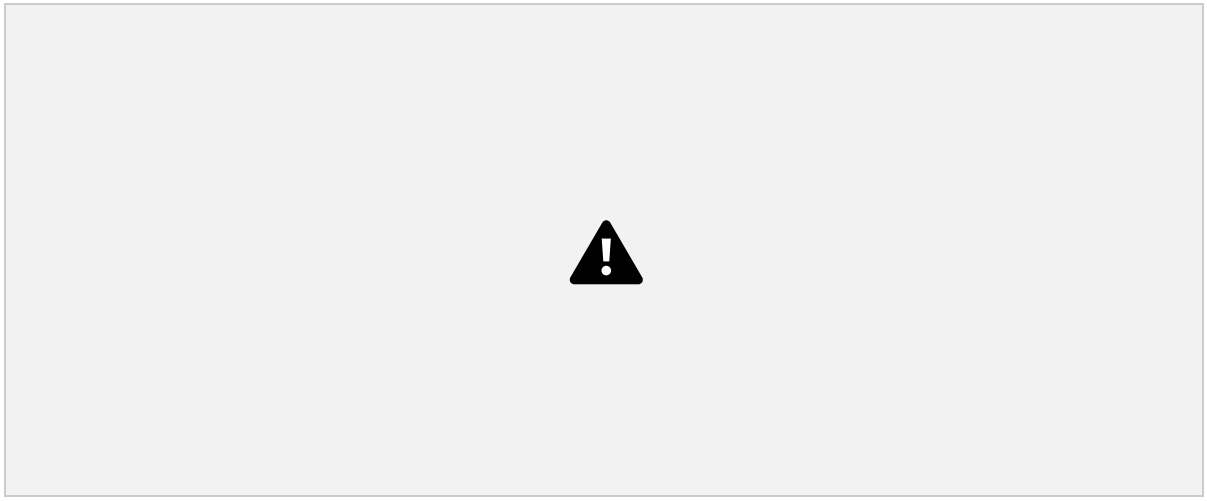
- Input -> [strat liniar] -> activare liniara -> [strat liniar] -> activare liniara -> [strat liniar] -> activare logistică -> Output

Este această configurație de rețea capabilă să învețe o clasificare 100% corectă a problemei date? Justificați.

Nu, pentru a rezolva problema este nevoie de un clasificator non-liniar care sa separe corecte datele de intrarea.

6. Se da următoarea reprezentare a valorilor Q pentru fiecare din acțiunile *A = {sus, jos, stânga, dreapta}*, asociate unei stări marcate prin simbolul ♦ în tabelul de mai jos.

Care va fi distribuția peste setul de acțiuni A atunci când agentul folosește metoda ε-greedy (cu ε = 0.1), și atunci când folosește o metodă de explorare ponderata (unde convertirea la probabilități se face prin operație de mediere ponderata a valorilor Q)?



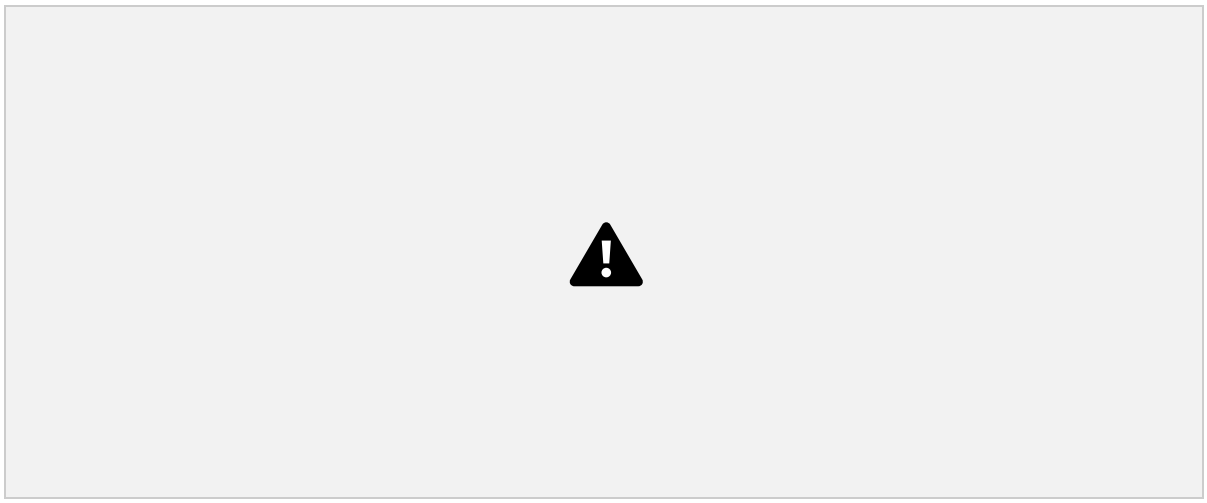
Exprimați răspunsul ca tuplu de patru valori în ordinea (sus, jos, stanga, dreapta), cu precizie la a treia zecimală, prin rotunjire in jos.

13.4

2.4 ♦ 2.4

12.1 ε-greedy = (sus: 0.925, jos: 0.025, stanga: 0.025, dreapta: 0.025)

explorare-ponderata = (sus: 0.442 jos: 0.399, stanga: 0.079, dreapta:



0.079)
(cred!!!)

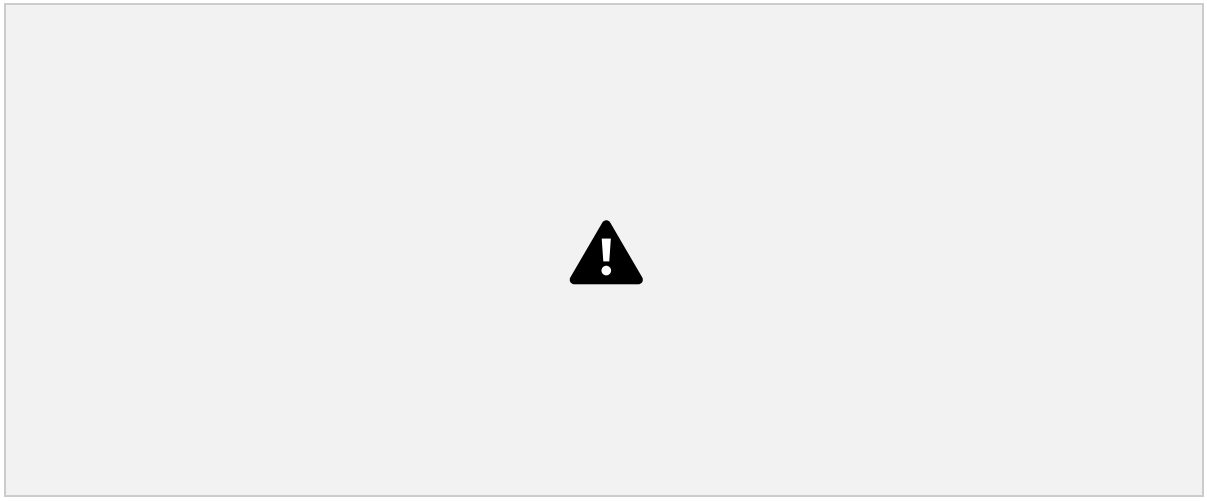
Cum calculezi?

Suma ponderilor si procentul fiecari ponderi la suma

7. Un algoritm genetic folosește cromozomi de forma *x = abcdefgh*, cu o lungime fixă de 8 gene (de la a la h).

Fiecare genă constă într-un număr din intervalul [0 .. 9]. Funcţia de fitness a unui individ x se calculează prin

f(x) = (a+b) - (c+d) + (e+f) - (g+h).



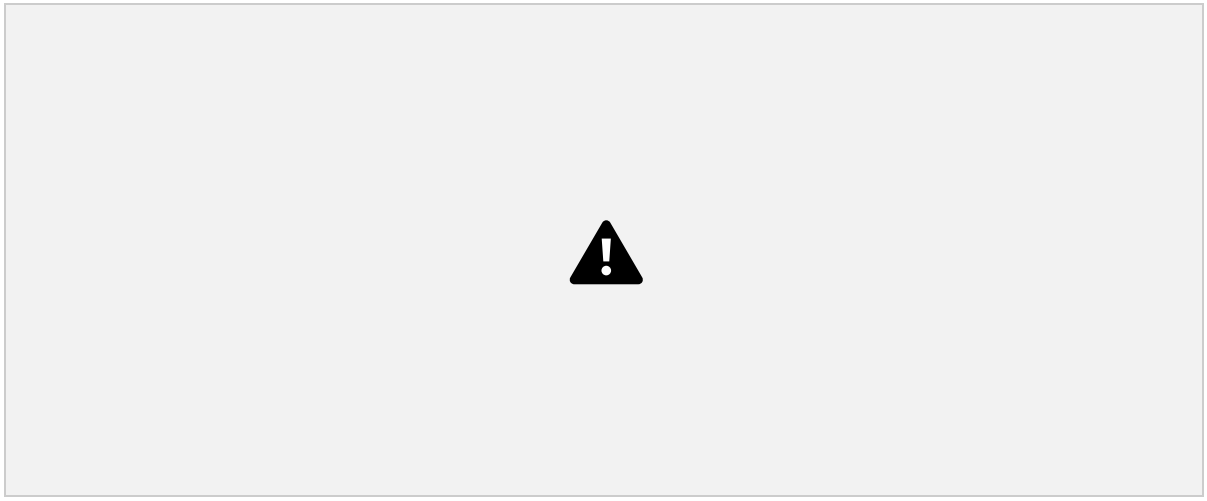
Fie populația de invidizi dată prin:

- O1: 8 7 1 2 3 5 3 2
- O2: 6 5 9 2 1 2 3 2
- O3: 2 7 1 2 6 2 0 1
- O4: 5 8 3 4 3 9 4 2

Care este valoarea maximală de fitness care poate fi atinsă de un individ prin funcția *f*?

Răspunsul

Onew3: 8 7 3 4 3 5 4 2, Onew4: 5 8 1 2 3 9 3 2Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 218Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2Onew3: 8 8 1 4 3 9 3 2, Onew4: 5 7 3 2 3 5 4 2270 4:13O3:12f(new_pop)=38, NUf(new_pop)=47, NU36Onew1: 2 7 1 2 3 9 4 2, Onew2: 5 8 3 4 6 2 0 1Onew1: 8 7 1 2 3 9 4 2, Onew2: 5 8 3 4 3 5 3 2O1:15f(new_pop)=55, DA



Încrucișați primii doi indivizi în ordinea fitness-ului prin crossover single point (recombinare binară cu punct de recombinare la 50% din lungimea cromozomului). Scrieți indivizii rezultanți (Onew1 și Onew2) sub forma indicată în populație (e.g. Onew1: a b c d e f g h).

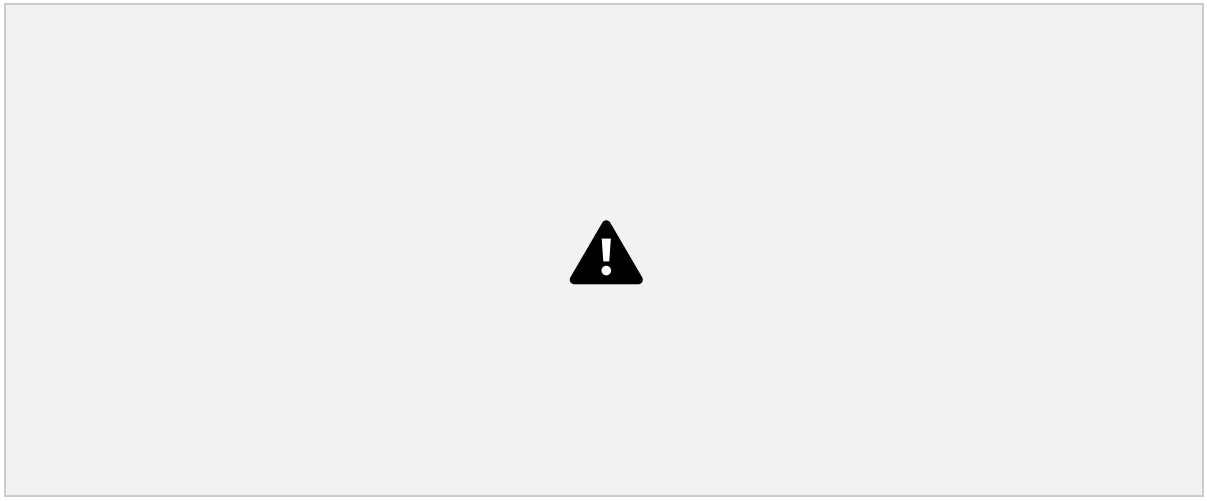
Răspunsul

Alege...Onew3: 8 7 3 4 3 5 4 2, Onew4: 5 8 1 2 3 9 3 2Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 218Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2Onew3: 8 8 1 4 3 9 3 2, Onew4: 5 7 3 2 3 5 4 2270 4:13 0 3:12f(new_pop)=38, NUf(new_pop)=47, NU36Onew1: 2 7 1 2 3 9 4 2, Onew2: 5 8 3 4 6 2 0 1Onew1: 8 7 1 2 3 9 4 2, Onew2: 5 8 3 4 3 5 3 2 0 1:15f(new_pop)=55, DA

Care este fitness-ul populației noi formate din (Onew1, Onew2, Onew3 și Onew4)? Este el mai mare decât fitness-ul populației anterioare?

Răspunsul

Alege...Onew3: 8 7 3 4 3 5 4 2, Onew4: 5 8 1 2 3 9 3 2Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 218Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2Onew3: 8 8 1 4 3 9 3 2, Onew4: 5 7 3 2 3 5 4 2270 4:13 0 3:12f(new_pop)=38, NUf(new_pop)=47, NU36Onew1: 2 7 1 2 3 9 4 2, Onew2: 5 8 3 4 6 2 0 1Onew1: 8 7 1 2 3 9 4 2, Onew2: 5 8 3 4 3 5 3 2 0 1:15f(new_pop)=55, DA



Care este individul cu fitness maximal si care este aceasta? Specificati raspunsul sub forma <nume_individ>:<valoare fitness>.

Răspunsul

Alege...Onew3: 8 7 3 4 3 5 4 2, Onew4: 5 8 1 2 3 9 3 2Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 218Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2Onew3: 8 8 1 4 3 9 3 2, Onew4: 5 7 3 2 3 5 4 2270 4:13 0 3:12f(new_pop)=38, NUf(new_pop)=47, NU36Onew1: 2 7 1 2 3 9 4 2, Onew2: 5 8 3 4 6 2 0 1Onew1: 8 7 1 2 3 9 4 2, Onew2: 5 8 3 4 3 5 3 2 0 1:15f(new_pop)=55, DA

Încrucișați indivizii O1 și O4 prin 2-point crossover, cu tăiere după genele b și f.

Scrieți indivizii rezultanți (Onew3 și Onew4) sub forma indicată în populație.

Răspunsul

Alege...Onew3: 8 7 3 4 3 5 4 2, Onew4: 5 8 1 2 3 9 3 2Onew3: 8 7 3 4 3 9 3 2, Onew4: 5 8 1 2 3 5 4 218Onew1: 8 7 1 2 6 2 0 1, Onew2: 2 7 1 2 3 5 3 2Onew3: 8 8 1 4 3 9 3 2, Onew4: 5 7 3 2 3 5 4 2270 4:13 0 3:12f(new_pop)=38, NUf(new_pop)=47, NU36Onew1: 2 7 1 2 3 9 4 2, Onew2: 5 8 3 4 6 2 0 1Onew1: 8 7 1 2 3 9 4 2, Onew2: 5 8 3 4 3 5 3 2 0 1:15f(new_pop)=55, DA



Se considera stările (s_1, s_2, s_3, s_4); în fiecare stare poate fi executată una din acțiunile (a_1, a_2, a_3). După aplicarea algoritmului Q-learning, pentru un număr de episoade, se obțin următoarele valorile Q(stare, acțiune):

	$s = s_1$	$s = s_2$	$s = s_3$	$s = s_4$
$a = a_1$	0.1	0.2	0.3	0.4
$a = a_2$	0.5	0.6	0.7	0.8
$a = a_3$	0.9	1.0	1.1	1.2

In continuare, agentul porneste din starea s_3 si executa acțiunea a_1. El va primi recompensa 1 și va trece în starea s_2. În aceasta stare el va alege sa execute acțiunea a_2, prin care va ajunge în starea s_4, iar recompensa primită va fi 0. Calculati modificările pentru Q(stare, actiune) prin executarea acestor acțiuni (α = 0.2, δ = 0.9).

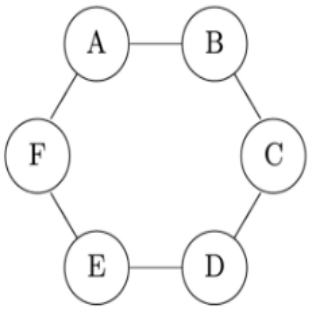
Q(a1, s3) = Q(a1, s3) + alpha * (R(s2) + delta * maxa'Q(a', s2) - Q(a1, s3)); a' = a2

Q(a2, s2) = Q(a2, s2) + alpha * (R(s4) + delta * maxa'Q(a', s4) - Q(a2, s2)); a' = a2

Q(a1, s3) = 0.3 + 0.2* (1 + 0.9 * 0.6 - 0.3) = 0.548

Q(a2, s2) = 0.6 + 0.2 * (0 + 0.9 * 0.8 - 0.6) = 0.624

Pentru următoarea rețea SOM cu 6 noduri (A-F) și 2 intrări (x_1, x_2 - intrările nu sunt specificate în figura), ponderile asociate fiecărui nod sunt w_1 și w_2. Se considera valoarea (2, -4) aplicată pe intrări. Se utilizează distanța euclidiana, specificati care sunt nodurile pentru care se vor actualiza ponderile (se considera o vecinătate cu raza = 1).



Node	A	B	C	D	E	F
w_1	-1	0	3	-2	3	4
w_2	2	4	-2	-3	2	-1

D(A) = (-1 - 2)^2 + (2 + 4)^2 = 9 + 36 = 45

D(B) = (0 - 2)^2 + (4 + 4)^2 = 4 + 64 = 68

D(C) = (3 - 2)^2 + (-2 + 4)^2 = 1 + 4 = 5 <- cel mai apropiat punct

D(D) = (-2 - 2)^2 + (-3 + 4)^2 = 16 + 1 = 17

D(E) = (3 - 2)^2 + (2 + 4)^2 = 1 + 36 = 37

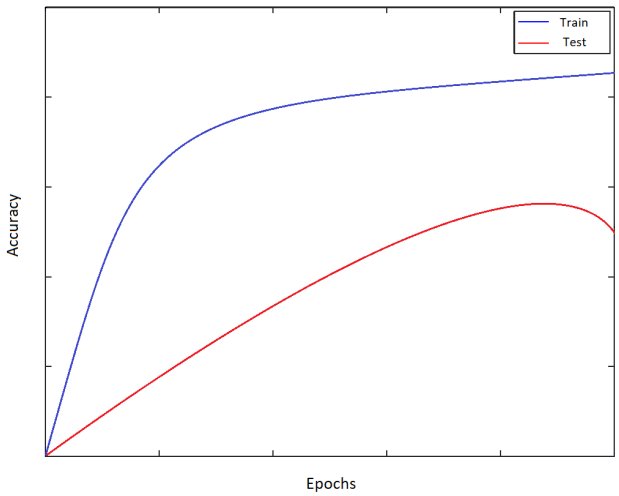
D(F) = (4 - 2)^2 + (-1 + 4)^2 = 4 + 9 = 13

R = 1 => Se actualizeaza nodurile **C, B, D**

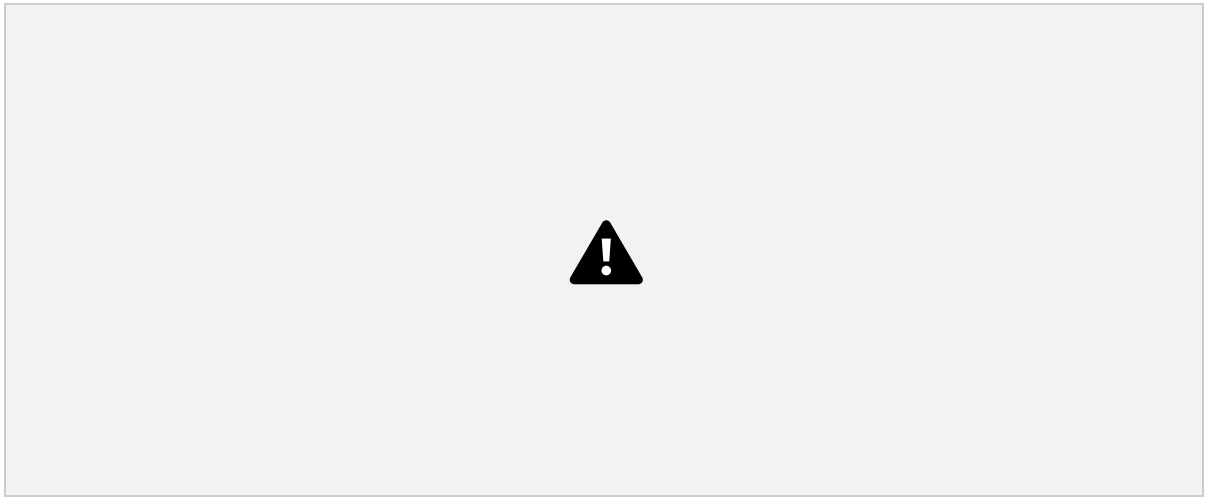
PARTEA I
Grila

f

Cum interpretați figura de mai jos?



Alegeți o opțiune:



a. Rețeaua nu învață nicio caracteristică a datelor

b. Rețeaua are arhitectura potrivită pentru setul de date pe care este antrenată

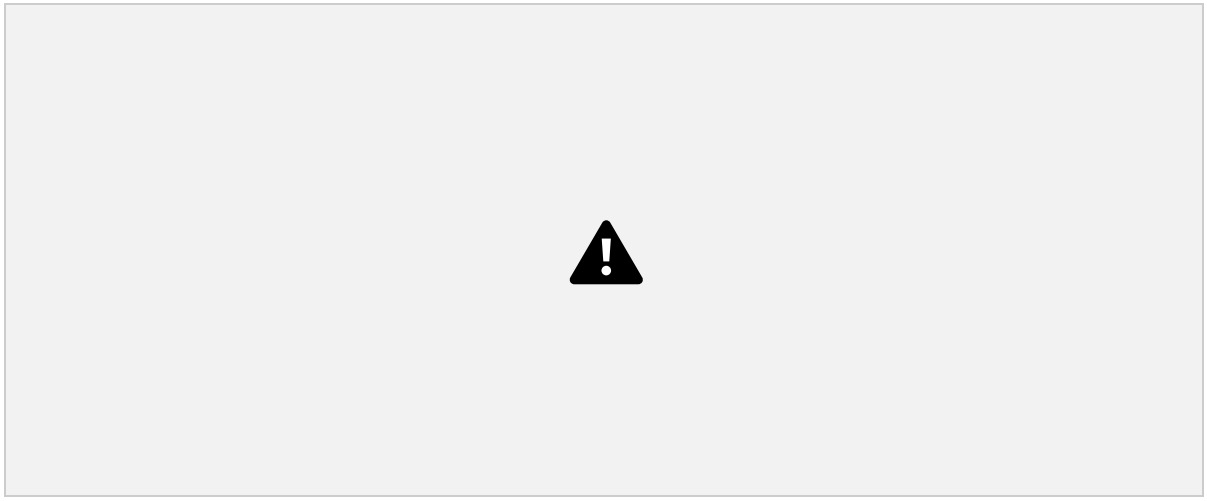
c. Rețeaua intră în regim de overfit

Câți parametri sunt într-o rețea care respectă structura de mai jos, antrenată pe setul de date Q(a1, s3) = 0,3 + 0,2 * (1 + 0,9 * 1 - 0,3) = 0,62 (din formula de la Q learning)

Q(a2, s2) = 0,6 + 0,2 * (0 + 0,9 * 1,2 - 0,6) = 0,696T (28x28x1):

Câți parametri sunt într-o rețea care respectă structura de mai jos, antrenată pe setul de date MNIST (28x28x1):

L0: Input
L1: Conv1(c=5, k=5, p=2, s=1)
L2: MaxPool(k=2, s=2)
L3: Conv2(c=5, k=3, p=1, s=1)
L4: AvgPool(k=2, s=2)
L5: ReLU



L6: Output

Alegeți o opțiune:

a. 12

b. 245

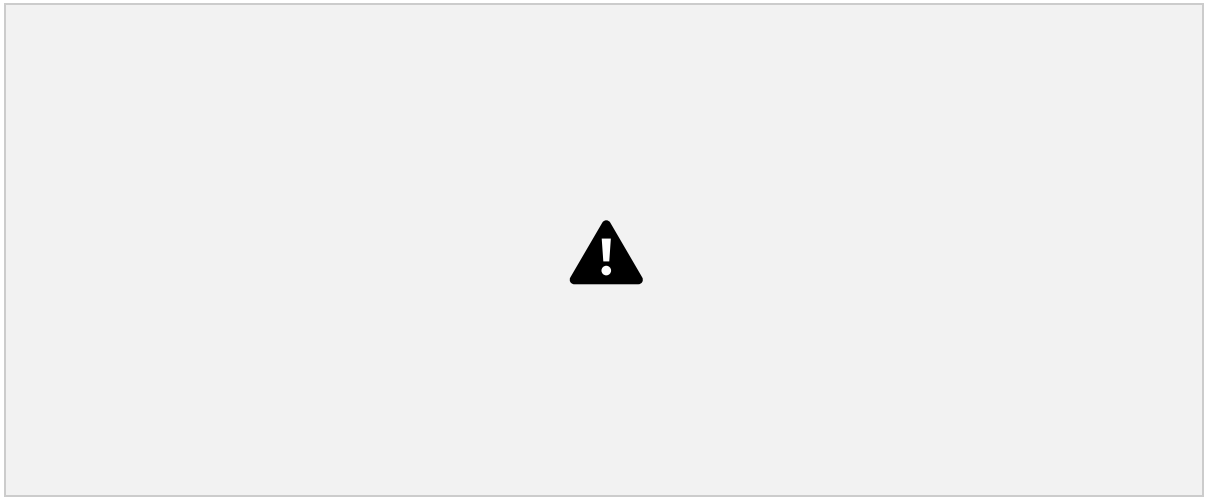
c. 350(5x5x1x5 + 3x3x5x5 ?)

d. 170

Care dintre următoarele procedee au ca efect reducerea variabilității valorilor de actualizare a ponderilor (Δw) în timpul procesului de stochastic gradient descent (SGD)?

1. **Reducerea dimensiunii batch-urilor**
2. **Reducerea ratei de învățare**
3. **Creșterea dimensiunii batch-urilor**
4. **Creșterea ratei de învățare**

Alegeți o opțiune:



a. 1 si 4

b. 2

c. 3 si 4

d. 4

e. 2 si 3 (cred + 1) (+1)

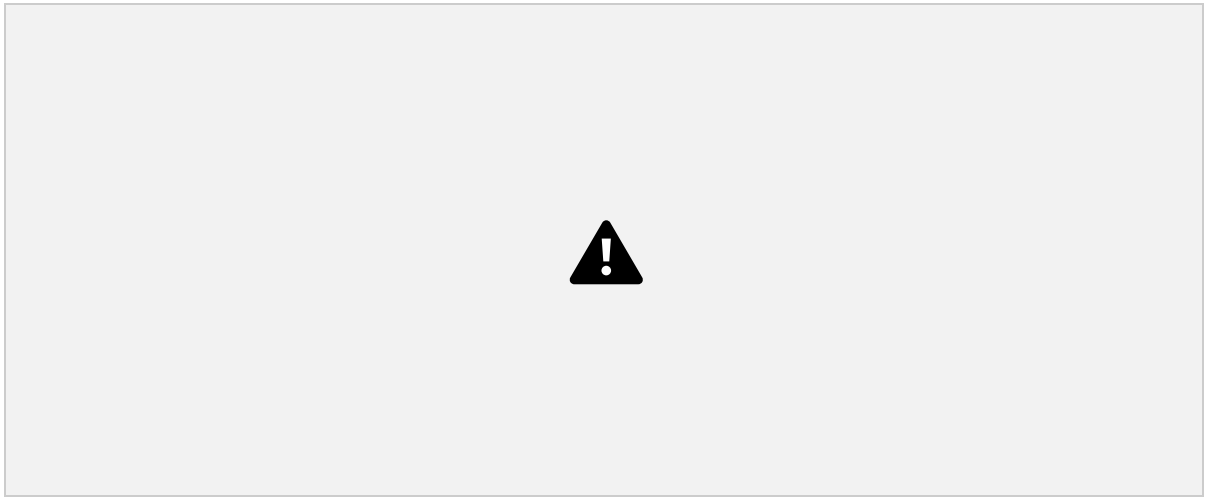
f. 1

g. 1 si 2

h. 3

2.Considerăm situația în care se antrenează un model folosind gradient descent. La un moment dat derivata funcției de cost ajunge să fie 0, însa nu avem nicio informație despre funcția de cost. Ce se poate spune cu siguranță?

Alegeți o opțiune:
a. A fost găsit un maxim global.
b. Funcția a ajuns într-un minim sau maxim global.
c. A fost găsit un minim local. (+1)(+1)(+1)(-1 poate sa fie si maxim local, are dreptate)
d. Nici o afirmație nu este adevărată. (+1 +1 gradientu poate fi 0 la minime, maxime, la platouri. Se intreaba ce se poate spune cu siguranta, ceea ce e nimic.)



3.Straturile de tip Average Pool sunt utilizate în arhitecturile de rețele neuronale artificiale adânci cu scopul de a

Alegeți o opțiune:reduc

a. Reduce zgomotul din rețea prin efectuarea mediei activărilor

b. Reduce dimensiunea activărilor de la ieșirea unui strat înainte de a fi trimis stratului următor - asta cred(+1)(+1)(+1)

c. Îmbunătăți calitatea informației care este propagată prin rețea.

d. Întări corelațiile care se întâmplă la nivel local.

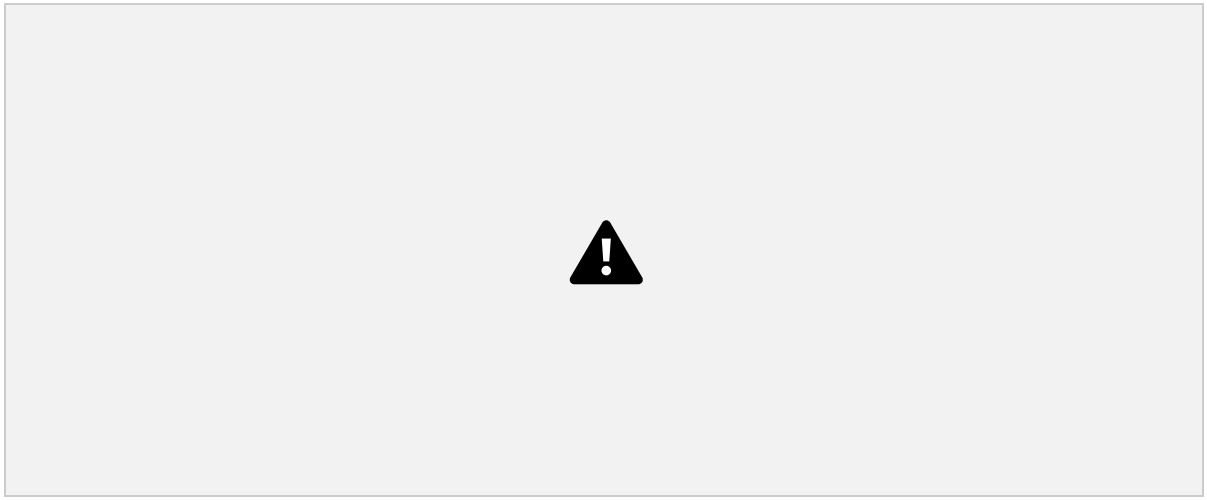
Fie un strat de convolutie cu intrarea de dimensiune (7x7), filtru de dimensiune (3x3), stride = 1 (se ingnora a treia dimensiune, nu exista padding). Specificati dimensiunea iesirii stratului convolutional.

Alegeți o opțiune:

a. 7x7

b. 3x3

c. 5x5



MSE (Mean Squared Error)Care dintre următoarele funcții de eroare ați utiliza pentru o rețea pe care o antrenați într-o problemă de regresie?

Alegeți o opțiune:

a. Negative Log Likelihood

b. Binary Cross-Entropy

c. Multi-Class Cross-Entropy

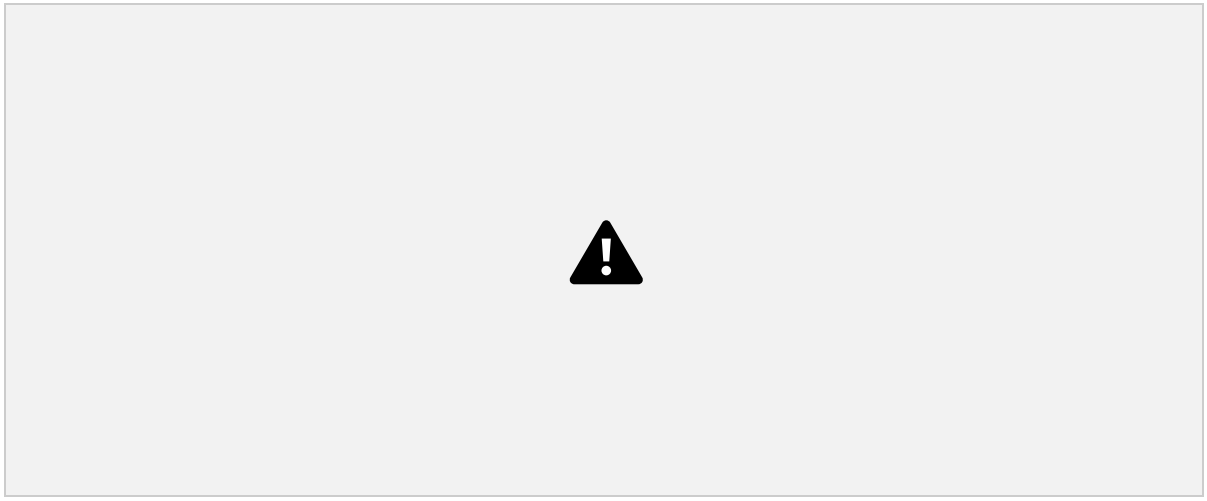
d. MSE (Mean Squared Error)

Câți parametrii trebuie să învețe un layer de Average Polling cu dimensiunea kernel-ului de 2 și pas de 2?

Alegeți o opțiune:

a. 4

b. 2



c. 0

d. 3

7.Care din următoarele stringuri nu este un rezultat posibil care se poate obține pentru individul ”1934523107” după o operație de crossover, cu crossover point la 70% din lungimea individului?

Alegeți o opțiune:

a. 1934523107

b. 1934523813

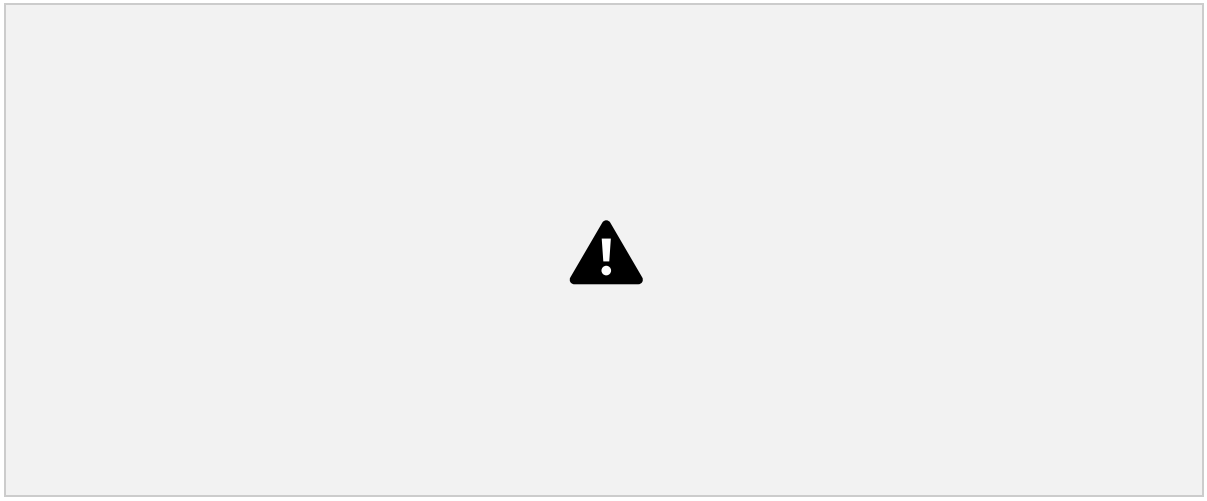
c. 1034523207

d. 1984528107

8.
Cum se reprezintă o politică?

Alegeți o opțiune:

a. O funcție care asociază valori (utilități) pentru fiecare pereche (stare, acțiune)



b. O funcție pentru asocieri stare - acțiune (https://stackoverflow.com/questions/46260775/what-is-a-policy-in-reinforcement-learning)

c. O listă cu acțiuni

d. O funcție pentru asocieri stare - utilitate

9.

În care din următoarele cazuri nu ați opta pentru utilizarea unui algoritm genetic:

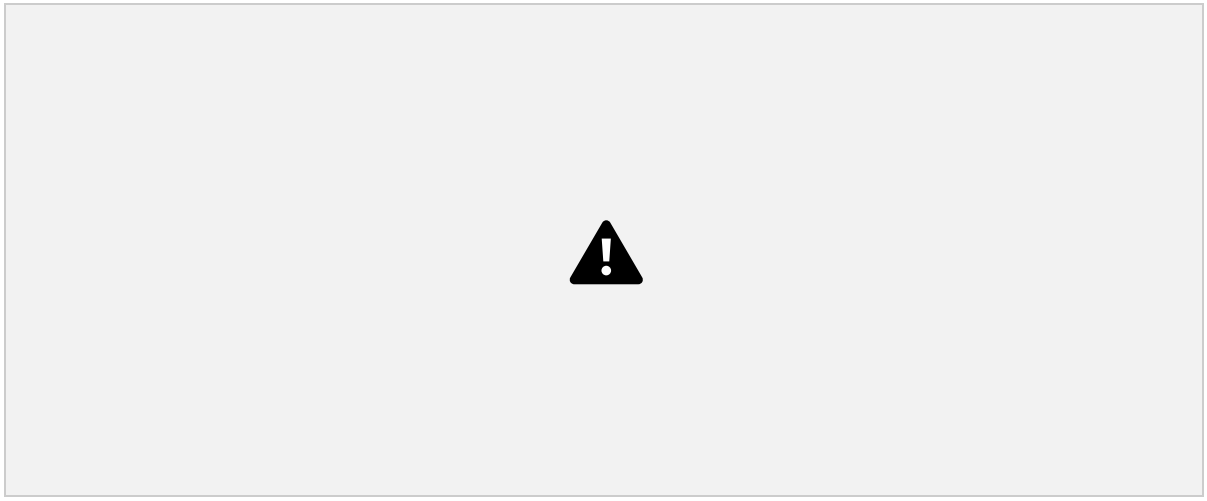
Alegeți o opțiune:

a. Problema conține atât variabile continue cât și discrete

b. Problema are puține variabile care trebuie optimizate

c. Nu există o soluție exactă pentru problemă (nu cred ca e asta pt ca AG se folosesc pentru optimizare masiva)

d. În care din următoarele cazuri nu ați opta pentru utilizarea unui algoritm genetic ??? ignorati



În algoritmul Q-Learning, care este efectul unei rate de învățare (learning rate) scăzute și a unui factor de atenuare (discount factor) ridicat:

Alegeți o opțiune:

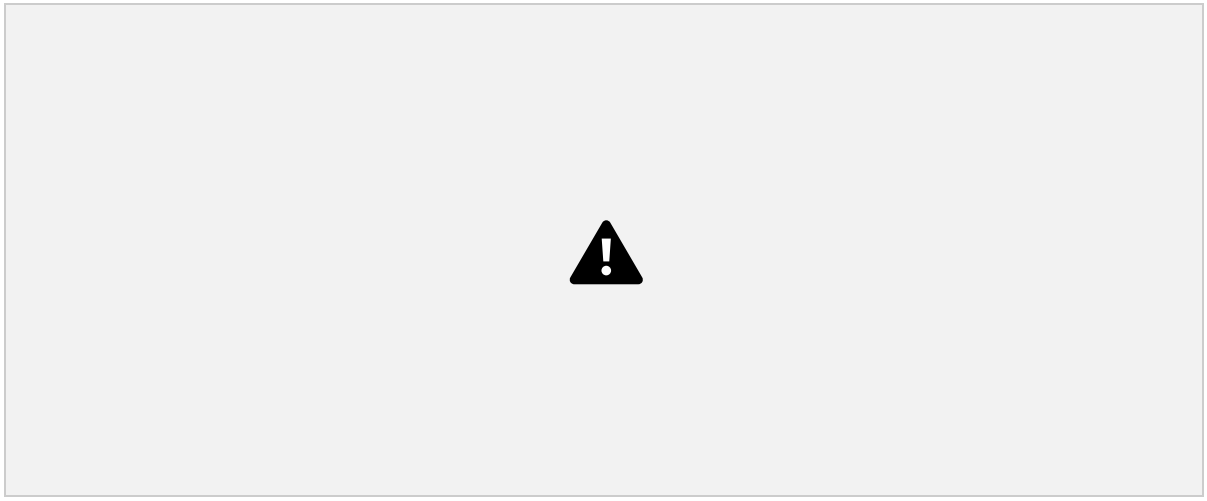
a. Agentul prețuieste mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

b. Agentul prețuieste mai mult recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv

c. Agentul prețuieste mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai conservator

d. Agentul prețuieste mai puțin recompensele viitoare și își actualizează utilitățile estimate în mod mai progresiv

Se considera o rețea neuronala cu doua iesiri care realizeaza o clasificare binara. Care dintre următoarele funcții de activare este recomandat a fi utilizata pentru stratul de ieșire.



Alegeți o opțiune:

a. Sigmoid (https://stats.stackexchange.com/questions/207049/neural-network-for-binary-classification-use-1-or-2-output-neurons)

b. Leaky ReLU

c. ReLU

Nu e sigmoid? Parca a zis ceva la curs.

Si eu tot asa imi amintesc (sigmoid)

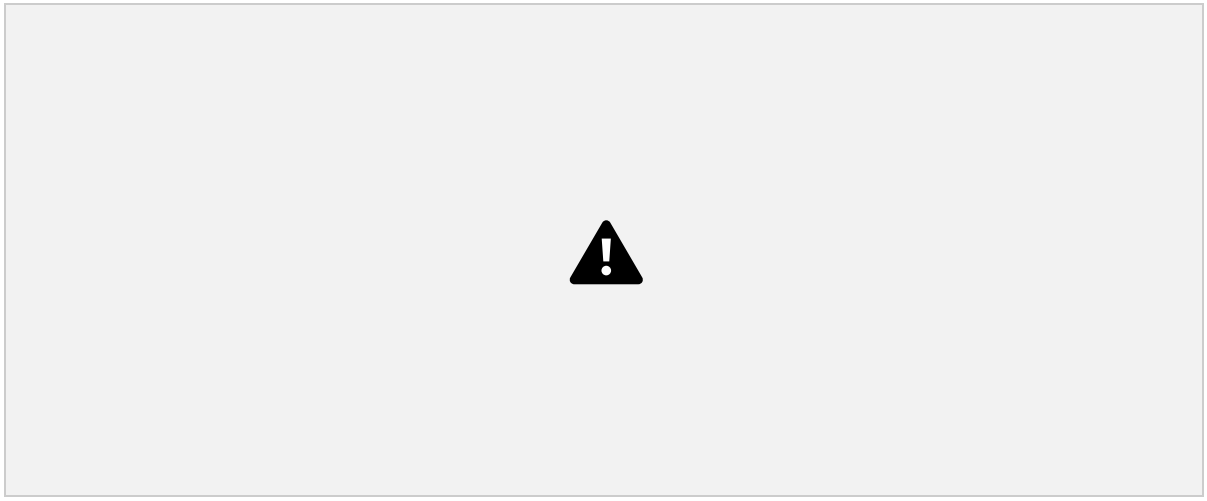
Q-Learning este o instanță a TD(0).

Select one:

True

False (asta cred ca e, aceeasi abordare nu inseamna ca e o instanta)

Policy control in TD(0) has two implementations: *SARSA* and *Q-Learning*.



https://towardsdatascience.com/td-in-reinforcement-learning-the-easy-way-f92ecfa9f3ce

În cazul unui algoritm genetic cu o populație formată dintr-un singur individ, se pot obține indivizi noi în populatie folosind:

Alegeți o opțiune:
a. Recombinare urmată de mutație

b. Numai recombinare

Cum se reprezintă o politică?

Alegeți o opțiune:

a. O funcție care asociază valori (utilități) pentru fiecare pereche (stare, acțiune)

b. O funcție pentru asocieri stare - acțiune

c. O listă cu acțiuni

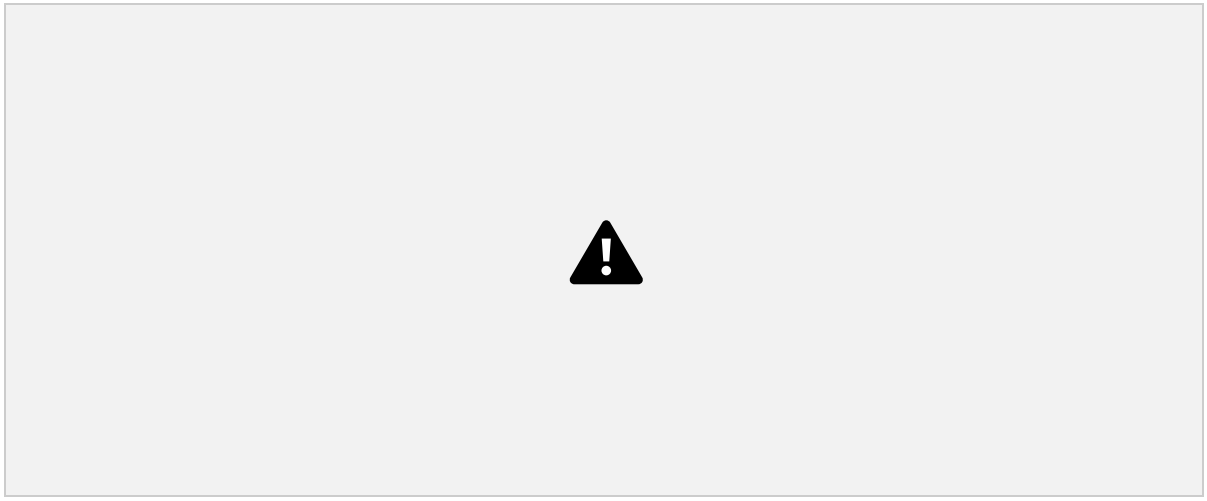
d. O funcție pentru asocieri stare - utilitate

Politica agentului

- $\pi: S \rightarrow A$

Agentul trebuie sa gaseasca, prin experiente repetate, o politica π = functie care pune in corespondenta stari cu actiuni (ASTA E DIN CURS)

Alegeți valoarea de adevăr pentru fiecare dintre următoarele propoziții:



i) Algoritmul Q-learning este de tipul on-policy

ii) Procesele de decizie Markov cu valori mici ale factorilor de atenuare accentuează recompensele pe termen scurt

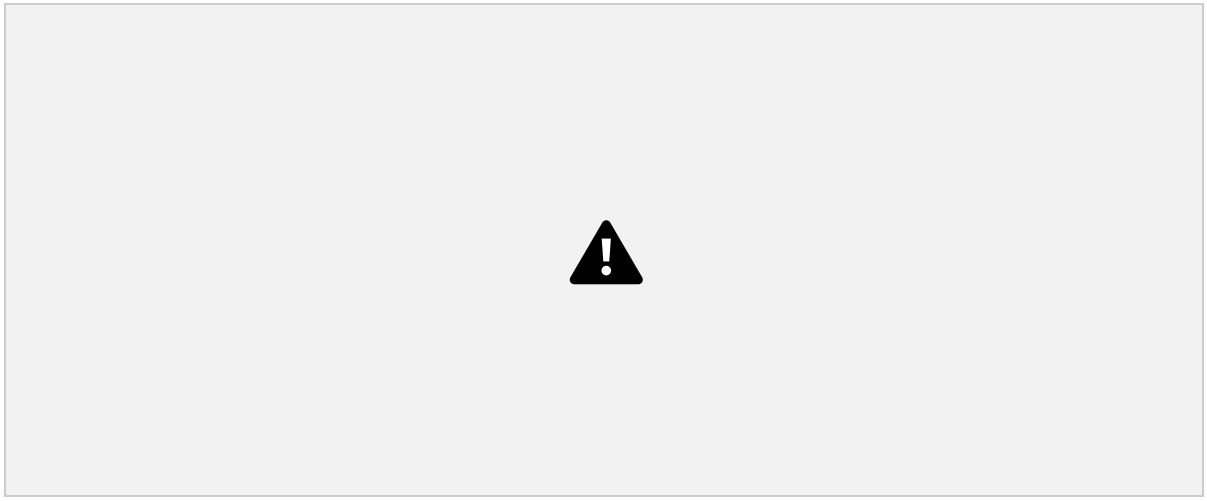
Alegeți o opțiune:

a. Fals, adevărat <- ? -- dc adevarat? Eu zic ca asta e (https://medium.com/@zsalloum/basics-of-reinforcement-learning-the-easy-way-fb3a0a44f30e)

b. Fals, fals

c. Adevărat, fals

d. Adevărat, adevărat



Care dintre următoarele metode ajută la reducerea procesului de “overfitting”?

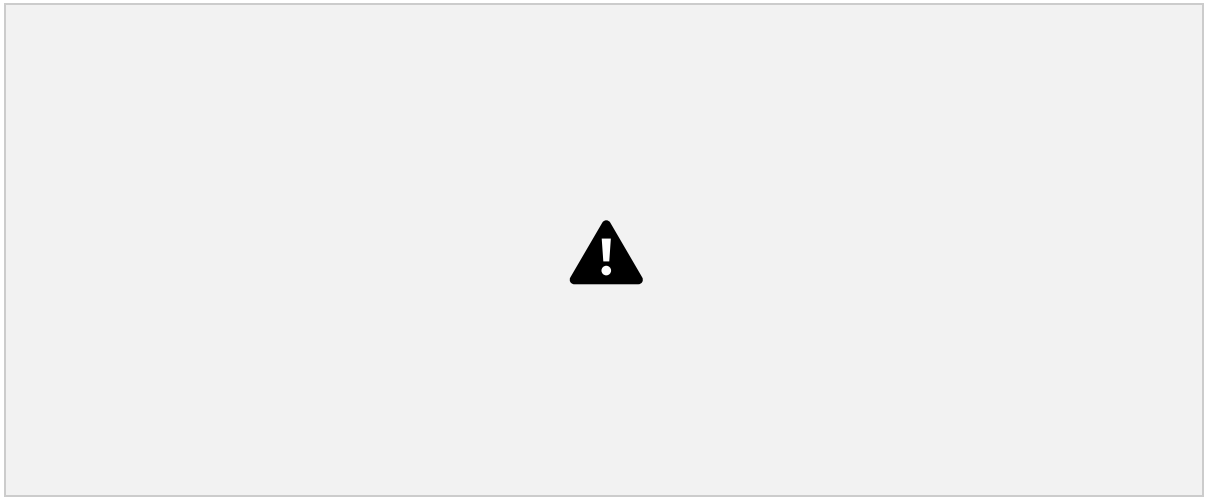
Alegeți o opțiune:

a. Utilizăm metode de regularizare. <- ?(cred) + 1

b. Folosim un model cu mai mulți parametri.

c. Utilizăm un set *aleator* (redus) de feature-uri din setul de antrenare.

d. Reducem rata de învățare pe parcusul antrenării.

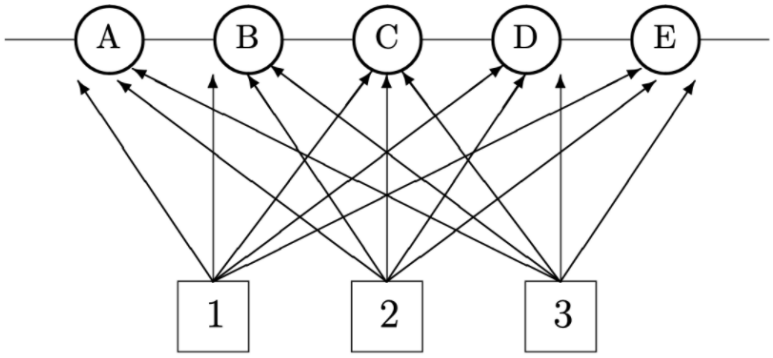


MSE (Mean Squared Error)Care dintre următoarele funcții de eroare ați utiliza pentru o rețea pe care o antrenați într-o problemă de regresie?

1. **Negative Log Likelihood**
2. **b. Binary Cross-Entropy**
3. **c. Multi-Class Cross-Entropy**
4. **d. MSE (Mean Squared Error) e in intrebare**

Retea SOM:

Pentru următoarea rețea SOM, care are 5 noduri (A - E) și 3 intrări. Rețeaua clasifica avioane pe baza valorilor celor trei intrări: 1 (dimensiune avion), 2 (număr maxim pasageri), 3 (viteza maximă posibilă). Care este numărul maxim de tipuri de avioane ce pot fi clasificate?



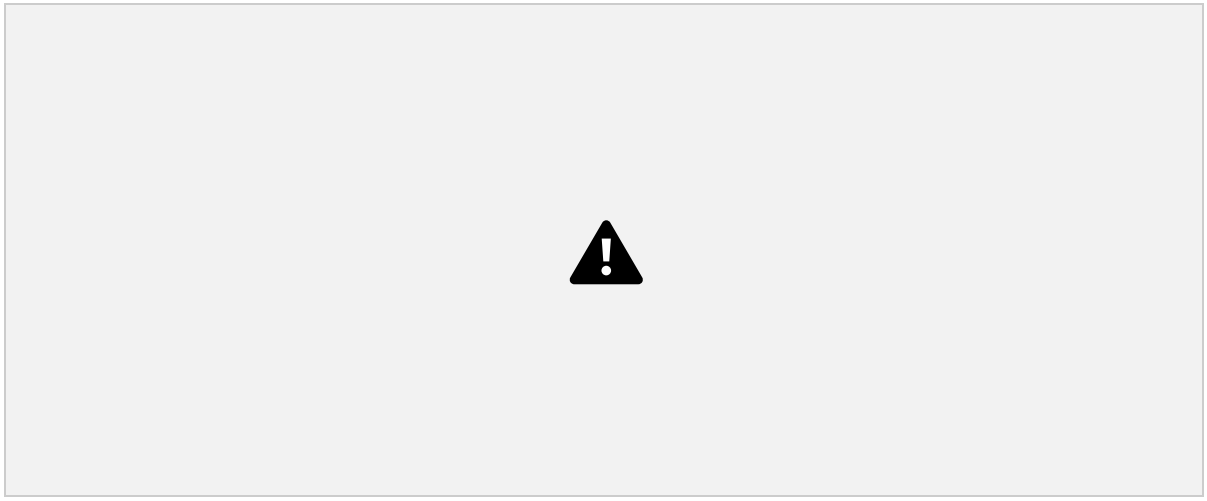
Alegeți o opțiune:

a. 2

b. 4

c. 3

d. 5 --- asta cred <- cred?



Considerăm situația în care se antrenează un model folosind gradient descent, însă nu se ajunge la costul global minim. Care ar putea fi motivul?

Select one:

a. Funcția de cost nu ține cont de regularizare.

b. Funcția de cost nu este convexă. --- pretty sure (+1)

c. Funcția de cost nu este concavă.

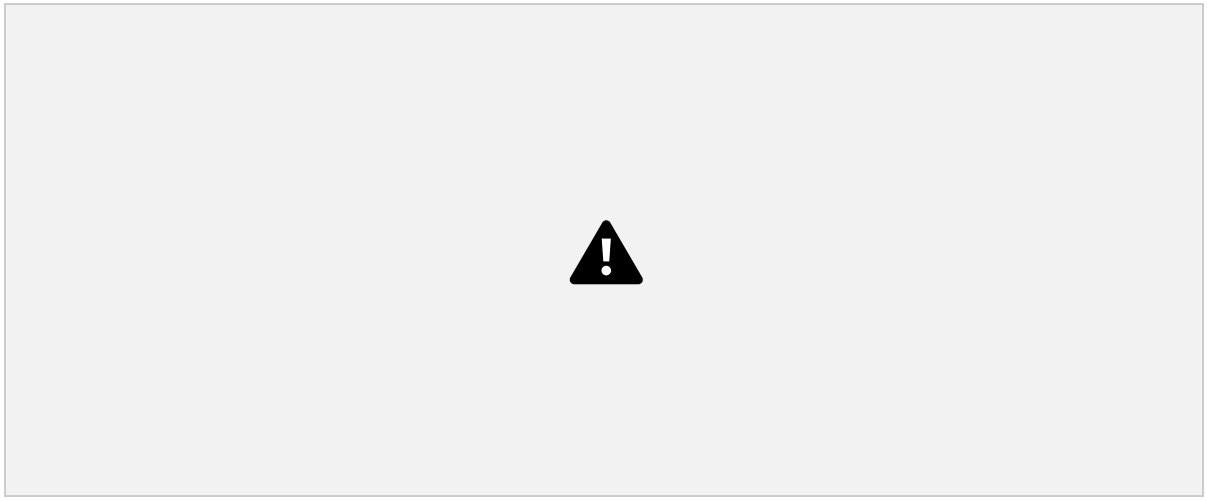
d. Funcția de cost este un polinom de grad > 2.

În formula de actualizare a parametrilor unei rețele folosind gradient descent cu momentum, ce se întâmplă când *gamma* are valoarea 1 și *eta* are valoarea 0?

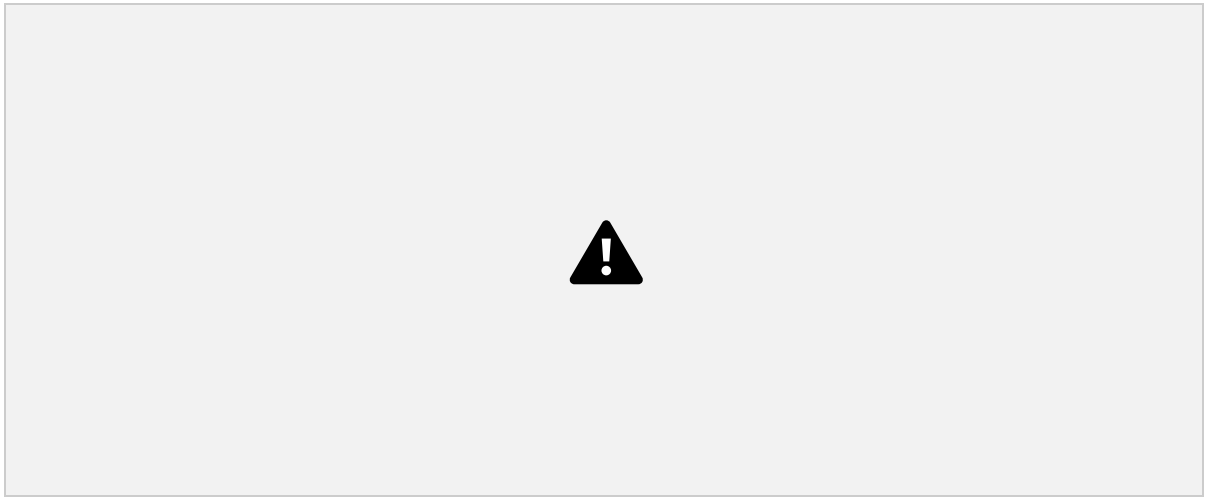
Momentum based Gradient Descent Update Rule

$$v_t = \gamma * v_{t-1} + \eta \nabla w_t$$
$$w_{t+1} = w_t - v_t$$

Select one:
a. Formula devine echivalentă cu formula pentru SGD simplu



b. Rețeaua nu învață valorile optime ale parametrilor (cred + 1 + 1 +1)
c. Rețeaua învață foarte greu valorile optime ale parametrilor
d. Rețeaua învață mai repede valorile optime ale parametrilor



Ce s-ar întâmpla într-o rețea neuronală artificială dacă am utiliza funcția de activare y = 2x, unde x este intrarea de pe un strat și y este ieșirea acestuia?

Alegeți o opțiune:

a. Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor. (+1) Sau c (+1 <- as) - https://missinglink.ai/guides/neural-network-concepts/7-types-neural-network-activation-functions-right/

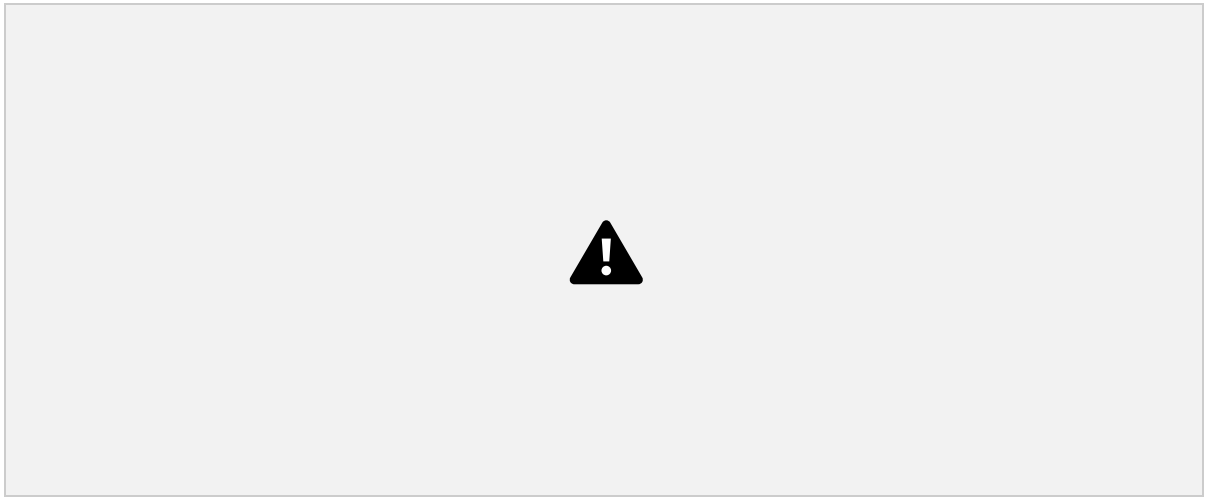
b. Ponderile s-ar micșora considerabil.

c. Ar fi imposibil ca rețeaua să mai învețe să rezolve o problemă de clasificare sau regresie (+1)

d. Valorile de la output ar deveni foarte mari - Eu cred ca e asta (+1)

Retea SOM, care are 5 noduri

Nu 3? Vad ca oricum nu poti avea combinari ca ar fi 6



Cum se poate preveni problema *vanishing gradients* în rețelele neurale adânci?

Alegeți o opțiune:

a. Prin creșterea numărului de parametri în straturi

b. Prin introducerea de conexiuni reziduale între straturi

c. Prin adăugarea mai multor straturi convoluționale în rețea

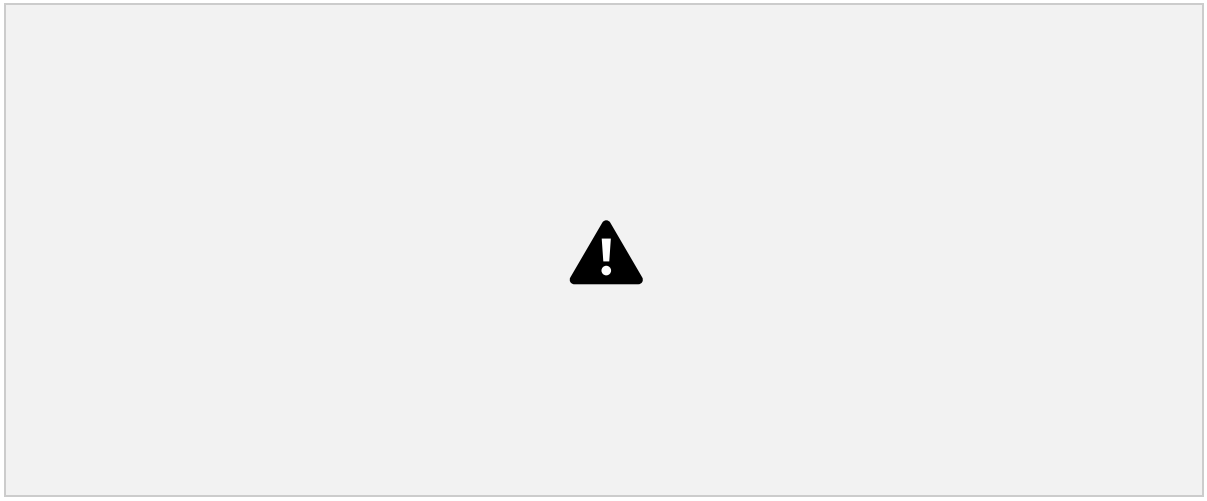
Care dintre următoarele condiții au ca efect obținerea aceluiași rezultat pentru algoritmii Q-Learning si SARSA în privința valorilor Q estimate?

Un mediu determinist

Un mediu nedeterminist, dar unde tranziția între stări se face complet uniform

O metodă de explorare a acțiunilor într-o stare care este lacomă (greedy)

O rată de învățare egală cu zero



Select one:

a. 1, 3 si 4

b. 4

c. 3

d. 3 si 4

e. 1 si 4

f. 2, 3 si 4

As mentioned earlier, Q-learning and SARSA are very similar algorithms, and in fact, Q-learning is sometimes called SARSA-max. When the agent's policy is simply the greedy one (that is, it chooses the highest-valued action from the next state no matter what), Q-learning and SARSA will produce the same results.

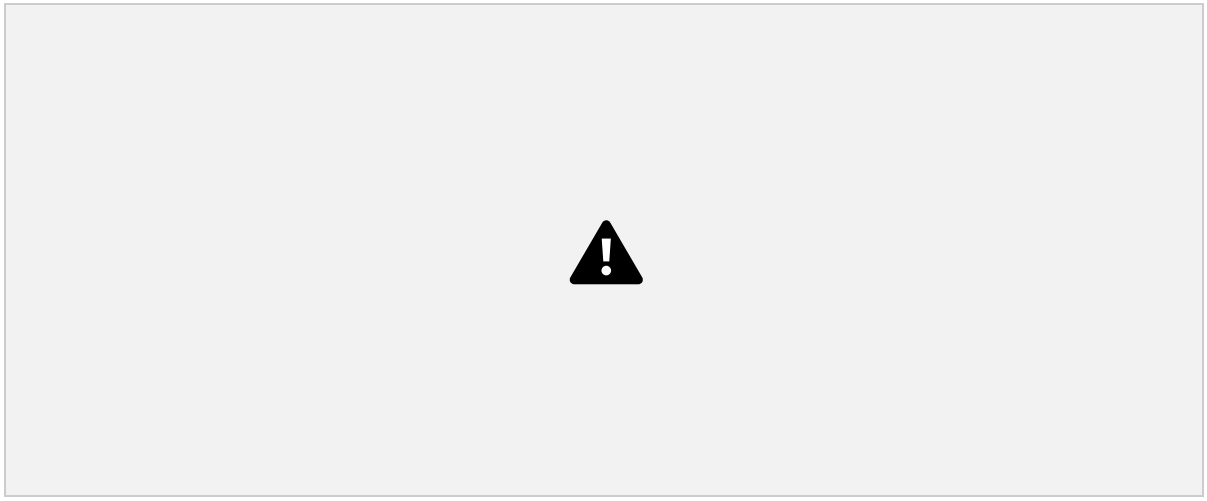
Cred ca c. 3 (si 4?) -- da. Ca pe slide 30

In practical terms, under the ε-greedy policy, Q-Learning computes the difference between Q(s,a) and the maximum action value, while SARSA computes the difference between Q(s,a) and the weighted sum of the average action value and the maximum:

Q-Learning: $Q(s_{t+1},a_{t+1}) = \max_a Q(s_{t+1},a)$

SARSA: $Q(s_{t+1},a_{t+1}) = \varepsilon \cdot \text{mean}_a Q(s_{t+1},a) + (1-\varepsilon) \cdot \max_a Q(s_{t+1},a)$

(cred ca 3 si 4)



Cred ca si 4, ca daca lr e 0 nu invata nimic si au aceleasi valori

Care din următoarele stringuri nu este un rezultat posibil care se poate obține pentru individul ”1934523107” după o operație de crossover, cu crossover point la 70% din lungimea individului?

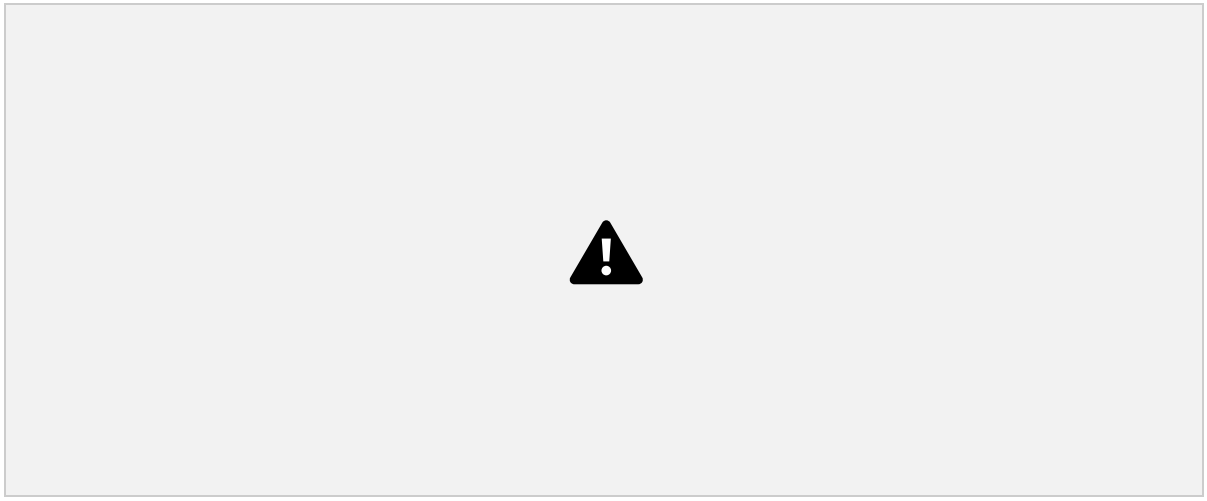
Alegeți o opțiune:

a. 1934523107

b. 1934523813

c. 1034523207

d. 1984528107



Ce funcții de activare ați folosi într-o rețea pentru a putea obține valori negative în urma aplicării activării: (raspunsuri multiple)

Alegeți una sau mai multe opțiuni:

a. Logistică

b. ReLU

c. Tangentă hiperbolică

d. Leaky ReLU

politic

Fie următoarea rețea neuronala cu doua intrări intrări binare x_1, x_2 și funcție de activare treaptă. Specificati care este funcția calculata.



Alegeți o opțiune:

a. OR

b. NOT AND

c. XOR

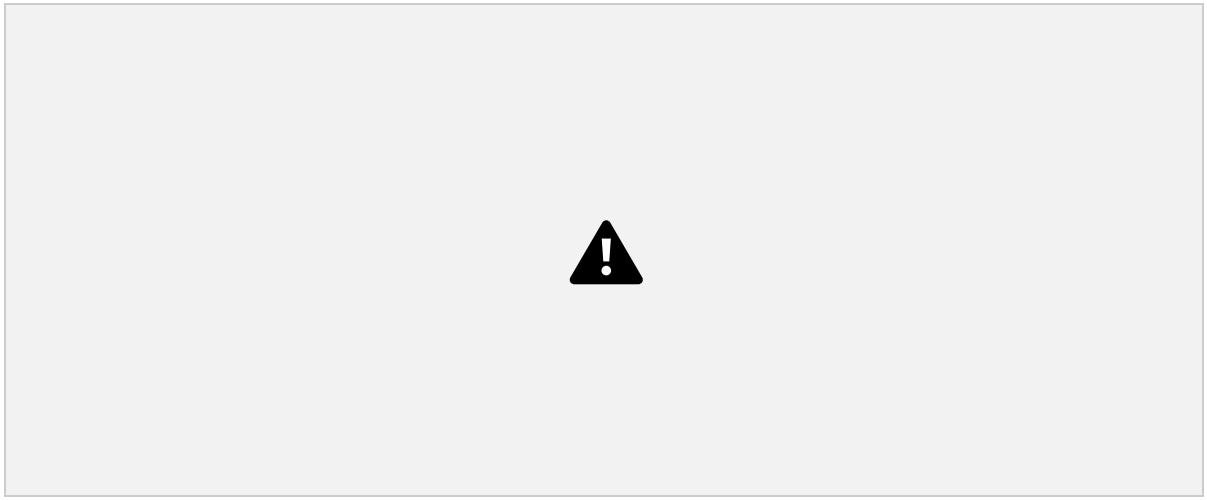
d. AND (cred) <-+ 1 + 1 +1 100%

X1 x2 -> g(z)

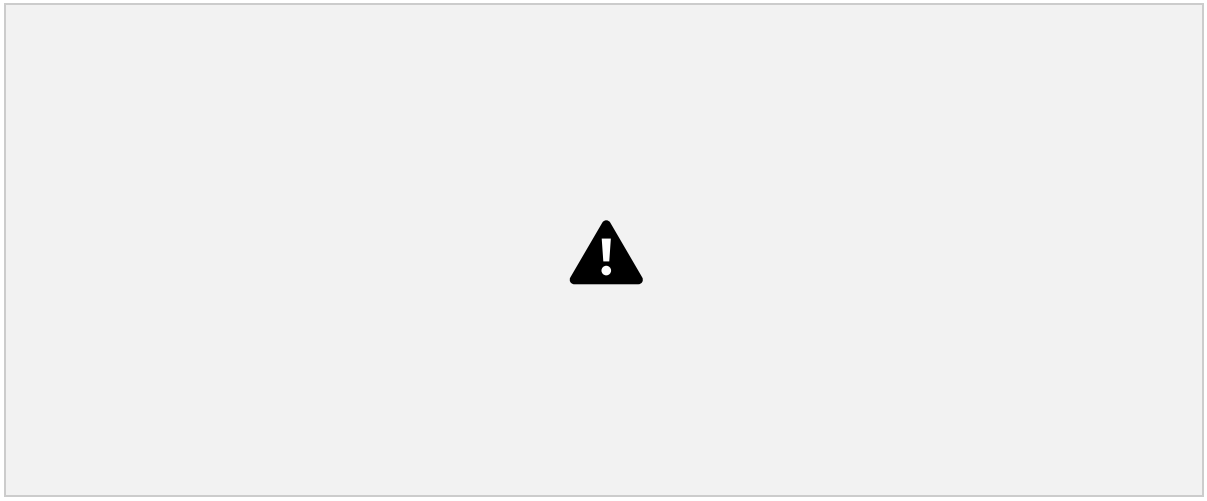
0 0 -> 0

0 1 -> 0

1 0 -> 0



1 1 -> 1 deci AND



Fie următoarea populație de 5 stringuri, unde fiecare string reprezintă codificarea în binar a unui număr natural. Considerând funcția de selecție F = x / 100 + #1(x), care sunt indivizii aleși în pasul de selecție, utilizând metoda *atribuire fitness proporțională*?
Observație: #1(x) întoarce numărul de ”1” din reprezentarea în binar a lui x

Indivizi:

32: ”0100000” -> 1.32 -> 0

95: ”1011111” -> 6.95 (2 ori)

10: ”0001010” -> 2.10 -> 0

73: ”1001001” -> 3.73 (o data)

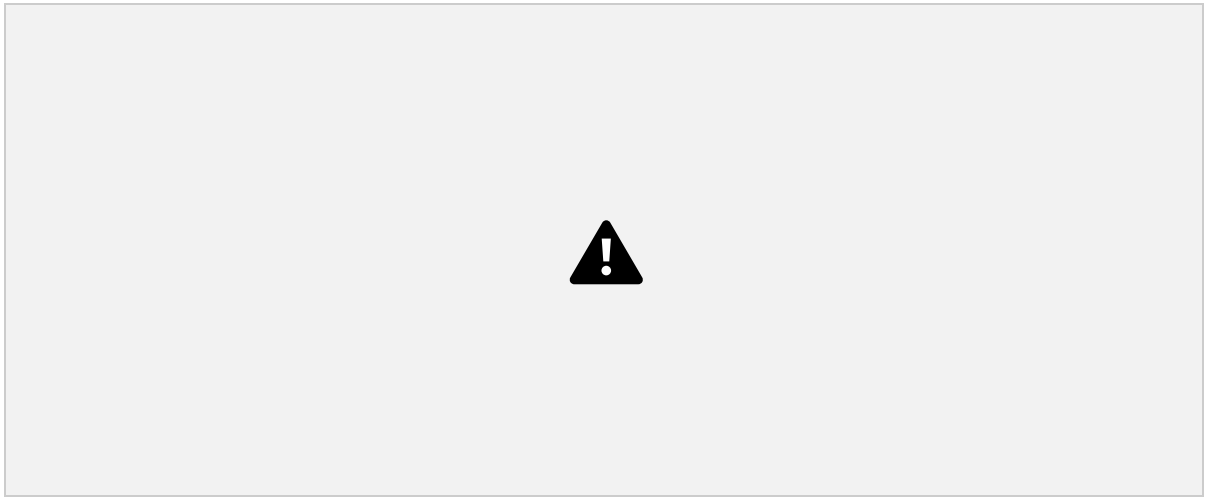
65: ”1000001” -> 2.65 -> 0

Mean value = 3.35

Alegeți o opțiune:

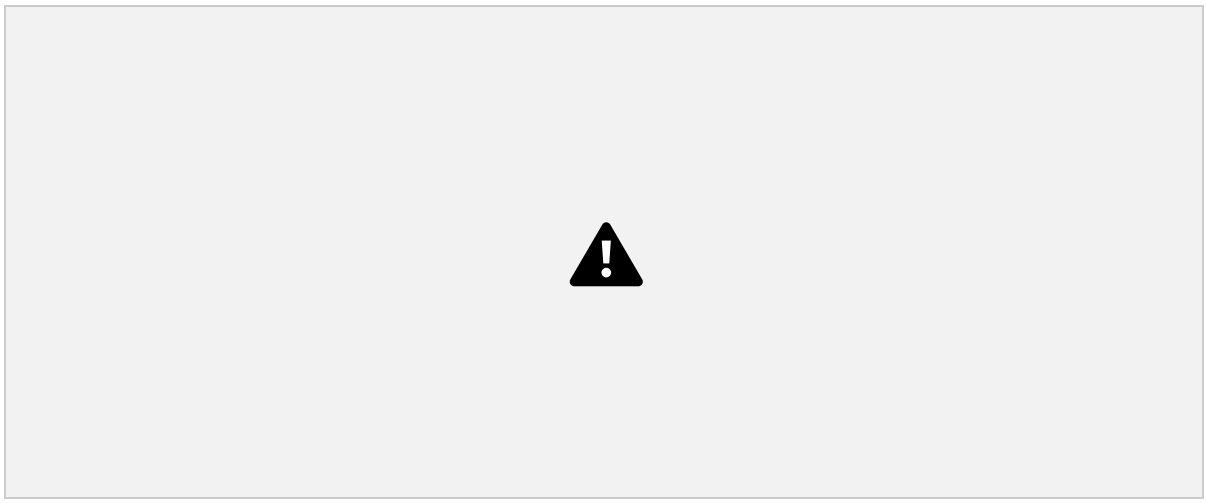
a. 95, 95, 73 (ca vine 6.95/3.35 = 2.blabla pentru 95, deci il luam de 2 ori) +1 + 1

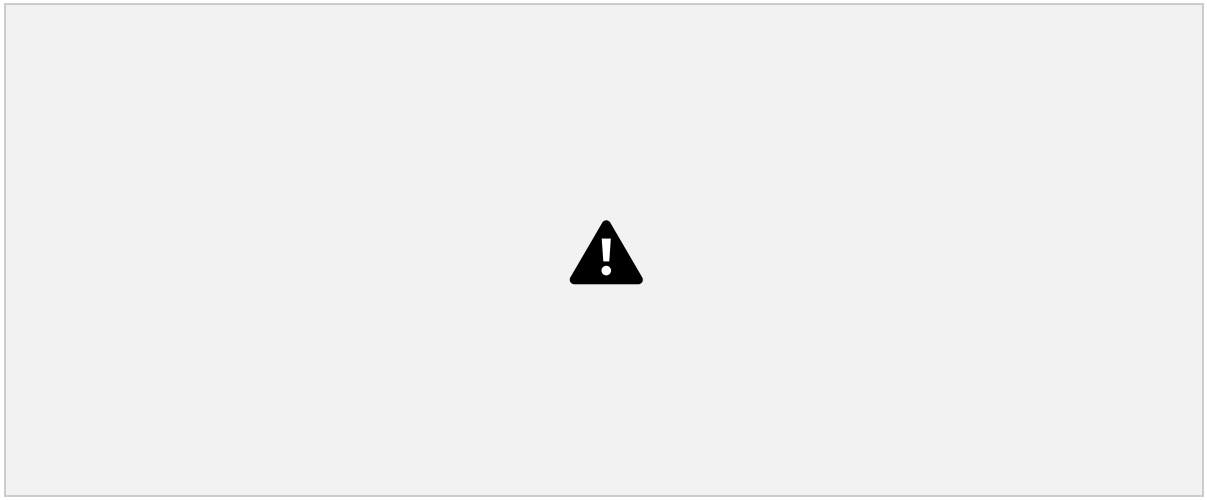
b. 65, 95, 73



c. 32, 10, 95, 73, 65

d. 95, 73 (nu e si in partial raspunsa?)





STOP

Partial ML

AI COBORAT PREA REPEDE, URCA INAPOI PENTRU FINAL SA NU PIERZI TRENUL

1.Care dintre urmatoarele sunt bune practici pentru reducerea overfitting-ului?

(a) Utilizarea unei funcții de cost cu 2 componente, care include un regulator pentru a penaliza complexitatea modelului

(b) Utilizarea unui optimizator bun pentru a reduce erorile pe datele de antrenare

(c) Construirea unei structuri de subseturi de modele imbricate, antrenarea pe fiecare subset pornind de la cel mai mic, si oprirea cand eroarea de cross-validare incepe sa creasca

(d) Eliminarea aleatoare a 50% din datele de antrenare

Alegeți o opțiune:
a. (a) si © (aflat dupa test, anonimul avea dreptate)
b. (b) si (c)
c. (c)
d. (a) si (b) (cred)
e. (a) si (b) si © *****

2. Care este avantajul folosirii algoritmului ”iterarea valorilor” vs ”iterarea politicilor”?

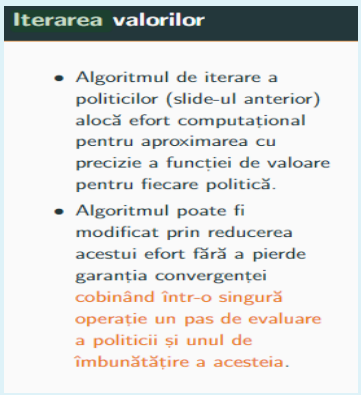
Alegeți o opțiune:

a. Necesită un efort computațional mai mic (vedeti comentarii si poza, this is the one)

b. Poate fi aplicat în probleme în care nu se cunoaște dinamica mediului

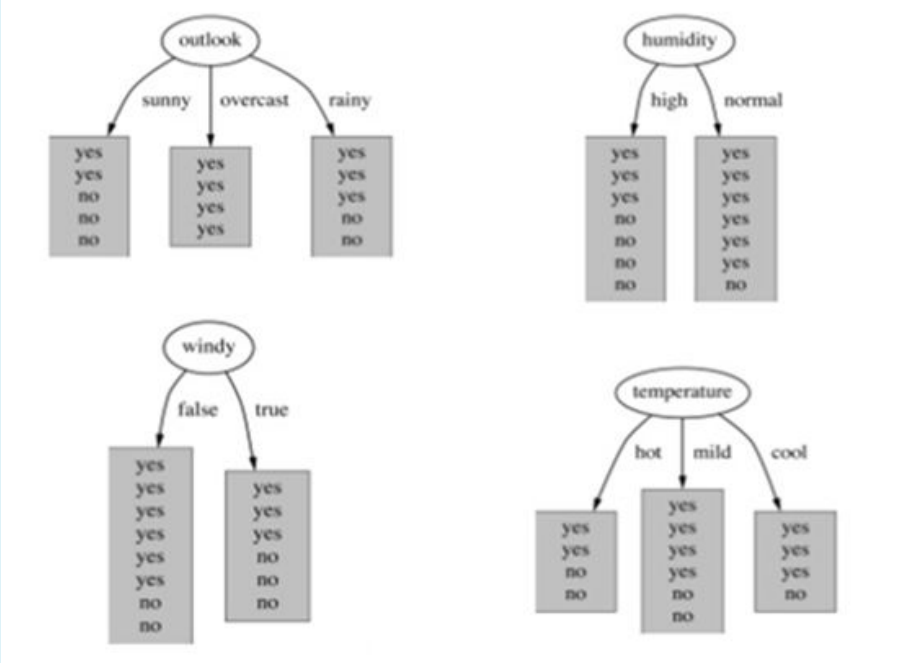
c. Calculează o politică optimă mereu, lucru care nu e garantat de ”Iterarea politicilor”

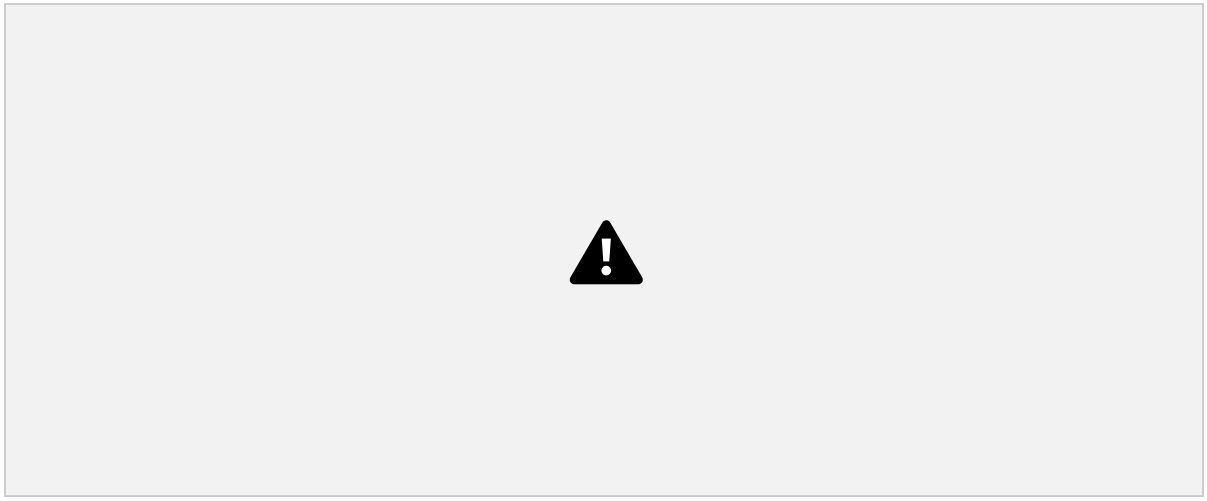
d. Nu are avantaje



Entropi

3. Se antrenează un arbore de decizie având “maximum information gain” (câștigul maxim informațional, bazat pe diferenta de entropie) drept criteriu de selecție a atributelor. Considerând acest criteriu și următoarea situație de antrenare (cf. imaginii), care va fi atributul selectat pentru a “împărți” nodul curent:





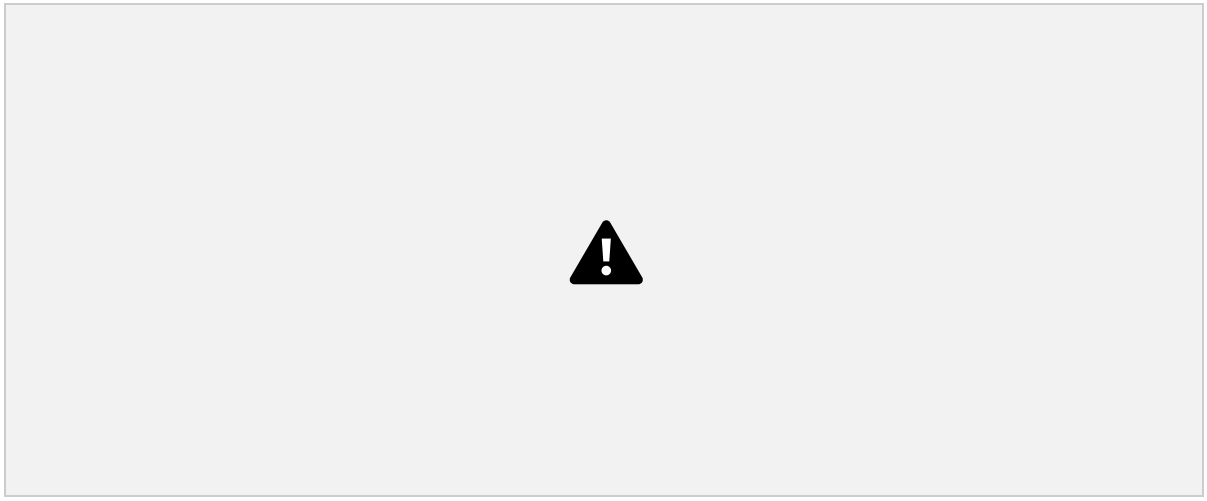
Alegeți o opțiune:

a. Temperature

b. Humidity

c. Windy

d. Outlook (https://stats.stackexchange.com/questions/362815/random-forests-and-information-gain)



In regresia logistica se folosesc:

(a) Distributie Bernoulli

(b) Distributie categoriala

(c) Distributie binomiala

(d) Distributie multinomial

Alegeți o opțiune:

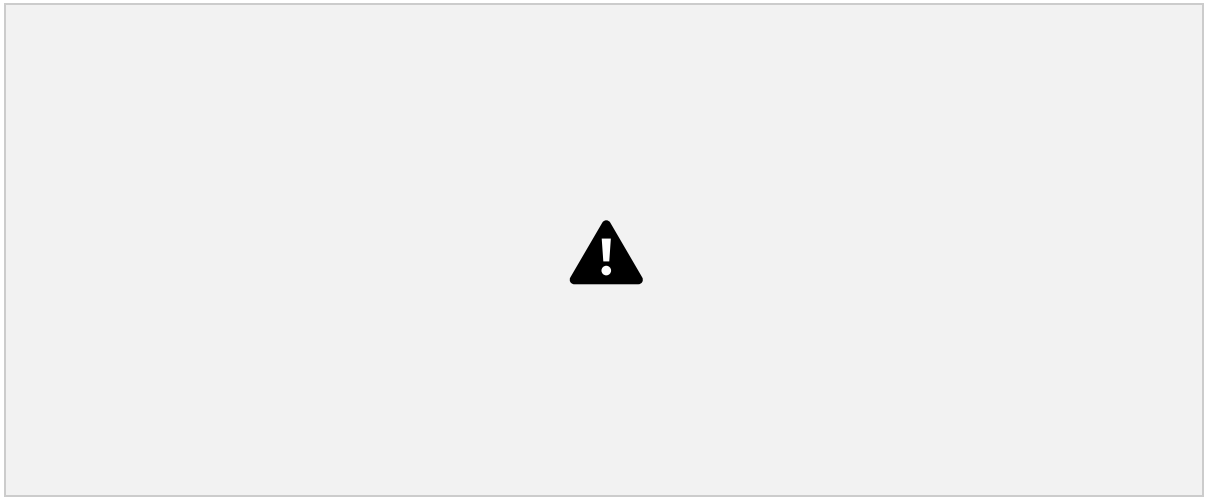
a. (a) + (c)

b. (a) + (b) + (c)

c. (b) + (c)

d. (a) + (b)

e. (c) + (d)



2.

Ce se intampla daca se alege viteza de invatare (parametrul α pentru algoritmul de gradient descent) foarte mica, respectiv foarte mare?

Alegeți o opțiune:

a. foarte mica - algoritmul de invatare ar putea sa convearga prea lent spre o solutie

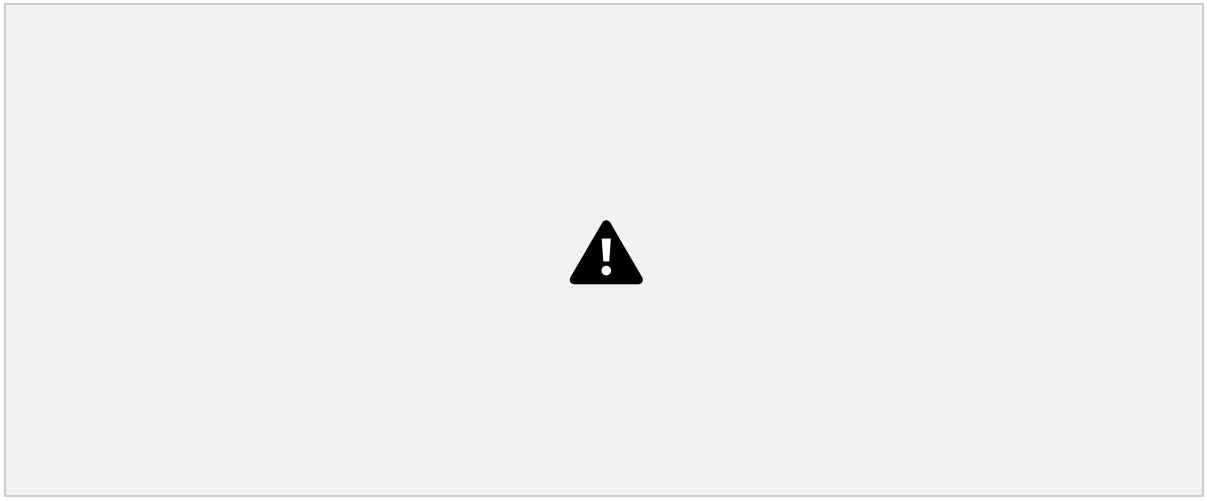
foarte mare - algoritmul de invatare ar putea sa nu gaseasca solutia

b. Nu se intampla nimic, viteza de invatare poate fi oricat deoarece algoritmul mereu va converge spre solutie in acelasi timp.

c. foarte mica - algoritmul de invatare ar putea sa convearga repede spre o solutie.

foarte mare - algoritmul de invatare ar putea sa convearga prea lent spre o solutie

d. Nu conteza viteza de invatare, deoarece formula de actualizare a parametrilor nu tine cont de aceasta.



3.Ce presupune ”lama lui Occam” in contextul arborilor de decizie?

Select one:

a. Nu se poate aplica principiul în contextul arborilor de decizie

b. Nu există mai mulți arbori corecți pentru aceeași problemă

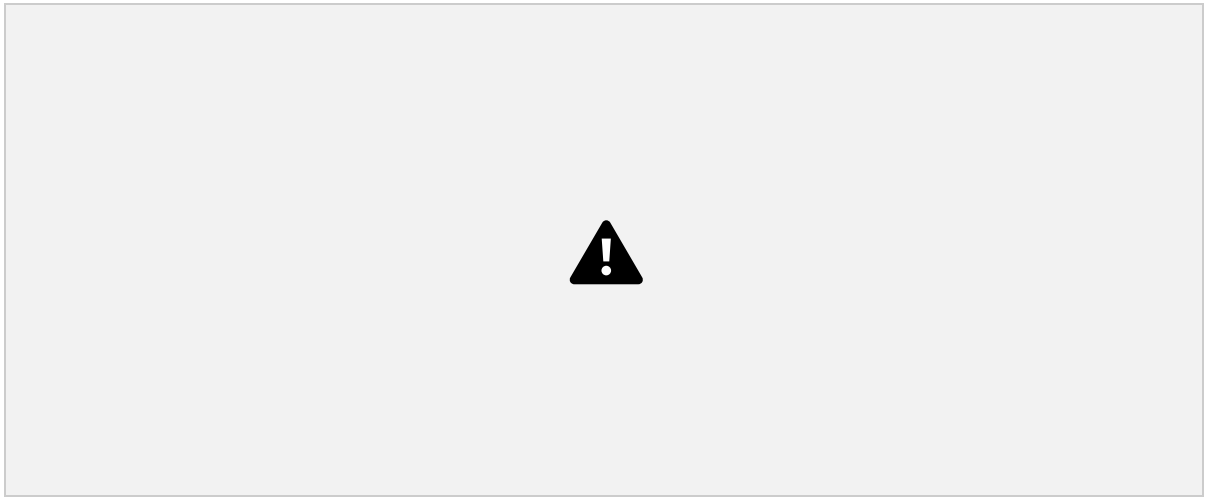
c. Dacă sunt mai mulți arbori de decizie corecți, se preferă cel mai simplu

d. Un arbore corect de decizie trebuie să cuprindă toate atributele din setul de date

21.

Fie un set de exemple cu N atribute boolene si clasificare in clasa si non-clasa. Cati arbori de decizie diferiti putem construi ?

Alegeți o opțiune:
a. 2*N
b. 2**N asta cred?
Asta e sigur: https://stackoverflow.com/questions/5671811/query-on-decision-trees
c. 2N+1
d. 2**N+1



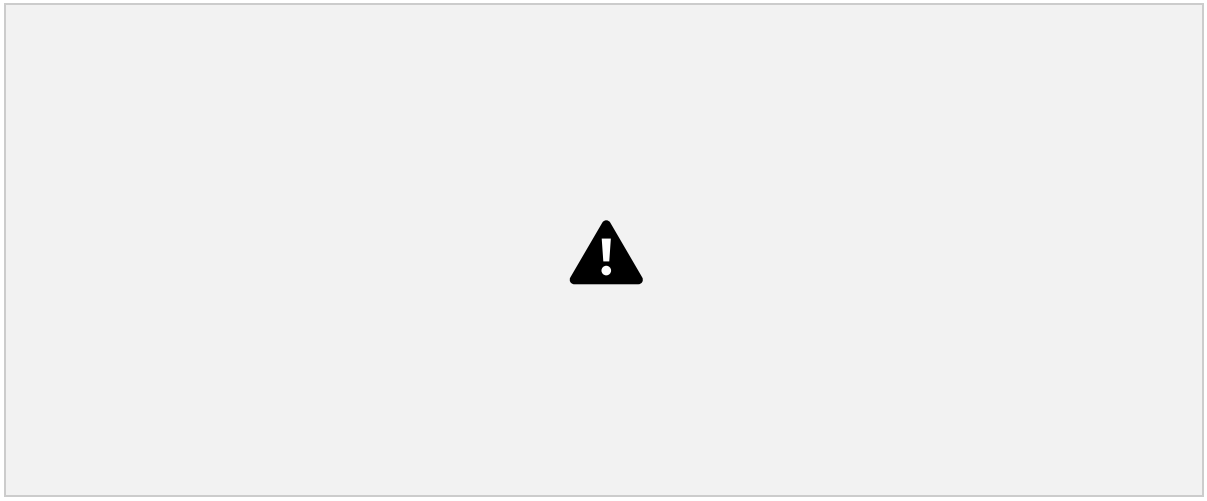
22.

Folosim o regresie liniara pentru prezicerea prețului batoanelor de ciocolată “ROM” care a fost antrenat pe factorii economici din România. Modelul obține rezultate foarte bune, însă după ce este rulat peste 5 ani acesta va avea rezultatele diferite. Care poate fi cauza?

Alegeți o opțiune:
a. Trebuia să folosim o regresie logistică pentru a putea modela parametrul de timp
b. Modelul trebuia antrenat de la început cu mai multe date
c. Factorii economici se schimbă, iar modelul trebuie re-antrenat folosind date noi

23. Arborii de decizie construiți cu algoritmul ID3 prezintă robustețe crescută la „outliers”? Care dintre răspunsuri este cel mai plauzibil?

Alegeți o opțiune:



a. Da, pentru că unele atribute nu sunt luate în considerare. (cred: https://datascience.stackexchange.com/questions/37394/are-decision-trees-robust-to-outliers) (stack exchange este o minciuna a cabalelor mondiale :)))

b. Da, întrucât acest lucru este garantat prin calculul entropiei.

c. Nu, pentru că ele (outliers) influențează sub-arborii generați ca fii ai unui nod test. (asta era, aflat dupa test)

d. Nu, pentru că vom obține valori negative pentru câștigul informațional în cazul lor.

Dorim să prezicem prețul unui apartament din zona Pipera. Pentru a face acest lucru ce putem folosi dintre:
Alegeți o opțiune:

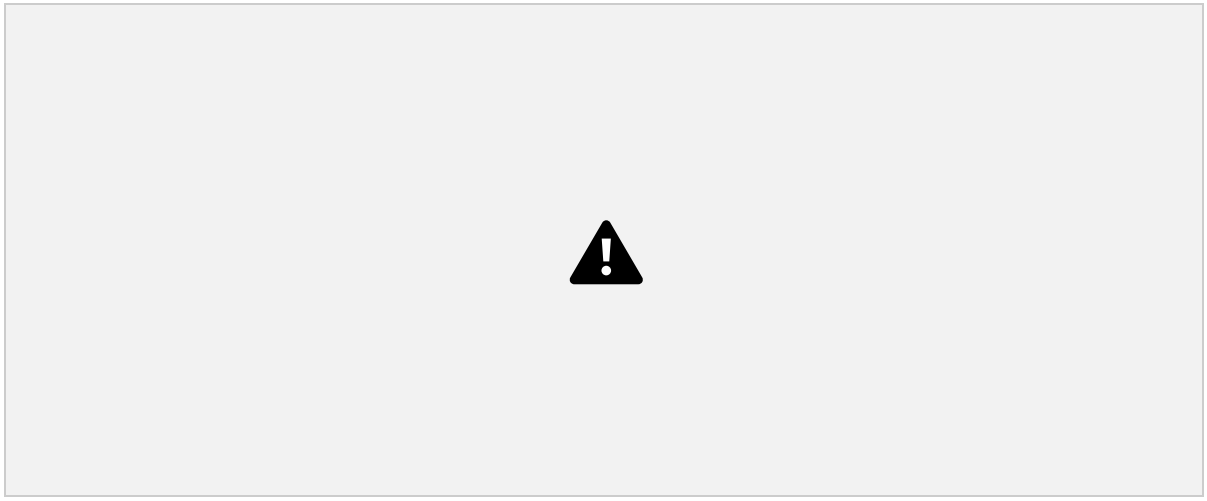
a. Regresie liniară

b. Regresie liniară sau arbori de decizie

c. Regresie liniară sau logistică(dc nu ar fi asta?)

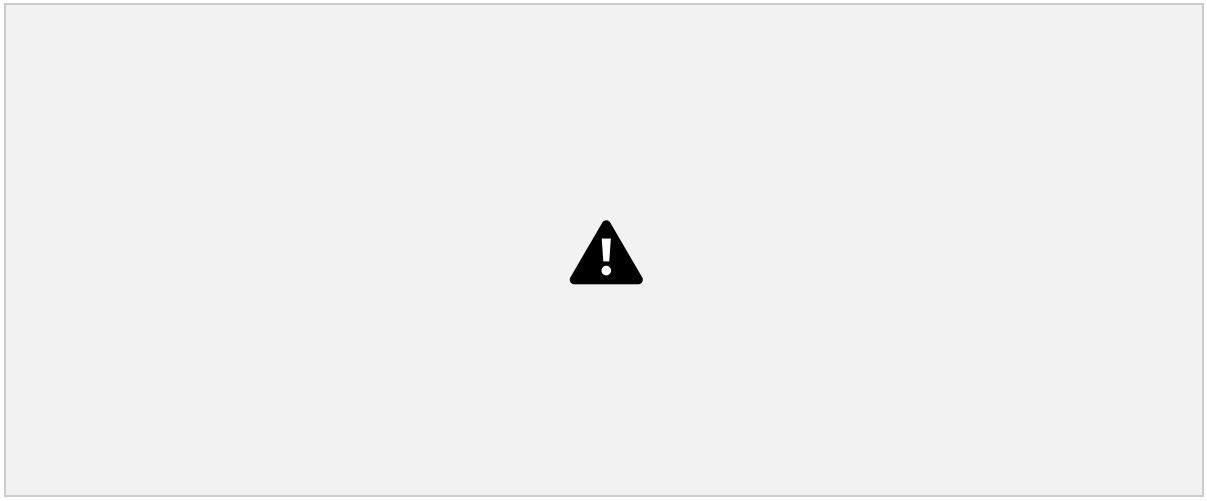
d. Regresie logistică

e. Arbori de decizie???



Ce se intampla daca se alege viteza de invatare (parametrul α pentru algoritmul de gradient descent) foarte mica, respectiv foarte mare?

Alegeți o opțiune:
a. Nu conteza viteza de invatare, deoarece formula de actualizare a parametrilor nu tine cont de aceasta.
b. Nu se intampla nimic, viteza de invatare poate fi oricat deoarece algoritmul mereu va converge spre solutie in acelasi timp.
c. foarte mica - algoritmul de invatare ar putea sa conveaarga prea lent spre o solutie
foarte mare - algoritmul de invatare ar putea sa nu gaseasca solutia
d. foarte mica - algoritmul de invatare ar putea sa conveaarga repede spre o solutie.
foarte mare - algoritmul de invatare ar putea sa conveaarga prea lent spre o solutie



4.In urma antrenarii unui algoritm de invatare automata, observati ca acesta are o acuratete foarte buna pe setul de antrenare, insa mica pe setul de testare.

Care poate fi motivul? Si cum am putea rezolva ? (presupunand ca avem un clasificator bazat pe arbori de decizie)

Alegeți o opțiune:

a. Overfitting. Putem aplica prunning. (google “pruning in decision tree for overfitting”)

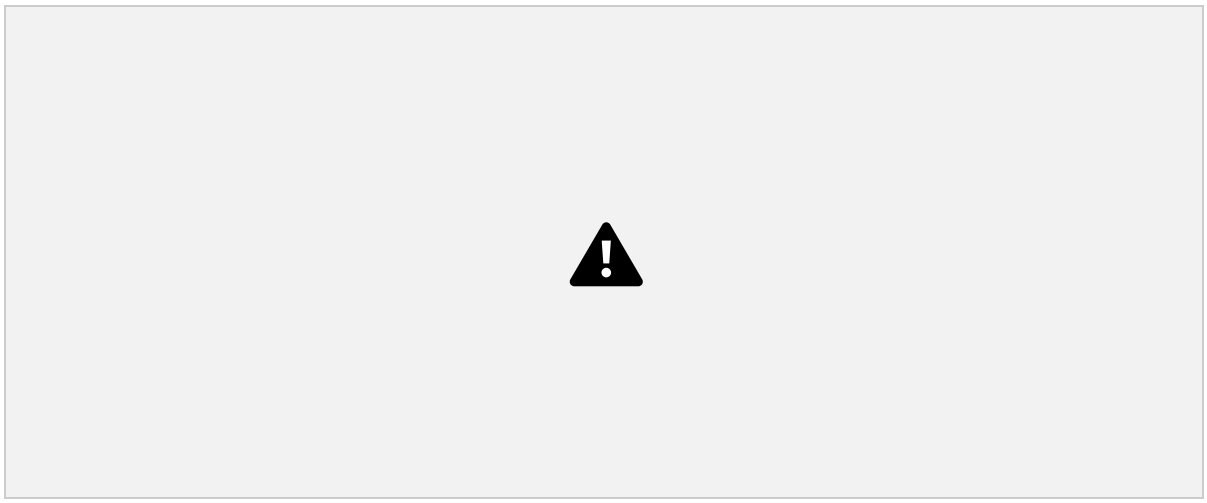
b. Overfitting. Adaugam mai multe atribute dupa care sa facem clasificarea

c. Underfitting. Putem adauga mai multe date in setul de testare.

d. Underfitting. Eliminam aleator un procent de date din setul de antrenare.

5.

Un agent se mișcă într-un mediu 3x3 cu următoarele recompense:



	1	2	3
1	**0.5**	**0.5**	**0.5**
2	**-1**	**0.5**	**1**
3	**0.5**	**0.5**	**0.5**

Agentul poate executa acțiunile A1 (se mută la stânga cu probabilitatea 0.8 sau se mută în celula de sus cu probabilitatea 0.2) și A2 (se mută la dreapta cu probabilitatea 0.6, se mută în celula de sus cu probabilitatea 0.2 sau se mută în celula de jos cu probabilitatea 0.2). Care este utilitatea stării (2,2) dacă factorul de atenuare are valoarea 0.9 (calculați folosind ecuația Bellman pentru un pas)?

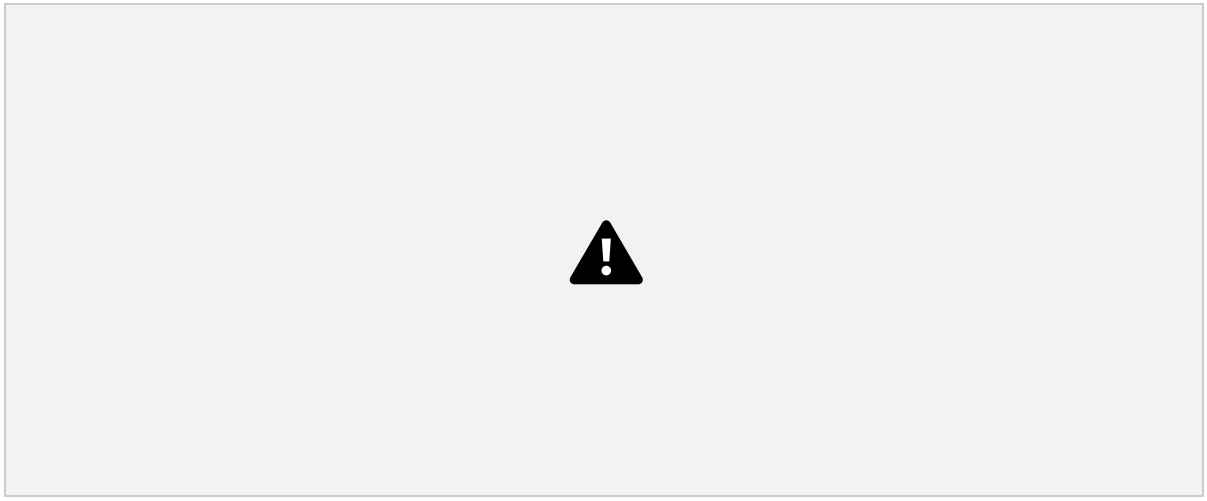
Alegeți o opțiune:

a. 1.14

b. 1.22

c. 0.72

d. 0.5



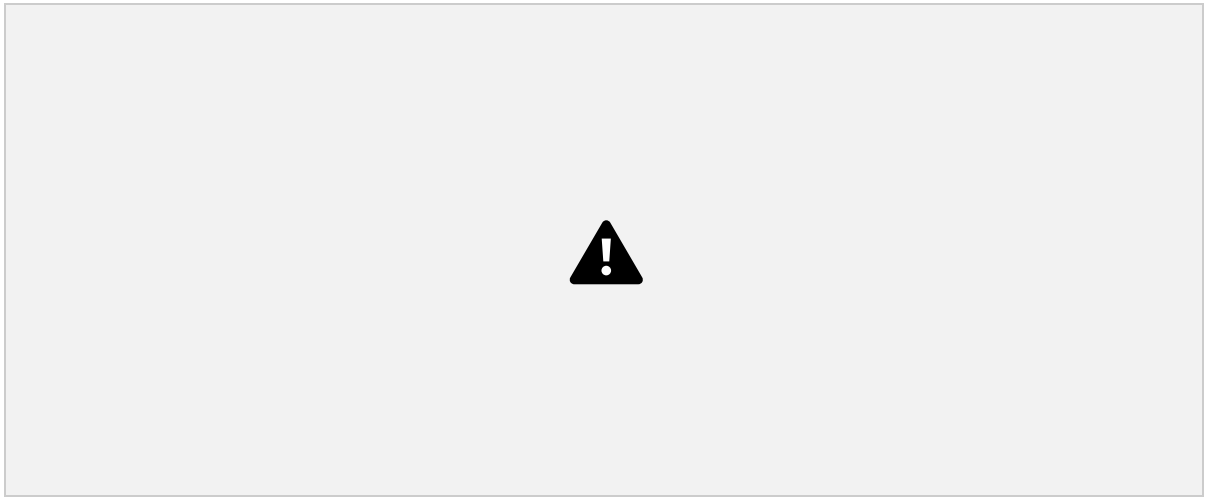
6.

In cazul antrenarii regresiei liniare folosind urmatorul set de date (x: intrare, y: iesire), specificati care este valoare J(0, 1), unde $J(\theta_0, \theta_1)$ este functia de eroare pătratică pentru modelul de regresie liniară.

x	y
3	4
2	1
4	3
0	1

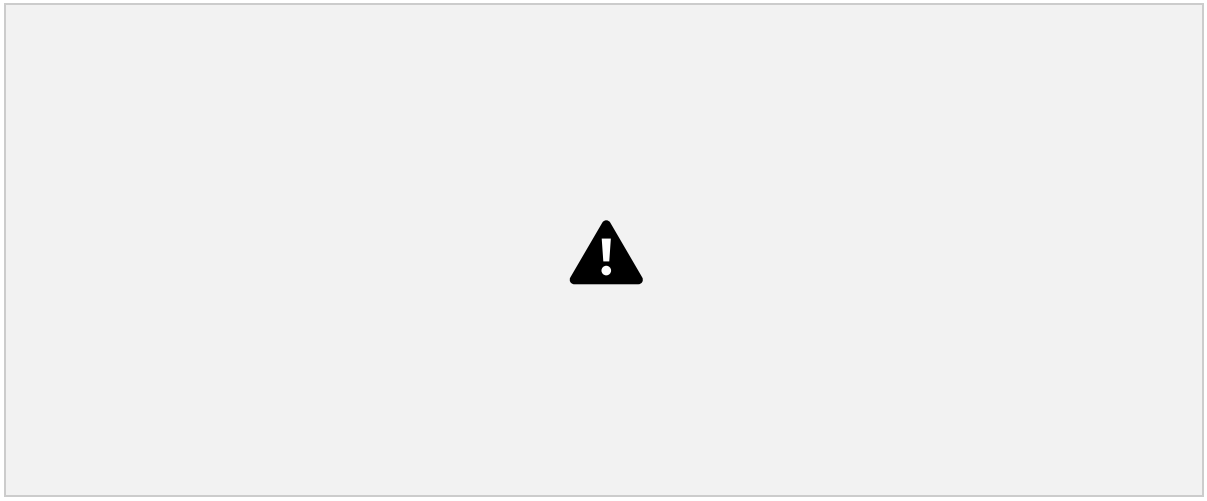
$$J(\theta_1) = \frac{1}{2n} \sum_{i=1}^{n} (h(x^i) - y^i)^2$$

Alegeți o opțiune:



a. 0.5

b. 1 = sqrt(¼*(1 + 1 + 1+ 1)) y’ = x



7.Pe un set de date cu atribute discrete se antrenează un arbore de decizie *T* prin algoritmul ID3, cu adancime maximă *h*.

Pe același set de date se antrenează un model RandomForest *M*.

Modelul *M* folosește weak-learners (i.e. arborii de decizie care alcatuiesc Pădurea Aleatoare) identici cu *T* (i.e. același criteriu de alegere a atributelor, aceeași adâncime maximă *h*).

Fiecare arbore din RandomForest este antrenat **pe același set de date precum și folosind același set de atribute** precum modelul *T*.

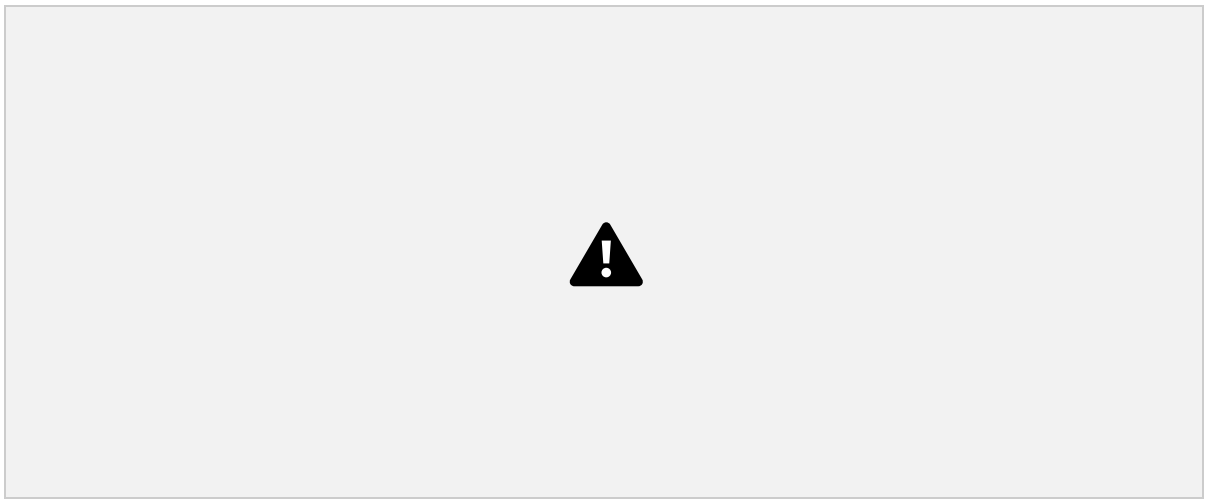
Modelul *M* astfel rezultat va avea:

Select one:

a. Aceeași acuratețe ca *T // cred ca asta - varianta finala*

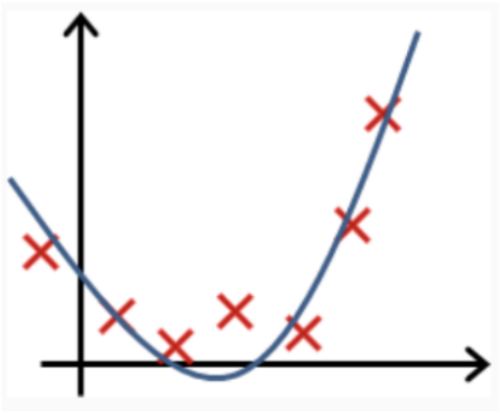
b. Acuratețe mai bună ca *T - cred ca asta +1*

c. Acuratețe mai mică decât *T*

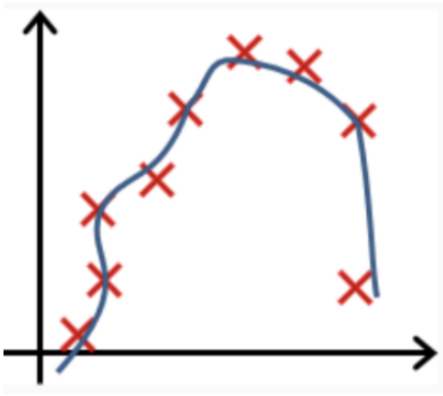


8. In urma antrenarii unei regresii, care figura corespunde aparitiei underfitingului?

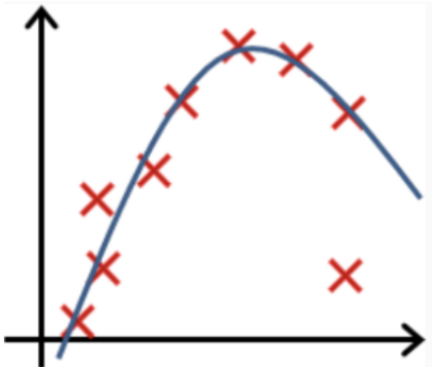
A.



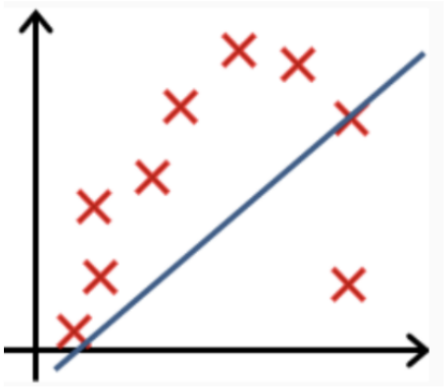
B.

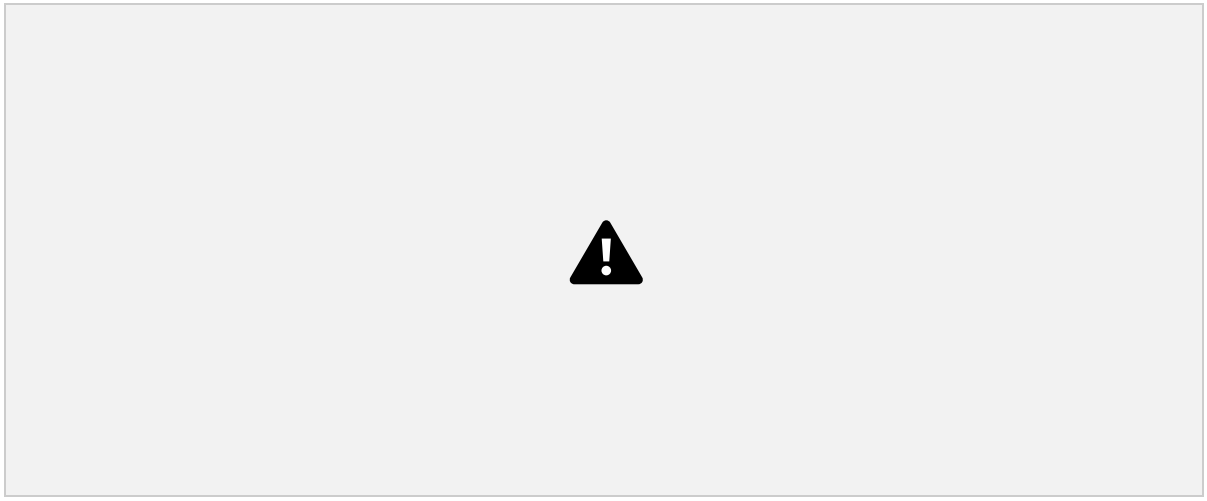


C.



D.





Alegeți o opțiune:

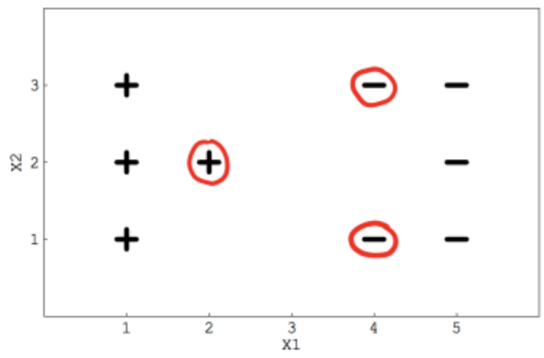
a. A

b. C

c. D

d. B

Dacă se elimina unul din punctele marcate cu rosu, hiperplanul de separare pentru un clasificator SVM se modifica?



Alegeți o opțiune:

a. Da (dacă se scoate +, sigur se modifică)

b. Nu

Care este ecuația care definește dreapta pe care se află vectorii suport ai clasei pozitive după determinarea marginii în algoritmul SVM? (w' reprezintă transpusul lui w)

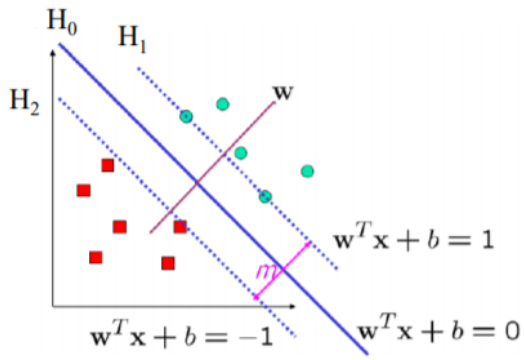
Alegeți o opțiune:

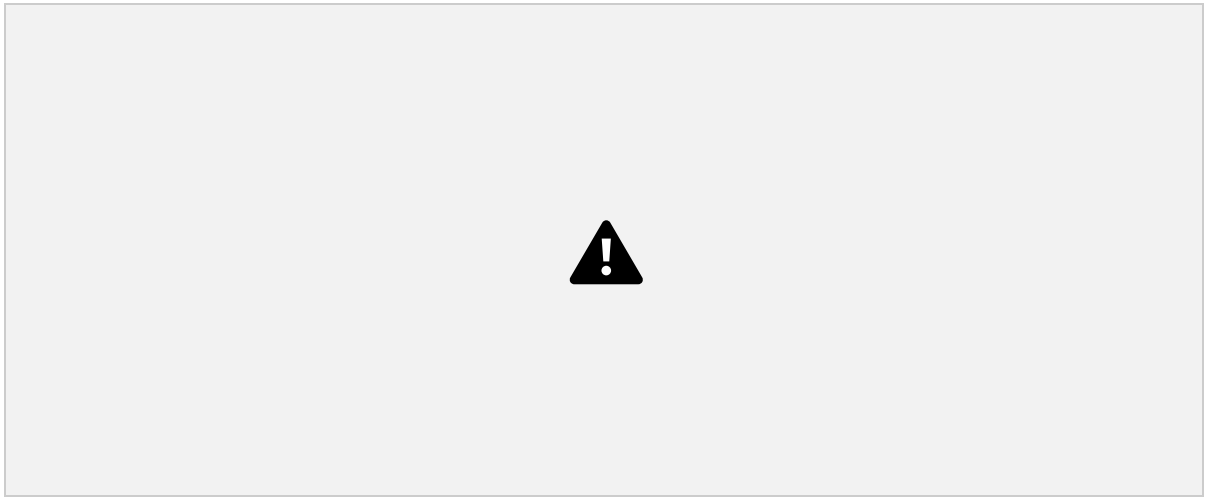
a. w' * x + b = 1

b. w' * x + b = -1 nu e asta? vezi poza de mai jos; nu, asta e pentru negative

c. w' * x + b = 0

d. w' * x + b > 1





$$f(x) = \text{sign}(\mathbf{w}^T\mathbf{x} + b), \text{ i.e.,}$$

$$f(x) = 1 \text{ daca } \mathbf{w}^T\mathbf{x} + b \geq 0$$

$$f(x) = -1 \text{ daca } \mathbf{w}^T\mathbf{x} + b < 0$$

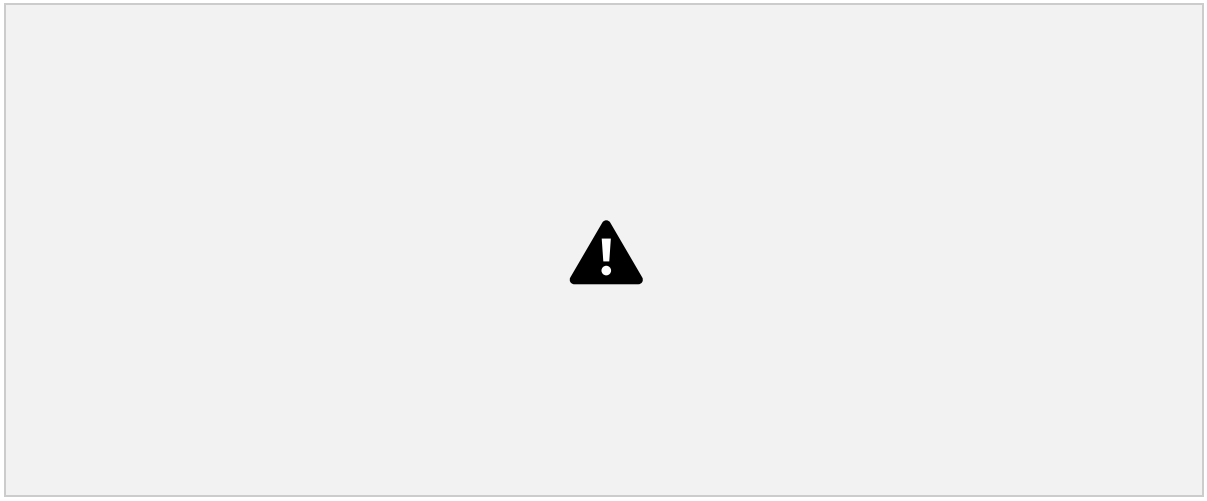
Datele de antrenare au erori deci ceea ce modelam nu este f ci f+eps. Considerand posibilele surse de erori mentionate mai jos care credeti ca sunt cele mai importante in rezolvarea unei probleme prin regresie liniara ?

(a) Erori de la senzori

(b) Erori de la o sursa malitioasa care introduce special aceste erori

(c) Erori de transciere (ale operatorului)

(d) Influente ale modelului care nu sunt luate in considerare



Alegeți o opțiune:

a. (a) si (b) si (c) si (d)

b. (a) si (c)

c. (a) si (b) si (c)

d. (a) si (b)

Un set de date utilizat pentru învățare supervizată are o valoare mare a entropiei informaționale dacă:

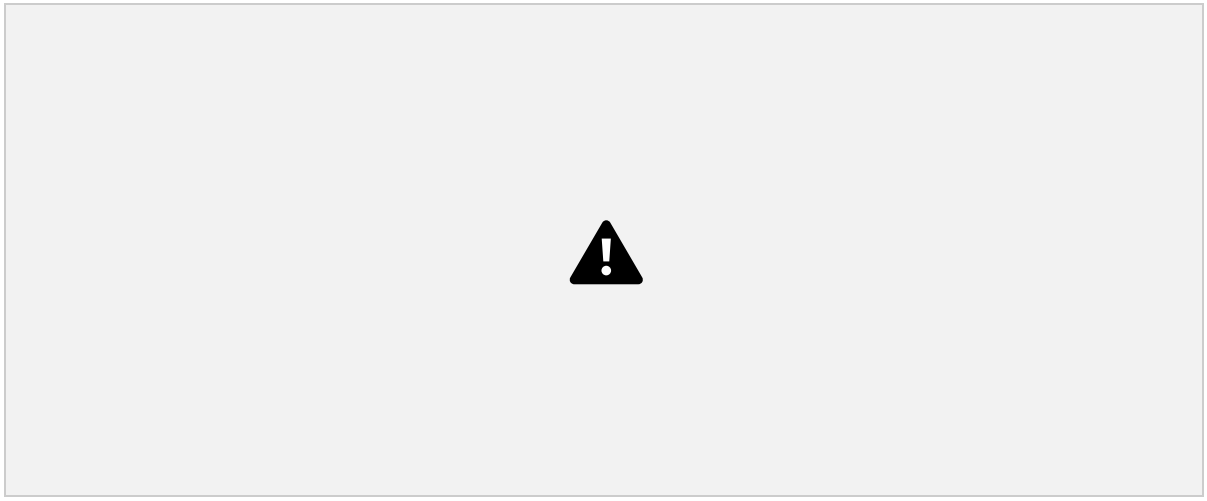
Alegeți o opțiune:

a. Foarte multe dintre exemple aparțin unui număr mic de clase, în timp ce restul de clase au un număr mic de exemple. Nu e asta? Ba da

What does high entropy mean?

Scientists refer to the measure of randomness or disorder within a system as **entropy**. **High entropy means high** disorder and low energy (Figure 1). ... If no energy or work were put into it, the room **would** quickly become messy. It **would** exist in a very disordered state, one of **high entropy**. **(in fizica e una, in date la noi aici e altceva, uita-te mai jos**) fuck it

Entropy means uncertainty. High entropy means it hard to predicate the next possibility. eg: All n possible moves has 1/n probability. Low entropy means a particular next move is



obviously observed. eg: Next Move 1 has 0.01% probability and next move 2 has 99.99% probability. **(deci b tre sa fie, ca inseamna ca orice exemplu poate fi in orice clasa. Daca ar fi multe intr-o clasa, ai avea probabilitate de 90+, deci entropie mica)**

b. Numărul de exemple din fiecare clasă este relativ similar +1(cred)

c. Toate exemplele fac parte din aceeași clasă

Procedura de cross-validation este folosită des pentru a găsi o valoare bună a hiperparametrilor unui model de învățare. În urma procedurii, se poate raporta o medie și o varianță a diferitelor modele (i.e. a instanțelor de model, pentru fiecare combinație de hiperparametrii).

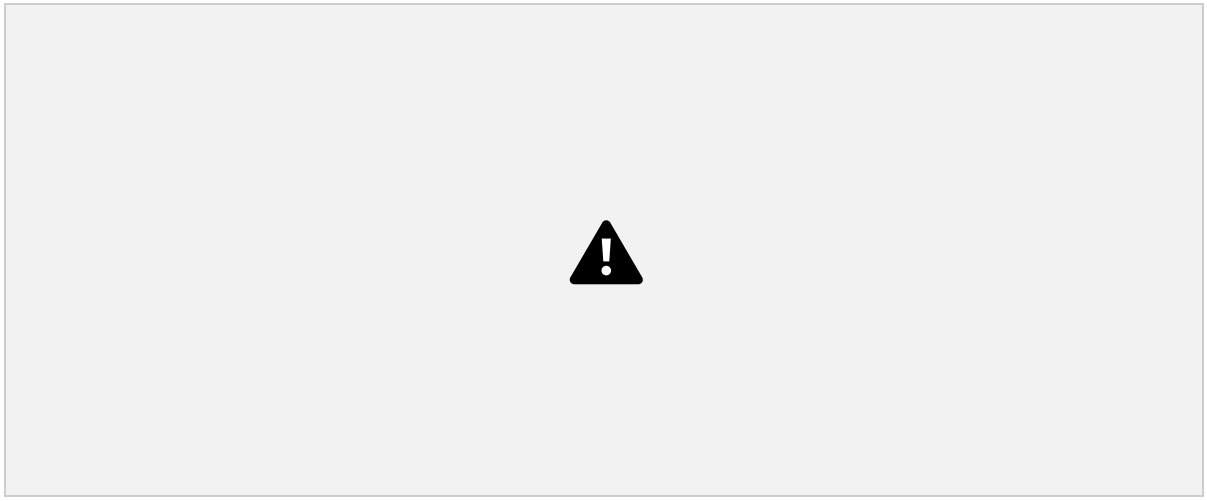
Ce fel de modele vor fi preferate?

Alegeți o opțiune:

a. Modele cu medie mare și varianță mare

b. Modele cu medie mare și varianță mică (cred)

c. Modele cu medie mică și varianță mare



d. Modele cu medie mică și variantă mică

Dorim sa rezolvam o problema de clasificare binara. Avem 2 clase, fiecare clasa cu 500 de exemple. Datele sunt liniar separabile.

Care este numarul maxim si minim de vectori suport?

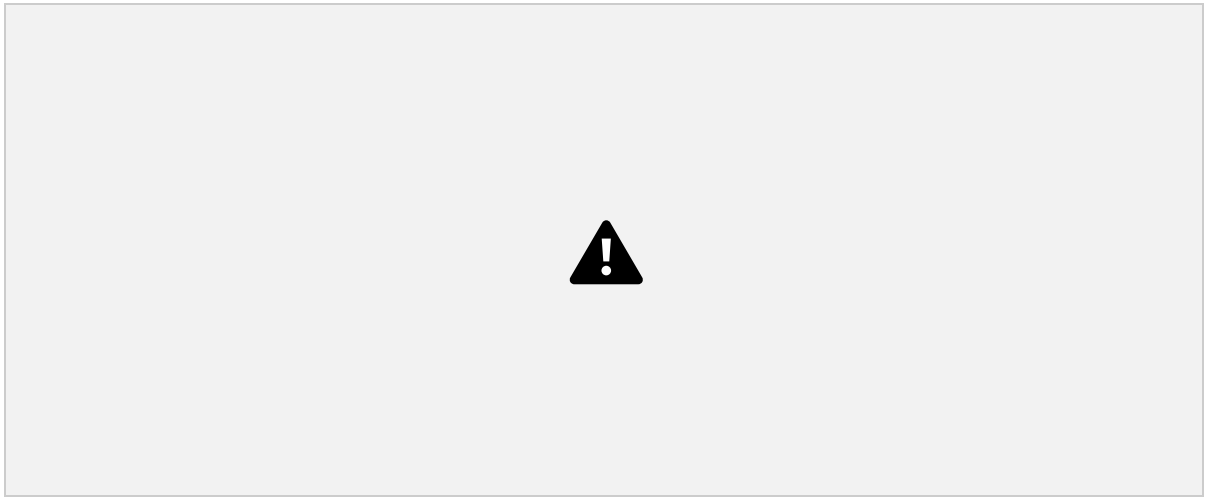
Alegeți o opțiune:(

a. minim - 250, maxim - 500

b. minim - 2, maxim - 1000

c. minim - 1000, maxim - 1000

d. minim - 500, maxim - 500



9. Care este diferența principală între clasele bagging și boosting ale algoritmilor de tip ensemble?

Alegeți o opțiune:

a. Spre deosebire de bagging, metodele de boosting folosesc clasificatori slabi

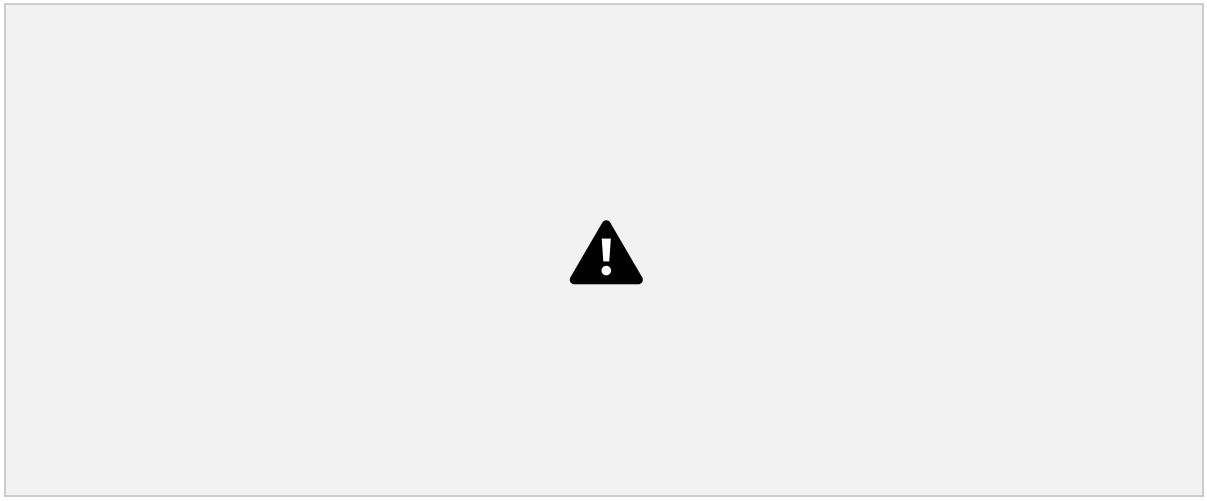
b. Spre deosebire de boosting, metodele de bagging folosesc clasificatori slabi

c. Clasificatorii metodelor de bagging sunt antrenați independent, în timp ce clasificatorii metodelor de boosting sunt antrenați iterativ

d. Clasificatorii metodelor de boosting sunt antrenați independent, în timp ce clasificatorii metodelor de bagging sunt antrenați iterativ

10.

Avem urmatoarea matrice de confuzie pentru o problema de clasificare binara (pe coloane sunt valorile reale, iar pe linii sunt valorile prezise).



Care afirmatie este adevarata?

	Positive	Negative
Positive	23	1
Negative	12	556

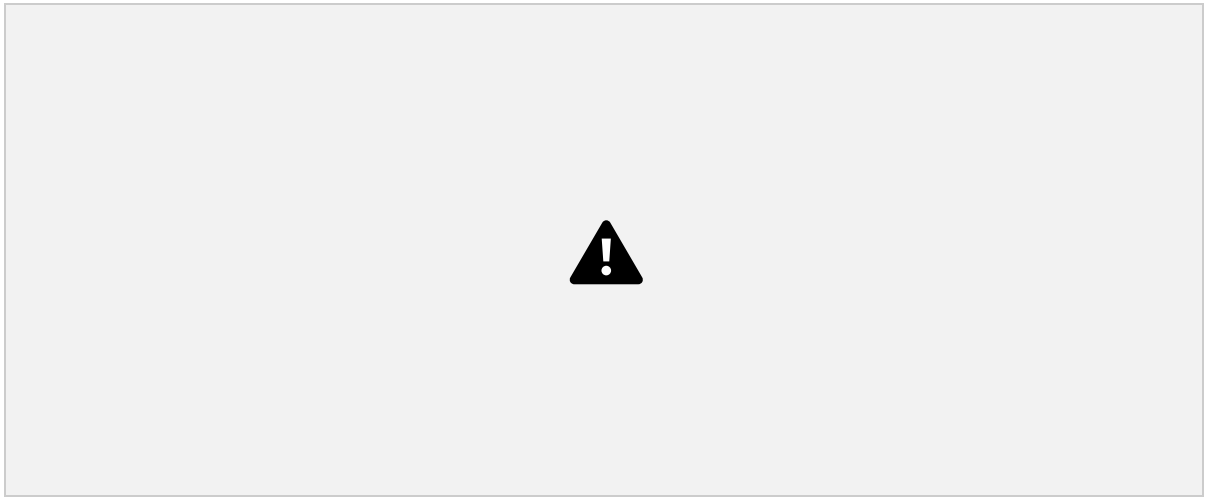
Alegeți o opțiune:

a. Recall=23/24

b. Accuracy=568/592

c. Accuracy=557/556

d. Precision=23/24



11. Ce tip de regresie ar trebui folosita pentru o problema in care dorim sa impartim un set de date in 2 categorii? (presupunem ca dorim sa antrenam un algoritm pentru care avem setul de date de antrenare)

Alegeți o opțiune:

a. Regresie logistica deoarece nu stim cum sa codificam "categoriile" in nume reale necesare regresiei liniare.

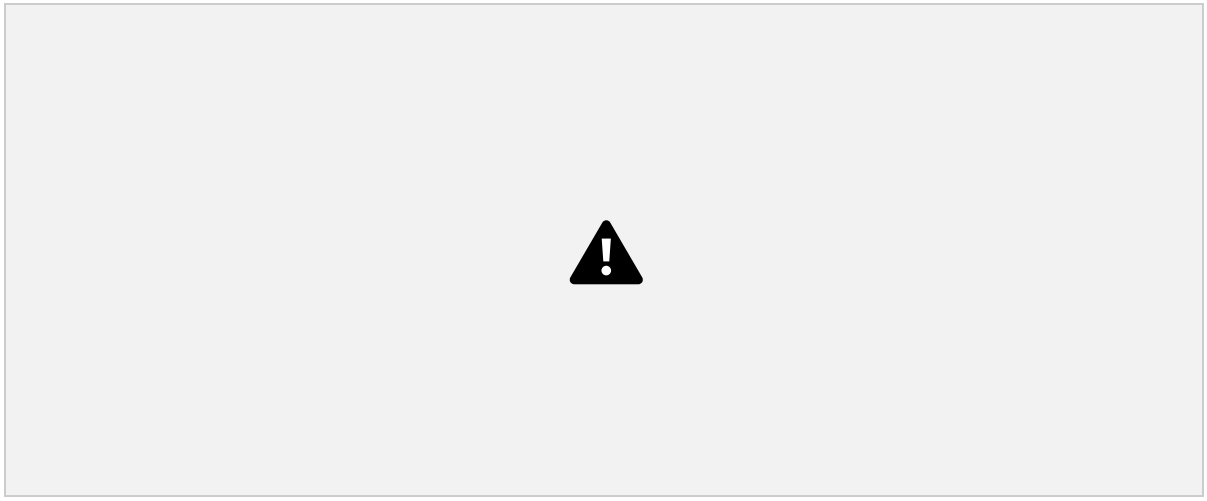
b. Regresia logistica deoarece foloseste functia logistica pentru a modela probabilitatea ca un punct din setul de date sa se gaseasca intr-o anumita clasa.

c. Regresie liniara deoarece cele 2 categorii (din setul de antrenare) pot fi etichetate cu 0 si 1. In etapa de antrenare algoritmul va avea de gasit o dreapta care trece prin cele 2 puncte (0 si 1)

d. Regresie liniara deoarece datele pot fi separate cu ajutorul unei drepte

Fie următoarea populație de 5 stringuri, unde fiecare string reprezintă codificarea în binar a unui număr natural. Considerând funcția de selecție F = x / 100 + #1(x), care sunt indivizii aleși în pasul de selecție, utilizând metoda *atribuire fitness proporțională*?

Observație: #1(x) întoarce numărul de ”1” din reprezentarea în binar a lui x



Indivizi:

32: ”0100000”

95: ”1011111”

10: ”0001010”

73: ”1001001”

65: ”1000001”

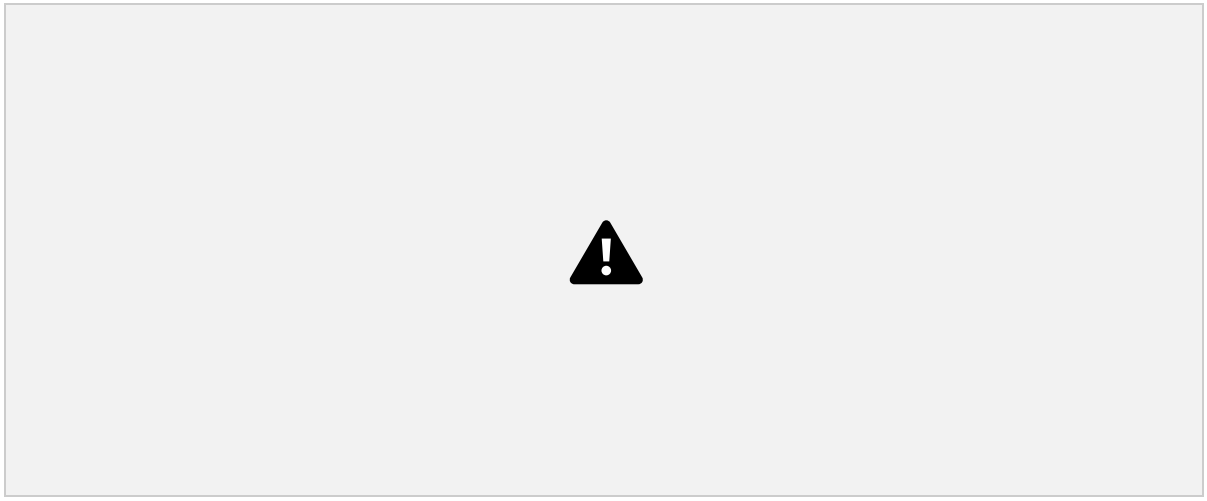
Alegeți o opțiune:

a. 95, 95, 73

b. 32, 10, 95, 73, 65

c. 65, 95, 73

d. 95, 73



12.Care dintre următoarele reprezintă presupunerea simplificatoare pe baza căreia operează clasificatorul Naive Bayes?

Alegeți o opțiune:

a. Distribuția din care sunt extrase datele este Bayesiană

b.Exemplele unui set de date sunt considerate independente între ele

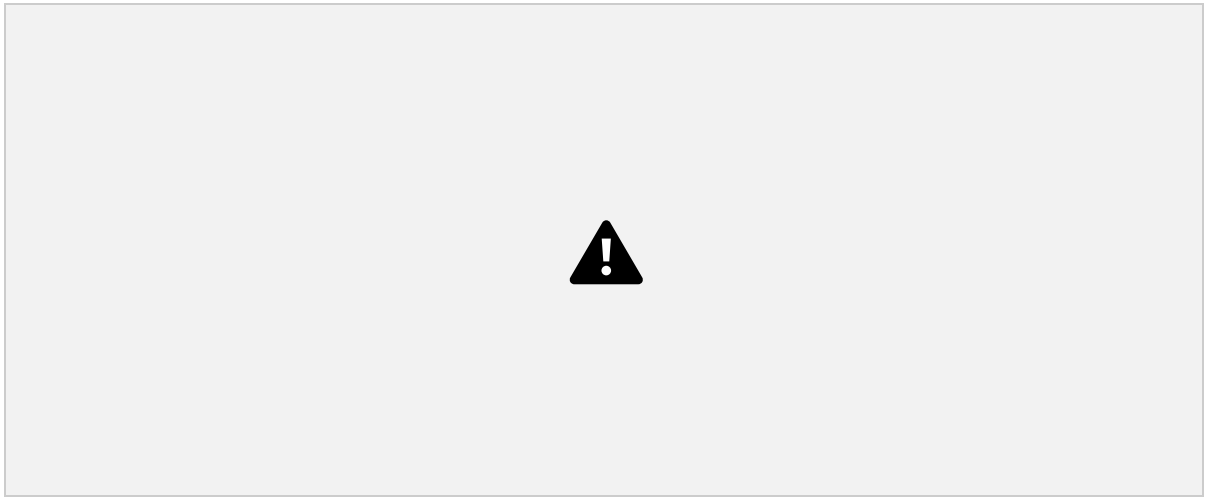
c. Atributele unui exemplu sunt considerate independente între ele

d. Distribuția din care sunt extrase datele este Gausiană

("To reduce the number of parameters, we make the Naive Bayes *conditional independence assumption* . We assume that attribute values are independent of each other given the class:")
https://nlp.stanford.edu/IR-book/html/htmledition/properties-of-naive-bayes-1.html

13.

Se considera urmatorul set de exemple:



Nr	Culoare	Tip	Productie	Se fura?
1	Rosu	Sport	Proprie	Da
2	Rosu	Sport	Proprie	Da
3	Rosu	Sport	Proprie	Da
4	Galben	Sport	Proprie	Da
5	Galben	Sport	Import	Da
6	Galben	SUV	Import	Nu
7	Galben	SUV	Import	Nu
8	Galben	SUV	Proprie	Da
9	Rosu	SUV	Import	Nu
10	Rosu	Sport	Import	Da

Aplicand algoritmul de invatare utilizand arbori de decizie, care este înalțimea minimă a arborelui?

Alegeți o opțiune:

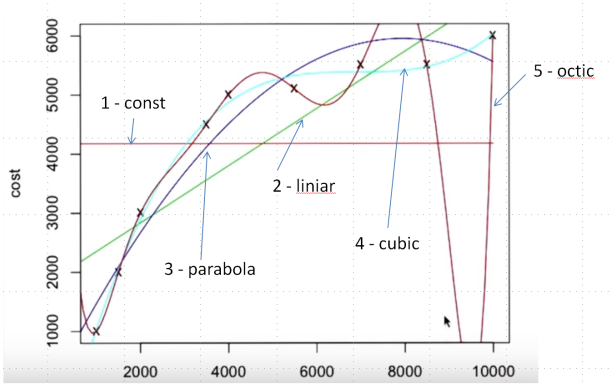
a. 3

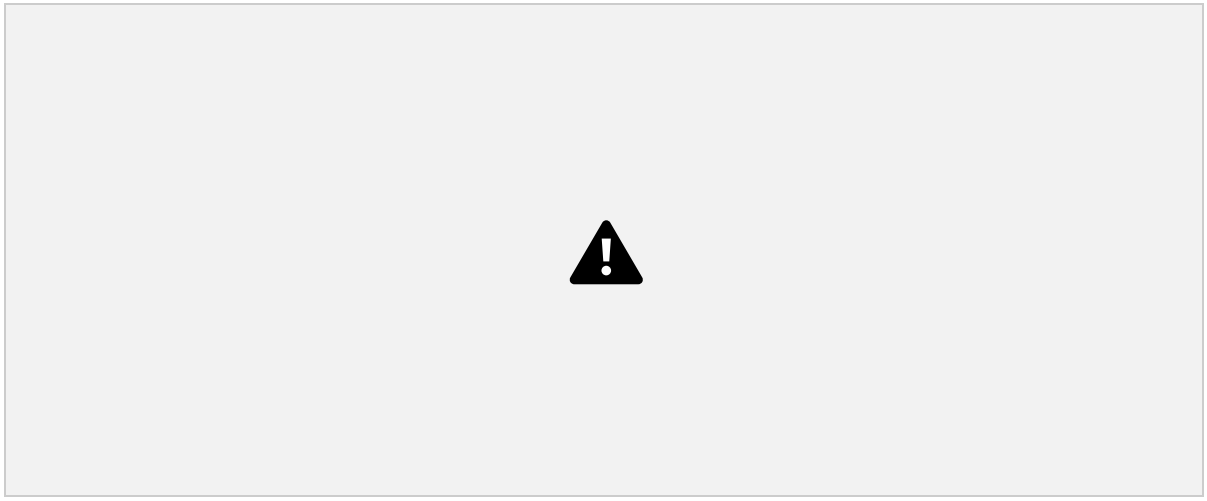
b. 1

c. 2

d. 4

Care curba trebuie aleasa pentru o buna predictie pe baza datelor existente in graficul urmator, folosind regresiei liniara?





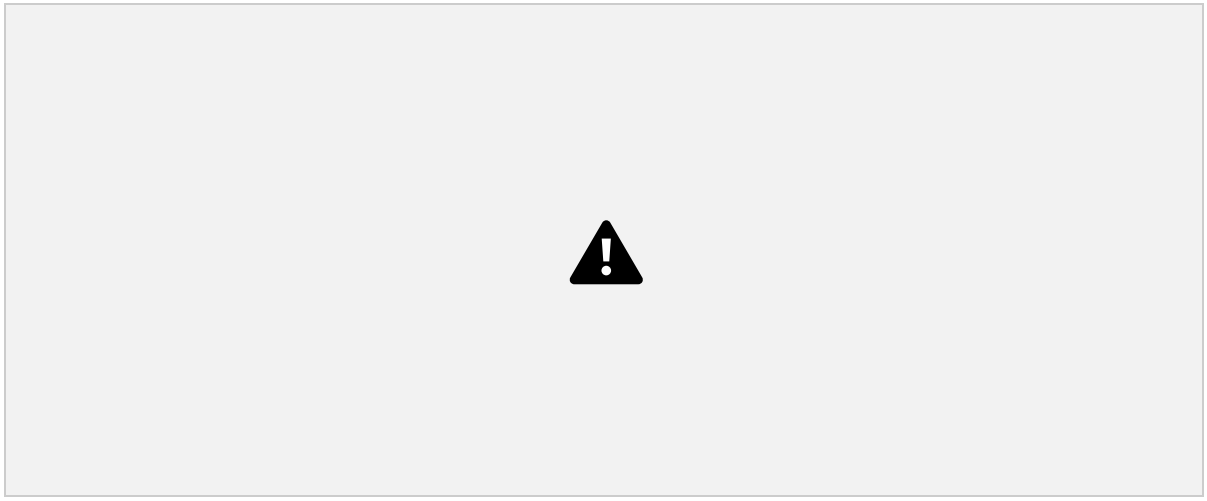
Alegeți o opțiune:a. 2

b. 3

c. 5

d. 1

e. 4



14. Dorim sa rezolvam o problema de clasificare binara. Avem 2 clase, fiecare clasa cu 500 de exemple. Datele sunt liniar separabile.

Care este numarul maxim si minim de vectori suport?

Alegeți o opțiune:

a. minim - 1000, maxim - 1000

b. minim - 500, maxim - 500

c. minim - 2, maxim - 1000 -- maybe? Asta zic si eu

d. minim - 250, maxim - 500

15.Regularizarea regresiilor liniare și logistice presupune

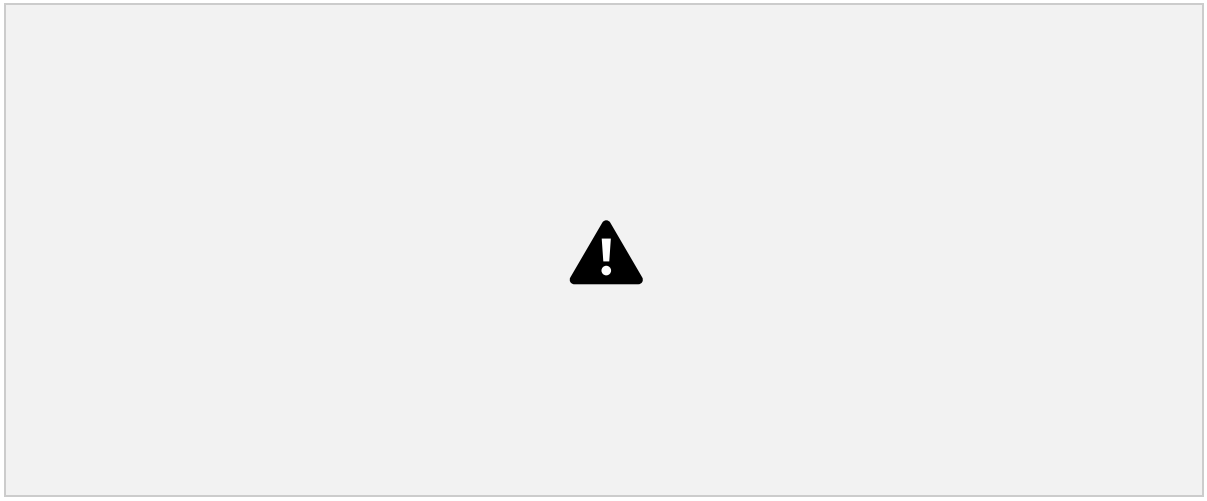
Alegeți o opțiune:

a. Transformarea spațiului de intrare într-unul mai complex

b. Creșterea dimensiunii setului de antrenare prin adăugarea de noi exemple

c. Adăugarea unui termen în funcția de cost care penalizează ponderile cu valori mari

d. Selectarea acelor atribute ale datelor de intrare care sunt mai informative



16.Un set de date utilizat pentru învățare supervizată are o valoare mare a entropiei informaționale dacă:

Alegeți o opțiune:

a. Numărul de exemple din fiecare clasă este relativ similar

b. Toate exemplele fac parte din aceeași clasă

c. Foarte multe dintre exemple aparțin unui număr mic de clase, în timp ce restul de clase au un număr mic de exemple. (cam asta ar fi)

17. Consideram urmatorul set de dat perechi (x,y):

(0,12) (1,13.5) (2,15) (3,16.5) (4,18) (5,19.5) (6,21)

Care functie descrie o regresie liniara pentru aceste date?

Alegeți o opțiune:

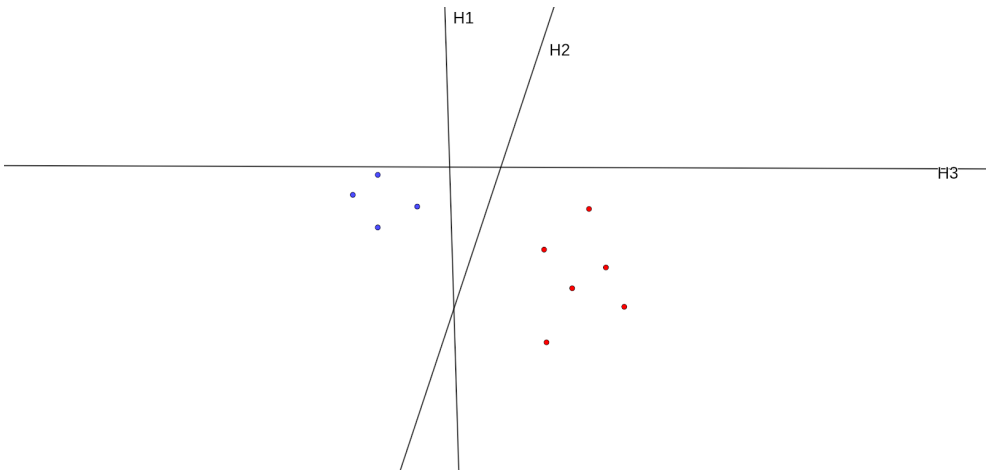
a. y=0.6x+8

b. y=2.5x+12

c. y=1.5x+12

d. y=12x+5

18.Avem un set de date cu 2 clase -- punctele rosii si albastre. Punctele si posibile hiperplanuri de separare sunt plotate mai jos. Care ar fi cel mai bun hiperplan de separare (dintre cele 3: H1, H2, H3)?



Alegeți o opțiune:

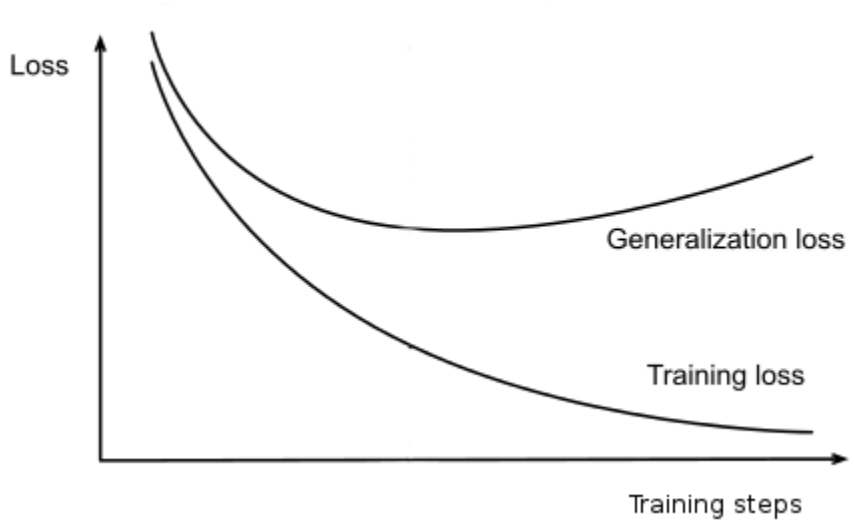
a. H3

b. H1

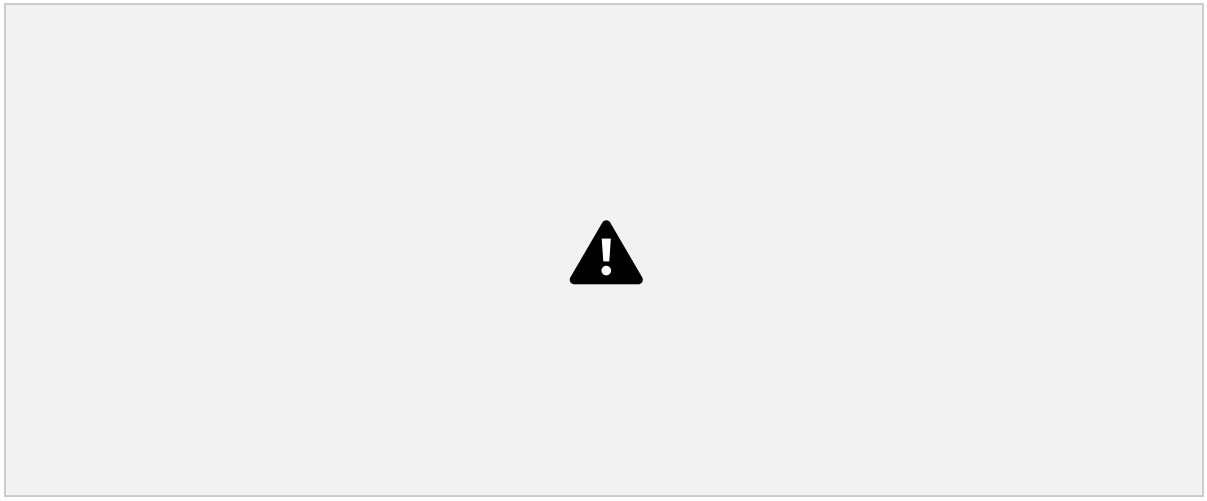
c. H2

d. Nu exista un hiperplan de separare

19. Curbele de învățare ale unui arbore de decizie arată ca în figura de mai jos



unde la fiecare pas de antrenare modelul vede mai mult din date.



Ce afirmație este adevărată cu privire la regimul de performanță în care a ajuns modelul?

Alegeți o opțiune:

a. Modelul este în regim optim

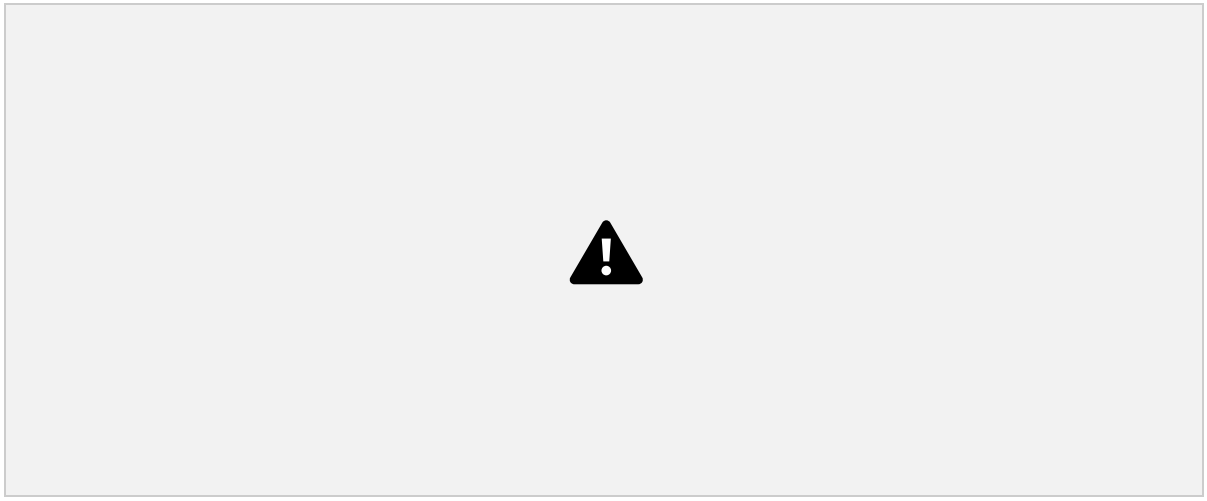
b. Modelul este în regim de underfitting (sub-potrivire)

c. Modelul este în regim de overfitting (supra-potrivire)

20.

In cazul algoritmului C4.5 daca avem valori necunoscute pentru un atribut in anumie exemple de invatare trebuie sa

Alegeți o opțiune:



a. atribuim acelui atribut valoarea cu cea mai **mare** frecventa din exemplele de invatare

b. atribuim acelui atribut valoarea cu cea mai mica frecventa din exemplele de invatare

21. Care este transformarea Φ(q) care corespunde Kernelului

Care este transformarea $\phi(q)$ care corespunde Kernelului

$K(a,b) = \phi^T(a)\,\phi(b) = a_1^2b_1^2 + 2a_1a_2b_1b_2 + a_2^2b_2^2$

$[q_1 \quad q_2 \quad \sqrt{2}q_1^2 \quad \sqrt{2}q_2^2]$

a

$[1 \quad q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 \quad \sqrt{2}q_2]$

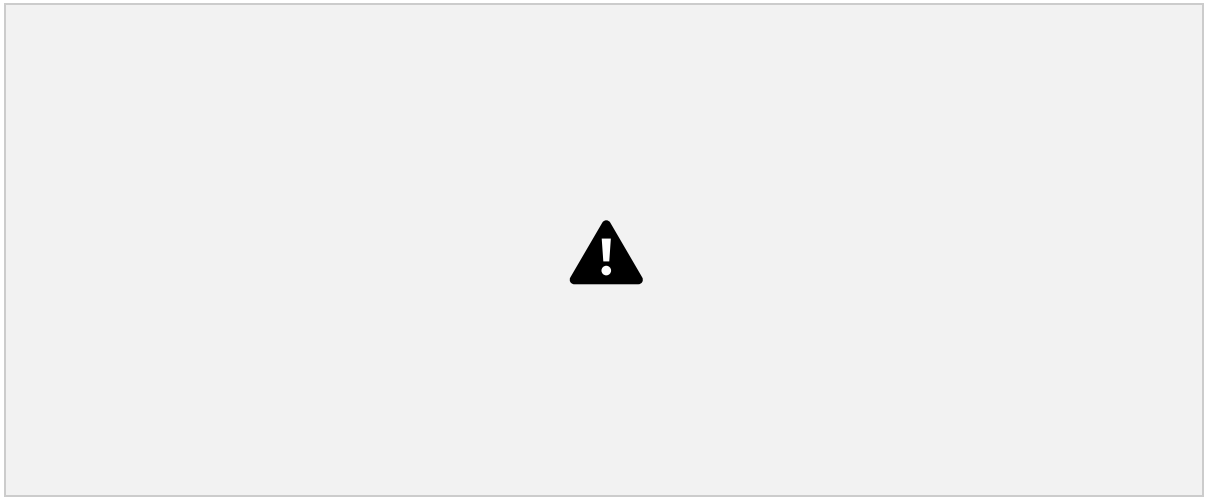
b

$[q_1 \quad q_2 \quad q_1^2 \quad q_2^2]$

c

$[1 \quad q_1^2 \quad q_2^2 \quad \sqrt{2}q_1 \quad \sqrt{2}q_2 \quad \sqrt{2}q_1q_2]$

d



$[q_1^2 \quad q_2^2 \quad \sqrt{2}q_1q_2]$ e varianta finala

22. Care dintre următoarele reprezintă criterii de oprire pentru construcția arborelui de decizie cu algoritmul ID3. Alegeți opțiunile corecte dintre:

1. Toate exemplele din subset fac parte din aceeași clasă
2. Câștigul informațional ajunge să fie negativ
3. Nu mai există atribute valide cu care să creăm un nod test
4. Adâncimea maximă este atinsă
5. Câștigul informațional depășește un anumit prag

Alegeți o opțiune:

a. 1

b. 1, 2 și 3

c. 1, 3 și 4(1 si 3 sigur, 4 nu sunt sigur)

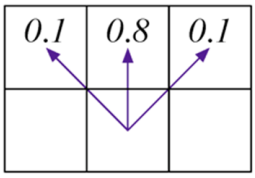
d. 1 și 4

e. 4 și 5

Fie problema MDP. Se considera un grid cu 2 linii si 3 coloane, in care un agent se poate deplasa in directiile sus, jos, stanga, dreapta. Pentru fiecare stare recompensele sunt date in figura a). Deplasarea in grid va avea loc daca agentul ramane in grid. In caz contrar agentul va ramane pe loc. Deplasarea in directia aleasa se va face cu probabilitatea 0.8. Cu probabilitati 0.1, respectiv 0.1 agenul se va deplasa de-a lungul celor doua diagonale care incadreaza directia de deplasare aleasa (ca in figura b).

S1 (R=0)	S2 (R=0)	S3 (R=10)
S4 (R=0)	S5 (R=0)	S6 (R= -5)

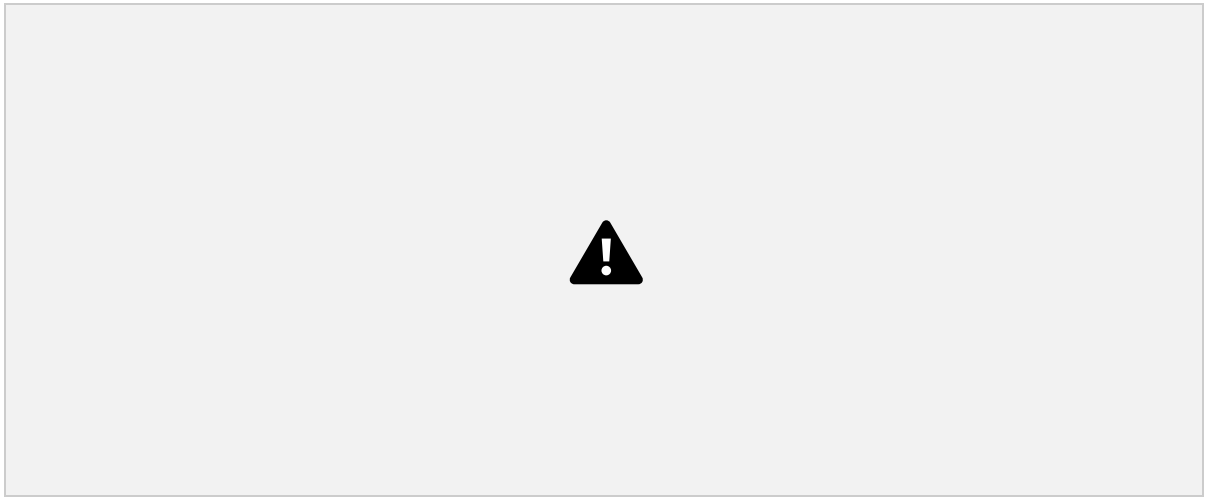
a)



b)

Dupa un numar de episoade utilitatile starilor sunt: U(S1) = 5, U(S2) = 7, U(S3) = -3, U(S4) = 2, U(S5) = 4, U(S6) = =-6.

Care este utilitatea starii S5 pentru pasul urmator, avand factorul de atenuare = 0.9.



Alegeți o opțiune:

a. 5.22

b. 5.4

c. 2.57

d. 0.7

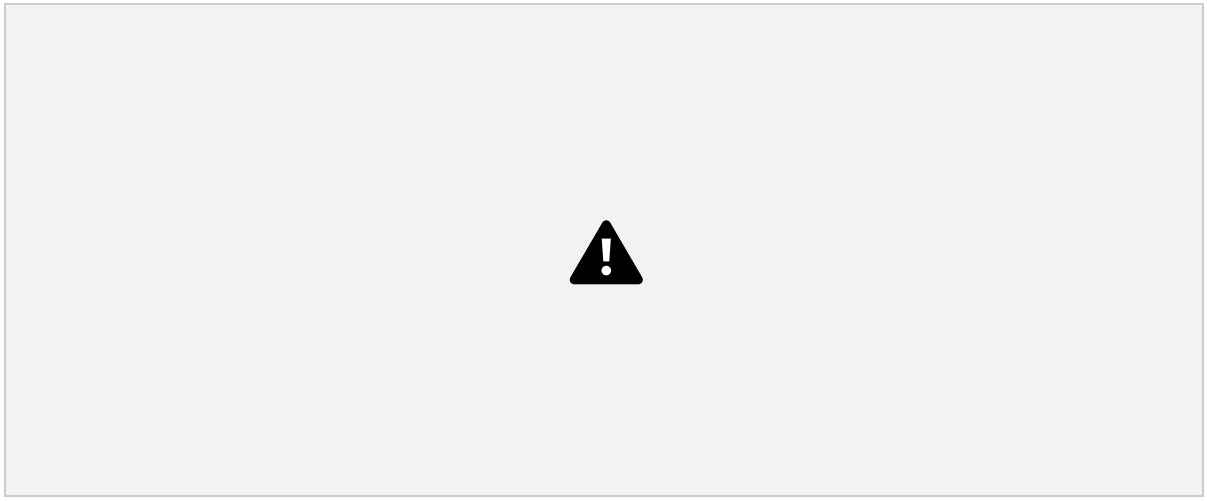
e. 4

Procedura de cross-validation este folosită des pentru a găsi o valoare bună a hiperparametrilor unui model de învățare. În urma procedurii, se poate raporta o medie și o varianță a diferitelor modele (i.e. a instanțelor de model, pentru fiecare combinație de hiperparametrii).

Ce fel de modele vor fi preferate?

Alegeți o opțiune:

a. Modele cu medie mică și varianță mică

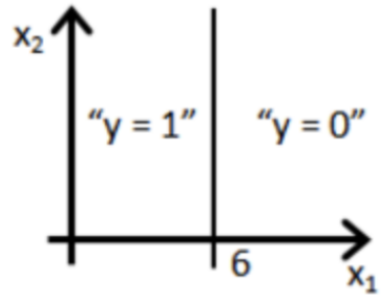


b. Modele cu medie mare și varianță mică

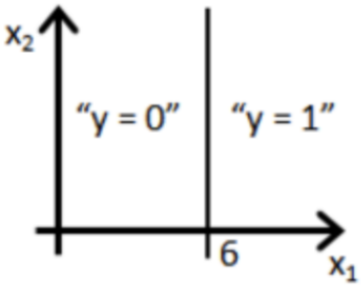
c. Modele cu medie mică și varianță mare

d. Modele cu medie mare și varianță mare

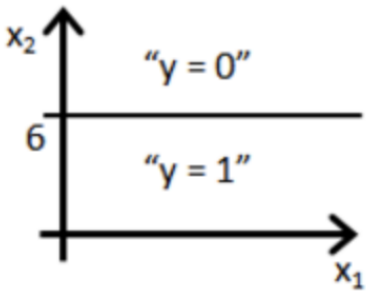
In urma antrenarii unei regresii liniare multi variabile, se obtine h(x) = -6 + 1*x1+0*x2. Care dintre figurile urmatoare este asociata acestei clasificari?



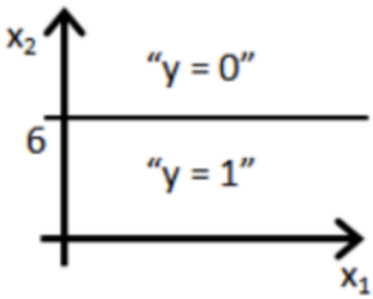
A.



B.



C.

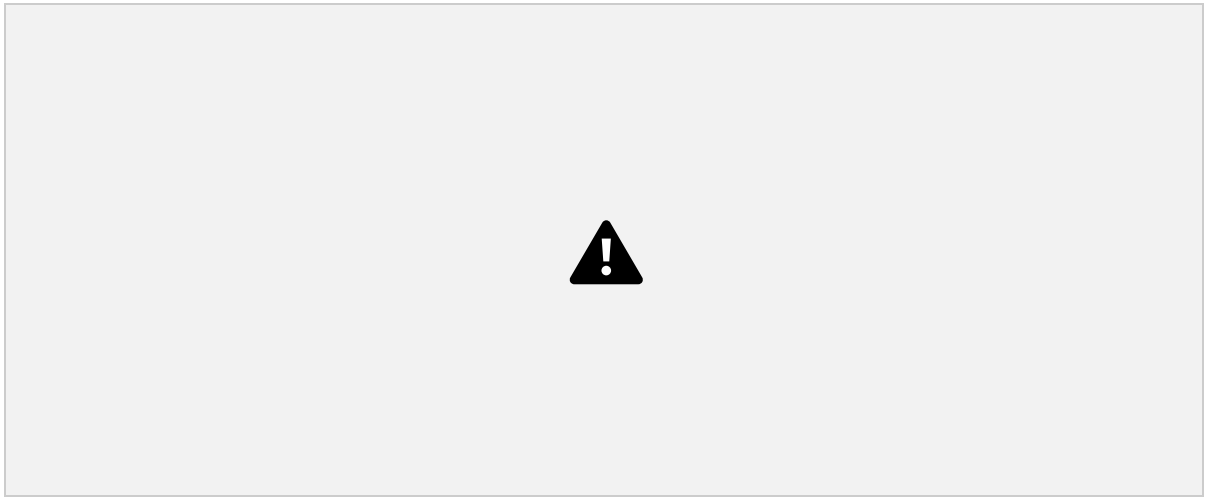


D.

Alegeți o opțiune:

a. B(cred)(sigur)

b. C



c. D (jos de tot https://www.cnblogs.com/maxiaodoubao/p/9879284.html)

Nu e bine. In link ai fct h = -6 + 0*x1 + 1*x2. Noi avem h = -6 + 1*x1 + 0 * x2

Da, e transpusa, atunci e b-ul

d. A

Se dau următoarele două afirmații despre modelele de tip Gradient Boosted Trees.

1. Clasificatorii slabi (weak learners) sunt independenți unul de celălalt
2. Metoda Gradient Boosted Trees obține performanțe mai bune prin agregarea rezultatelor obținute de clasificatorii slabi (weak learners)

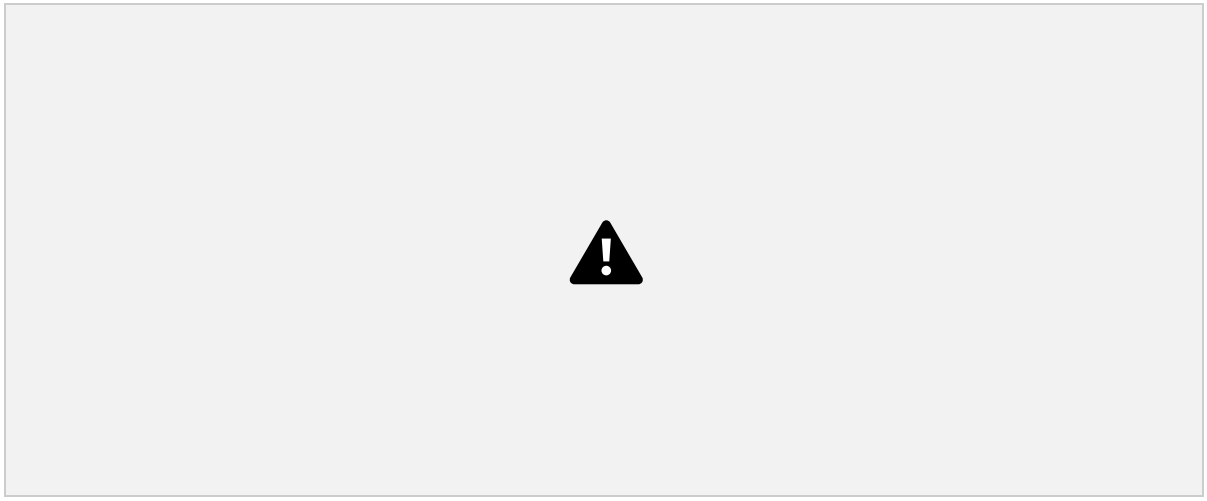
Care dintre cele două afirmații sunt adevărate:

Alegeți o opțiune:

a. 2

b. Nici una

c. 1 și 2



d. 1

Care dintre urmatoarele afirmatii este adevarata?

(a) O functie Kernel calculeaza un produs scalar intr-un un spatiu de dimensiune mai mare fata de spatiu de intrare

(b) Functia Kernel este o functie de similaritate

Alegeți o opțiune:

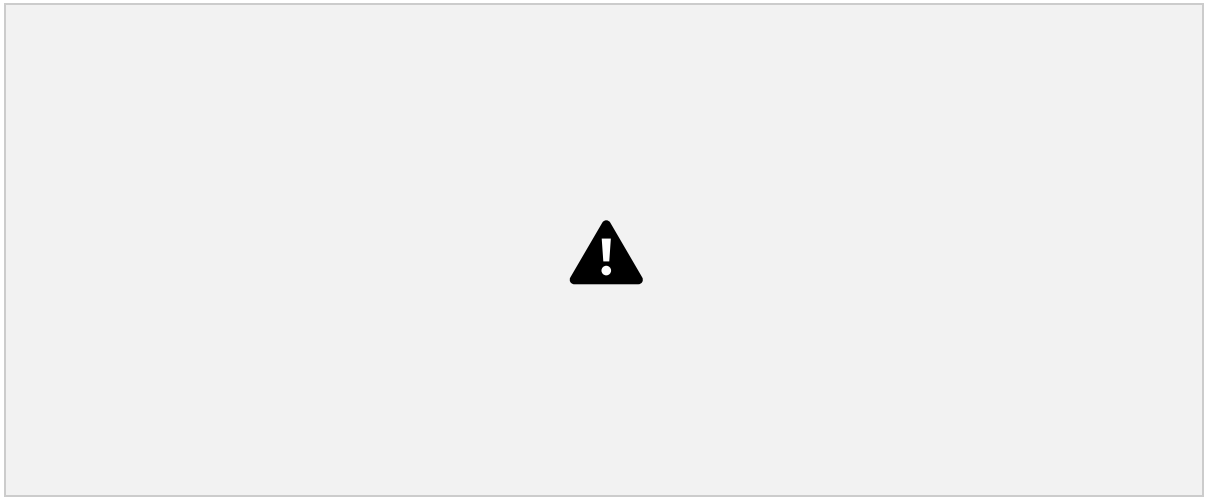
a. Nici una

b. (a) (pacaleala) :(

c. (b)

d. (a) si (b) (aflat dupa test din raspunsuri)

Intr-un arbore de decizie pentru clasificarea unor exemple care contin atribute cu valori continue, are sens sa repetam pe o anumita ramura a arborelui (cale de la radacina la o frunza) un acelasi atribut ?



Selectați o opțiune:

a) Adevărat <- asta era corect
b) Fals

https://stackoverflow.com/questions/19993139/can-splitting-attribute-appear-many-times-in-decision-tree

---

In urma antrenarii unui SVM, sunt gasiti 3 vectori suport.

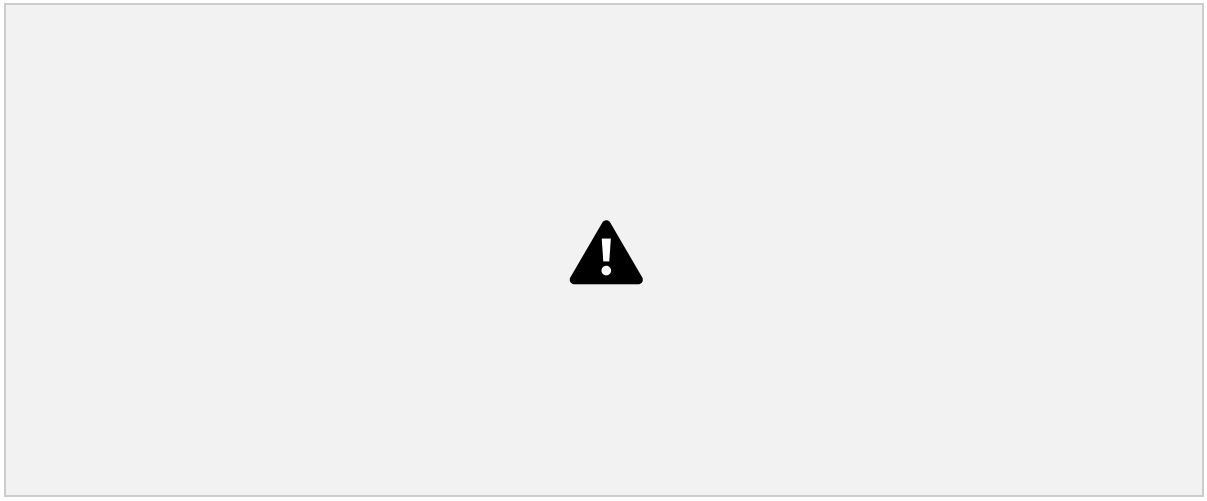
Dupa ceva timp mai gasim inca un set de date cu aceleasi caracteristici si clase ca setul folosit initial (cele 2 seturi de date nu contin intrari identitce).

Antrenam SVM-ul folosind celor 2 seturi de date (setul reunit este inca liniar separabil), insa in urma procesului vectorii suport nu se schimba.

Care afirmatie este adevarata?

Alegeți o opțiune:

a. performanta noului model e mai buna ca a celui antrenat doar pe setul initial de date(cred) (nope)
b. antrenarea folosind doar al doilea set de date ar avea ca rezultat vectori suport diferiti (cred ca asta totusi, daca se face antrenare pe setul doi de date si punctele



din el nu erau vectori suport in primul caz, atunci fara setul 1 de date trebuie sa apara alti vectori suport) (asta era)

c. antrenarea SVM-ului folosind doar al doilea set de date va da mereu un hiperplan de separere diferit de cel initial

---

In regresia logistica se folosesc:
(a) Distributie Bernoulli
(b) Distributie categoriala
(c) Distributie binomiala
(d) Distributie multinomiala

Alegeți o opțiune:

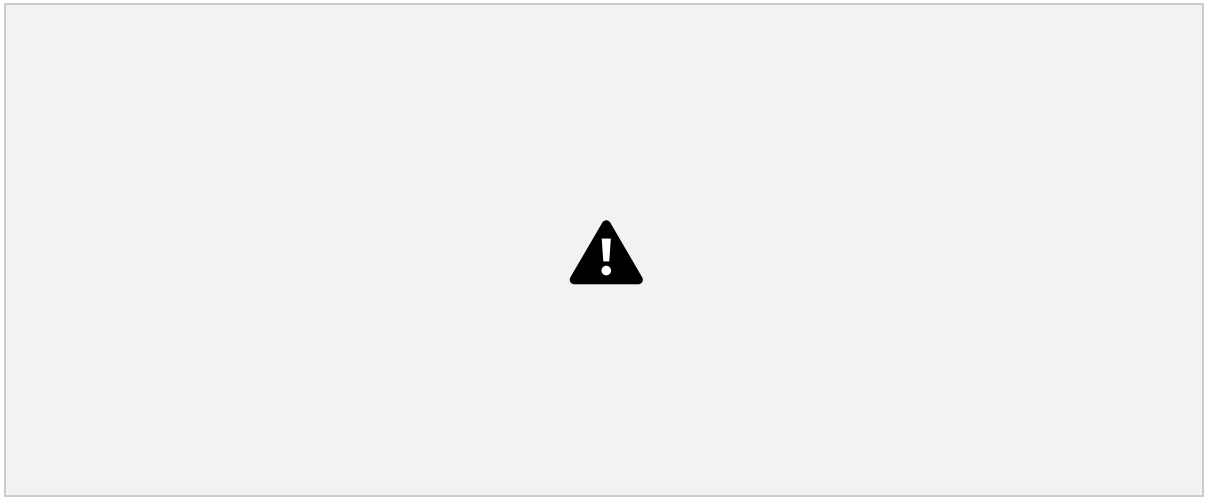
a. (c) + (d)

b. (a) + (b) + (c)

c. (b) + (c)

d. (a) + (b)

e. (a) + (c)



TEST 24.04.2020

https://drive.google.com/open?id=148MoDGskdlNjVKa9JuTFoA8G-Y--VSlI9f5YLuM8CVA

Doamne ajutaa. Numa bine

Care este motivul pentru care utilizăm activări neliniare în rețele neurale artificiale?

a.Activările trebuie limitate într-un domeniu ușor de gestionat (e.g. (-1,1) sau (0,1)) pentru a evita fenomenele de *vanishing/exploding gradients*.

b.Spațiile descrise de datele de intrare sunt întotdeauna neliniare.

c.

Ieșirile rețelei trebuie să fie neliniare pentru a putea fi utilizate în calculul funcției de eroare.

d.

Dacă s-ar utiliza doar activări liniare, prin compoziționalitate rețeaua ar echivala cu o funcție liniară. asa cred

Care afirmație este adevărată în cazul utilizării de straturi de tip *Batchnorm* în cadrul arhitecturii unei rețele adânci.
a.Valorile activărilor de pe straturi se stabilizează prin normalizarea acestora (per-canal), accelerând astfel procesul de antrenare. Asta? (aparent da, dupa ce au aparut rezultatele :)))
b.Valorile gradienților nu mai fluctuează de la un mini-batch la altul stabilizând astfel antrenarea.
c.Ponderile de pe straturi nu mai cresc la valori foarte mari ele fiind stabilizate de straturile Batchnorm.
d. Valorile ponderilor neimportante scad pe măsură ce se realizează mai mulți pași de învățare.

Intr-o retea SOM, care raspunsuri sunt adevarate pentru U-matrix:

a.Reda distanta intre neuroni adiacenti care este calculata si redata sub forma de diferite culori
b.O culoare inchisa intre neuroni corespunde unui gap intre ponderi si spatiul de intrare
c.Toate raspunsurile sunt corecte (asa zic si eu) +1 +1
d. Permite vizualizarea distantei dintre neuroni

Care afirmație este adevărată despre regularizarea L2 a rețelelor adânci.

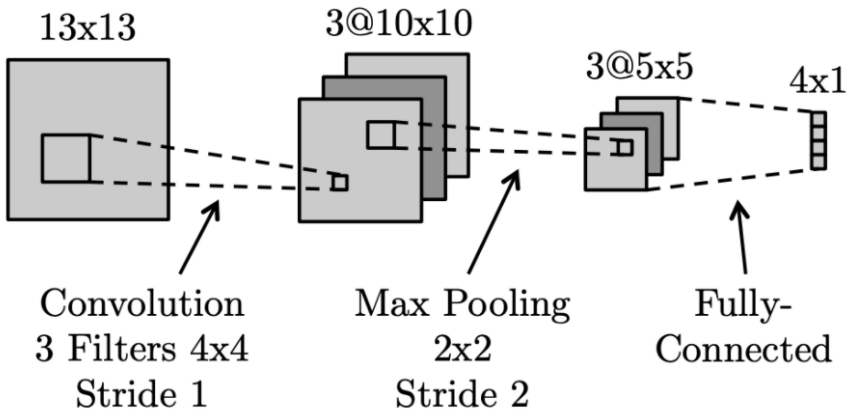
a.
Activările sunt normalizate la nivel de mini-batch evitând astfel valori mari care să influențeze puternic decizia și reducând overfit-ul.

b.
Fenomenul de overfit este estompat în timpul învățării deoarece (în medie) valorile ponderilor neimportante sunt micșorate, reducându-se astfel contribuția zgomotoasă a acestora la activările rețelei.

c.
Ajută la aducerea valorilor pentru ponderile rețelei mai aproape de setului unic de valori care rezolvă optim task-ul (minimizează funcția de loss).

d.
Împiedică apariția optimelor locale ducând astfel la o generalizare mai bună a rețelei.

Fie următoarea rețea adanca cu straturile: convolutional, max pooling, fully connected.



Numărul de ponderi asociate stratului convolutional este:

a.

30

b.

169

c.

48

Care este ieșirea unui neuron care are ponderile [3, -1, 2] și bias 2 pentru intrarea [7, 9, 10]?

a.

30

b.

34

c.

37

d.

32

Care dintre următorii indivizi nu reprezintă un posibil copil obținut printr-o operație de recombinare multi-punct între părinții de mai jos?

părinte 1: 0 0 1 1 0 1 0 1 1 1

părinte 2: 1 1 0 1 0 0 1 0 0 0

a.

0 0 1 1 0 0 0 1 0 0

b.

0 0 0 1 0 1 1 0 0 0

c.

1 0 1 1 0 1 1 0 0 0

d.

1 1 0 0 0 0 0 1 1 1 +1 +1

Cum se poate preveni problema *vanishing gradients* în rețelele neurale adânci?

a.Prin introducerea de conexiuni reziduale între straturi

b.Prin adăugarea mai multor straturi convoluționale în rețea

c.Prin creșterea numărului de parametri în straturi

Alegeți afirmația greșită:

a.Ieșirea unui funcții treaptă pentru intrarea [-1, 2, 0, 4, -3] este [-1, 1, 1, 1, -1]
b.Ieșirea unui funcții sigmoid pentru intrarea [-1, 2, 0, 4, -3] este [0.26, 0.88, 0.5, 0.98, 0.04]
c.Ieșirea unei funcții ReLU pentru intrarea [-1, 2, 0, 4, -3] este [0, 2, 0, 4, 0]
d. Ieșirea unui funcții tanh pentru intrarea [-1, 2, 0, 4, -3] este [0.83, 0.16, 0, 0.22, -0.45] (+1)

Alegeți afirmația corectă:

a.

Probabilitatea operației de mutație crește odată cu lungimea indivizilor.

b.

Operația de mutație adaugă gene noi la genele existente pe care le are un individ.

c.

Operația de mutație schimbă întotdeauna valorile genelor unui individ.

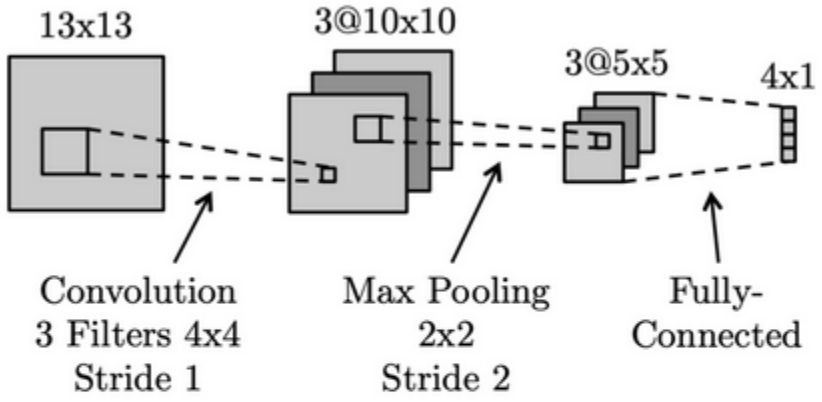
d.

Operația de mutație se aplică asupra descendenților.

Intr-o rețea perceptron, putem renunța la bias în calculul activării dacă îl considerăm ca pondere conectată la o falsă intrare cu valoare constantă?

Select one:
True
False

Fie următoarea rețea adanca cu straturile: convolutional, max pooling, fully connected.



Numărul de ponderi asociate stratului convolutional este:

- a. 30
- b. 169
- c. 48

4 * 4 * 3 = 48

Câți parametrii trebuie să învețe un layer de Average Polling cu dimensiunea kernel-ului de 2 și pas de 2?
Select one:
a.

2

b.

4

c.

3

d. 0 +1 ca ala nu invata

Straturile de tip Average Pool sunt utilizate în arhitecturile de rețele neuronale artificiale adânci cu scopul de a

Select one:

- a. Reduce zgomotul din rețea prin efectuarea mediei activărilor
- b. Reduce dimensiunea activărilor de la ieșirea unui strat înainte de a fi trimis stratului următor
- c. Îmbunătăți calitatea informației care este propagată prin rețea.
- d. Întări corelațiile care se întâmplă la nivel local.

Fie un strat de convolutie cu intrarea de dimensiune (7x7), filtru de dimensiune (3x3), stride = 1 (se ingnora a treia dimensiune, nu exista padding). Specificati dimensiunea ieșirii stratului convolutional.

Select one:
a.

3x3

b.

7x7

c.

5x5

Ce s-ar întâmpla într-o rețea neuronală artificială dacă am utiliza funcția de activare y = 2x, unde x este intrarea de pe un strat și y este ieșirea acestuia?

Selectați răspunsul corect:

a.Ponderile s-ar micșora considerabil.

b.Ar fi imposibil ca rețeaua să mai învețe să rezolve o problemă de clasificare sau regresie

c.Valorile de la output ar deveni foarte mari

d.Întreaga rețea s-ar putea reduce la o combinație liniară a intrărilor.

O rată de învățare foarte mare nu avantajează antrenarea unei rețele neuronale artificiale deoarece:

Select one:

a.

Reducem prea mult numărul de iterații necesari antrenării rețelei.

b.

Ieșirile de pe fiecare strat vor avea valori foarte mari.

c.

Derivatele în raport cu eroarea vor avea valori foarte mici.

d.

La fiecare pas de optimizare ponderile vor fi modificate prea mult corespunzător cu batch-ul curent de exemple de învățare (în raport cu restul setului de date). ++

Straturile de tip Average Pool sunt utilizate în arhitecturile de rețele neuronale artificiale adânci cu scopul de a

Select one:

a.

Reduce zgomotul din rețea prin efectuarea mediei activărilor

b.

Îmbunătăți calitatea informației care este propagată prin rețea.

c.

Întări corelațiile care se întâmplă la nivel local.

d.

Reduce dimensiunea activărilor de la ieșirea unui strat înainte de a fi trimis stratului următor

Partea 2

Wtf coaie? PULA

Explicați care este legătura între utilizarea legăturilor reziduale în rețele neurale adânci și tehnicile de boosting.

Legaturile reziduale iau informate din urma, prin intermediul skip-connections. Astfel, antrenarea de la blocul k este adusa si combinata cu antrenarea de la blocul k + 1. Intr-un mod similar functioneaza si boostingul, in care modelul i continua antrenarea din punctul in care "ramasese" modelul i - 1.

https://stats.stackexchange.com/questions/214273/are-residual-networks-related-to-gradient-boosting

Explicați legătura dintre presiunea de selecție din algoritmii genetici și balanța *explorare vs. exploatare* a acestora. Dați exemple de 2 mecanisme de selecție și felul în care acestea o influențează.

Presiunea de selectie inseamna probabilitatea de selectie a celui mai bun individ comparata cu probabilitatea medie de selectie a tuturor indivizilor. Astfel, cand presiunea este mare, probabilitatea de selectie a celui mai bun individ este mare, deci este vorba de exploatare. In caz contrar, toti indivizii au probabilitati de selectie apropiate, deci se prefera explorarea.

Doua mecanisme de selectie: selectia pe baza de ruleta, esantionare universala stohastica

Care este ieșirea unui strat softmax care primește la intrare vectorul de mai jos?

4 8 1 2 5

$$P(Y = k|X = x_i) = \frac{e^{s_k}}{\sum_j e^{s_j}}$$

e^4 / (e^4 + e^8 + e^1 + e^2 + e^5) . si la fel si pestu restul nu ?

P1 = 1.72%? :)))

Etc…

softmax_j = e^z_j / sum(e^z_k) cu j = 1,k

softmax_1 = e^4 / (e^4 + e^8 + e^1 + e^2 + e^5) = 0.017093562956559

softmax_2 = e^8 / (e^4 + e^8 + e^1 + e^2 + e^5) = 0.93327691490319

softmax_3 = e^1 / (e^4 + e^8 + e^1 + e^2 + e^5) = 8.5103838756858E-4

softmax_4 = e^2 / (e^4 + e^8 + e^1 + e^2 + e^5) = 0.0023133621842487

softmax_5 = e^5 / (e^4 + e^8 + e^1 + e^2 + e^5) = 0.046465121568434

Verificati si voi

N experti trebuie sa decida daca un mesaj de email este SPAM (1) sau EMAIL (0). Obiectivul este să se determine o singură predicție per mesaj. In acest scop, doriți să implementați un mecanism de vot majoritar, adică dacă mai mult de jumătate dintre experți prezic SPAM, predicția finală trebuie să fie SPAM pentru acea instanță, in caz contrar, predicția finală trebuie să fie EMAIL.

(1) Construiti o retea neurala care implementeaza un astfel de vot majoritar pentru cazul a 4 experti, A, B, C si D. Indicati structura retelei, intari, iesiri, ponderi, valori de prag si functia de activare.

(2) Explicati pe scurt cum se poate generaliza reteaua la N experti

(3) Care model dintre o retea neurala si un arbore de decizie este mai potrivit pentru rezolvarea acestei probleme in cazul general in care N este mare ? Justificati raspunsul.

(4) Sa presupunem ca fiecare expert individual foloseste informatii complet diferite si fiecare expert are acelasi nivel de acuratete (85%) in clasificare pentru un set de exemple dat. Se poate imbunatati acuratetea in acest caz pentru setul de exemple folosind un mecanism de vot majoritar ? Justificati raspunsul.

Fie un strat de convoluție care are cele două filtre de mai jos:

1	2	-1
0	9	4
5	8	2

4	0	7
0	5	0
3	0	6

Care este ieșirea stratului de convoluție având ca intrare imaginea de mai jos, cu stride 2 și padding 1? Explicați pașii urmați pentru a obține răspunsul.

2	4	1	3	-2	5	9
1	1	1	3	2	1	7
6	0	5	-1	1	-1	4
3	1	1	2	7	8	6
2	5	9	9	8	4	6
0	0	0	0	0	0	0
-1	1	2	5	9	2	4

E ceva online care calculeaza asta? Nu cred ca vor ceva direct

Revin cu rezultat :D Hai ca e nesimtita Foarte

Mirel

Avand padding 1, intrarea va fi bordata pe fiecare latura cu o coloana/ un rand plin de elemente egale cu 0.

Avand stride 2, fiecare filtru va avansa in input din 2 in 2 pozitii (atat pe verticala, cat si pe orizontala)

Pentru fiecare filtru, folosim urmatoarele formule

Hout = (H_in + 2 * padding - dilatation * (kernel_size - 1) - 1) / stride + 1

Analog pentru Wout

Astfel, imaginile rezultate vor avea fiecare dimensiunea 4x4. Astfel, avand 2 canale (2 filtre), vom avea ca iesire 4x4x2 (H x W x C).

Canalul 1:

- primul element: 1*0 + 2*0 + (-1)*0 + 0*0 + 9*2 + 4*4 + 5*0 + 8*1 + 2*1 = 0 + 0+ 0 + 0 + 18 + 16 + 0 + 8 + 2 = 44

- al doilea element: 1*0 + 2*0 + (-1)*0 + 0*4 + 9*1 + 4*3 + 5*1 + 8*1 + 2*3 = 0 + 0 + 0 + 0 + 9 + 12 + 5 + 8 + 6 = 40

Canalul 2:

- primul element: 4*0 + 0*0 + 7*0 + 0*0 + 5*2 + 0*4 + 3*0 + 0*1 + 6*1 = 0 + 0 + 0 + 0 + 10 + 0 + 0 + 0 + 6 = 16

- al doilea element: 4*0 + 0*0 + 7*0 + 0*4 + 5*1 + 0*3 + 3*1 + 0*1 + 6*3 = 0 + 0 + 0 + 0 + 5 + 0 + 3 + 0 + 18 = 26

Explicati rolul regularizarii in retelele adanci. Specificati asupra caror parametri se aplica regularizarea. (SCRIETI SI VOI ALTFEL, ATAT M-A DUS PE MINE CAPUL)

Regularizarea are rolul de a constrange influenta ponderilor cu valori foarte mari asupra iesirii.

Refularizarea se aplica asupra ponderilor // e bine(reformulati)

Intr-un algoritm genetic se considera urmatorii doi parinti:

p1: 128 255 50 17 2 si

p2: 123 4 344 280 12.

Construiti cei doi copii obtinuti prin recombinare reala discreta avand

sample1: 2 2 1 1 2 si

sample 2: 1 2 1 1 2.

c1: 123 4 50 17 12

c2: 128 4 50 17 12

Check this. E bun yap

Explicați de ce rețelele convoluționale sunt invariante la translație dar nu și la rotație sau scalare. Cum putem ameliora aceste neajunsuri?

Invarianta la trnaslatie presupune ca indiferent de pozitia unui obiect intr-o imagine (presupunand o problema de computer vision), acesta va fi tratat (de exemplu detectat) la fel de o retea convolutionala. Totusi, daca am roti obiectul sau i-am modifica dimensiunea, rezultatele retelei s-ar schimba din cauza ca filtrele care se aplica unei retele gasesc patternuri intre pixeli apropiati, indiferent de pozitia acestora in imagine, dar nu si de orientarea lor. De exemplu, un filtru care detecteaza linii drepte, precum cel de jos:

0 10

0 10

nu ar detecta nimic daca am intoarce o imagine cu linii drepte la 90 de grade. Cat despre invarianta la scalare, o imagine mai mica, de exemplu, ar avea un numar mai mic de pixeli si, implcicit, mai putine date pentru retea.

9Exams.ro: Test Final Invatare automata

1)invatarea pac.ce inseamna o ipoteza de invatare aproximativ corect, ce inseamna o ipoteza de invatare probabil aproximativ corecta. Explicati semnificatia celor 2 notiuni pentru invatarea automata si explicati diferentele intre acestea.

2)fie un svm si urmatoarele exemple de invatare (multimi de antrenare):
clasa 1 (1 1) (1 2) (2 1)
clasa 2 (0 0) (1 0) (0 1)
indicati care sunt vectorii suport si gasiti marginea care separa optim clasele

3)Se poate aplica un SVM liniar in cazul unei multimi de antrenare in care exemplele sunt afectate de zgomot . Si daca nu, cum poate fi modifcat SVM-ul astfel incat sa poata face clasificarea in acest caz. Explicati.

4)Intr-o retea de tip SOM(Self organizing maps) , nu numai unitatea castigatoare este mutata catre exemplu dar si unitatile din vecinatatea acesteia. De ce este acest aspect important in metoda de invatare?

5)2 indivizi reprezentati binar,2 masti, sa se aplice crossover uniform

6) 4 biti cu probabilitate de mutatie 10%.care e probabilitatea de supravietuire a individului

7) Operatorul de eliminare a unui exemplu negativ la algoritmi genetici pentru invatarea regulilor de decizie

“Subiecte din folclor” sem 2, ÎA - lucrare1

1. Sa se proiecteze o retea neurala care spune daca suma a 2 cifre(0<=cifra <=7) este mai mare ca 8.

R:

x1 ---(w1 = 1)---> |
|-> ** O = 9 ** -----> ** y = f(w1 * x1 + w2 * x2 - O) **
x2 ---(w2 = 1)---> |

f(x) = 1, pentru x > 0
0, altfel

O este “theta”, x1/2 sunt intrari, ce este intre “**” sunt neuroni

Î: Theta nu ar trebui sa fie 8 conform cerintei?
R: Pai zice > 8, nu >= 8.
Î: Domeniul cifrei conteaza la ceva?
R: DA / daca era binar

2. Care e conditia de convergenta la algoritmul de invatare al perceptronului? Dar la Hopfield?
R: In cazul perceptronului, invatarea se opreste atunci cand eroare este 0, cand diferenta dintre iesirea oferita de perceptron si valorile dorite pentru diverse intrari sunt identice. (Cand toate exemplele sunt clasificate corect)
Reteaua Hopfield converge atunci cand se ajunge intr-un minim local energetic, cand niciun neuron nu doreste sa isi schimbe starea. *Adica atunci cand iesirea fiecarui neuron la momentul t+1 este aceeasi ca cea la momentul t, nu? DA :)*

3. Care e diferenta intre TD si Q-learning?
R: In cazul TD politica este fixa, agentul trebuie sa invete utilitatea starilor. La Q-learning agentul invata si actiuni(ceea ce trebuie sa faca). TD implica invatare pasiva, iar Qlearning invatare activa. Q-learning are o functie de explorare, mentine un tabel cu valorile Q.

4. Care este legatura intre stabilizarea unei retele Hopfield si un proces de cautare?
R: Pentru a cauta un anumit sablon intr-o retea neurala Hopfield deja antrenata, se initializeaza starea neuronilor conform sablonului dorit si se lasa ca reteaua sa se stabilizeze. Starea finala a neuronilor este sablonul rezultat in urma cautarii.

5. Exprimarea unor atribute ca valori continue in ID3.
R:
Solutia 1 (valori numerice)
Ordonez valorile atributului din SI. Partitionez in intervale $(A_i+A_{i+1})/2$, fiecare interval o valoare.
Solutia 2 (valori numerice)
Pt fiecare A_i, i=1,m imparte obiectele in (-infinit, A_i] si (A_i, + infinit)=> partitie P_i
Pentru fiecare P_i calculeaza castigul informational si selecteaza partitia cu castig informational maxim.
Solutia 3 (valori simbolice)
Utilizeaza Informatia de separare = cantitatea de informatie necesara pentru a determina valoarea unui atribut A intr-un set de invatare C.

6. Ce inseamna fenomenul de overfitting si in ce contexte apare? De ce apare la retele neurale?

R: “overfit”(overfitting) = ipoteza formata/gasita include zgomot sau sabloane de date irelevante.
Un algoritm backpropagation poate ajunge sa calculeze un set de ponderi care nu rezolva problema. Fenomenul de overfitting. Nr de ponderi care se invata / nr. de ponderi care influenteaza o iesire particulara < nr. de exemple.
Fenomenul apare atunci cand reteaua neurala incearca sa invete prea bine. Overfitting-ul este intalnit si la arborii de decizie atunci cand se incearca o clasificare mult prea ampla.(De respectat lema lui Occam.)

Overfitting = incercarea de a utiliza un model statistic cu prea multi parametrii
Multi parametrii care se potrivesc bine pe un numar restrans de exemple dar nu generalizeaza bine (e ok ce scrie la R :) Pai fix asa scrie in curs.

7. Care este conditia de convergenta in cazul unei retele backpropagation ?
R: Eroarea sa fie 0.
Aici cred ca nu e bine. Se ajunge la convergenta cand eroarea nu se mai schimba (gradientii la iesire devin 0). => Mult mai bine așa; dacă ar fi eroarea 0, se poate să nu se ajungă niciodată în acel **punct** și nu se va mai opri. :)

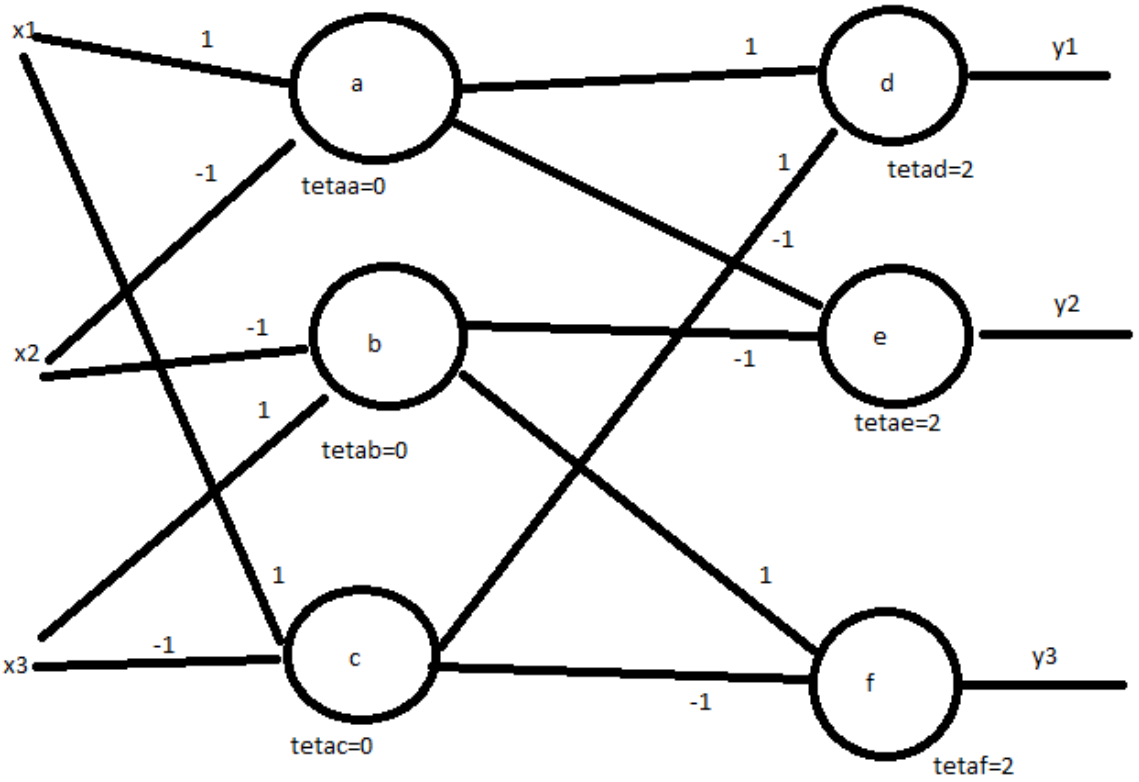
8. Care sunt aplicatiile cele **mai importante** ale unei retele Hopfield si pe ce principii se bazeaza acestea ?
R: Recunoasterea de **patternuri**, problema comis voiajorului (*sa fim seriosi, problema comis voiajorului nu* **se** *rezolva cu Hopfield like*). Suntem, dar si decana a fost cand a bagat problema in **curs** :P (realizeaza o aproximare, in cel mai bun caz :)))
(Cele doua aplicatii ale retelei **Hopfield** au fost luate dintr-un paper.)

9.Retea, ponderi, functie de activ**are pentru:**

x1	**x2**	**y**
1	0	1
0	1	1
0	0	1
1	1	0

R: w1/2 = 1;
f(x1,x2) = (w1x1 + w2x2) < 2 ??
Asta nu e nand? mie asa mi se pare. Si ar fi w1 - 1; w2 -1.5 si teta -2

10. Sa se construiasca o retea neurala cu 3 intrari si 3 iesiri, care sa afle maximul intrarilor.



1.

11. Care este numarul de neuroni necesari pentru o retea cu n noduri de intrare si n noduri de iesire ?
R: n? cel putin n

12. Indicati o retea neurala care sa poate sa reproduca litera C.
R: perceptron / hopfield.

13. Dati ex unde si in ce alg de invatare si cum se aplica euristica de alegere a ipotezei de invatare.

14. Descrieti structura si modul de functionare al unui LSC. (ce e aia? :)))

15. Construiti o retea perceptron care sa reprezinte functia SI logic, SAU logic, etc .

16.1 Diferenta intre invatare supervizata si invatarea prin recompensa. (curs1?)

16.2 Diferenta intre ADP si MDP.
ADP nu cunoaste modelul mediului, estimeaza probabilitatile tranzitiilor T(s,a,s') pe baza frecventei cu care ajunge in s' dupa ce se executa a in s, are o politica fixa.
MDP cunoaste modelul mediului, ….

Alte subiecte:

16. Calcul utilitati pt un exemplu dat

17. Asta e rezultatul cerintei (deduceti voi cerinta).

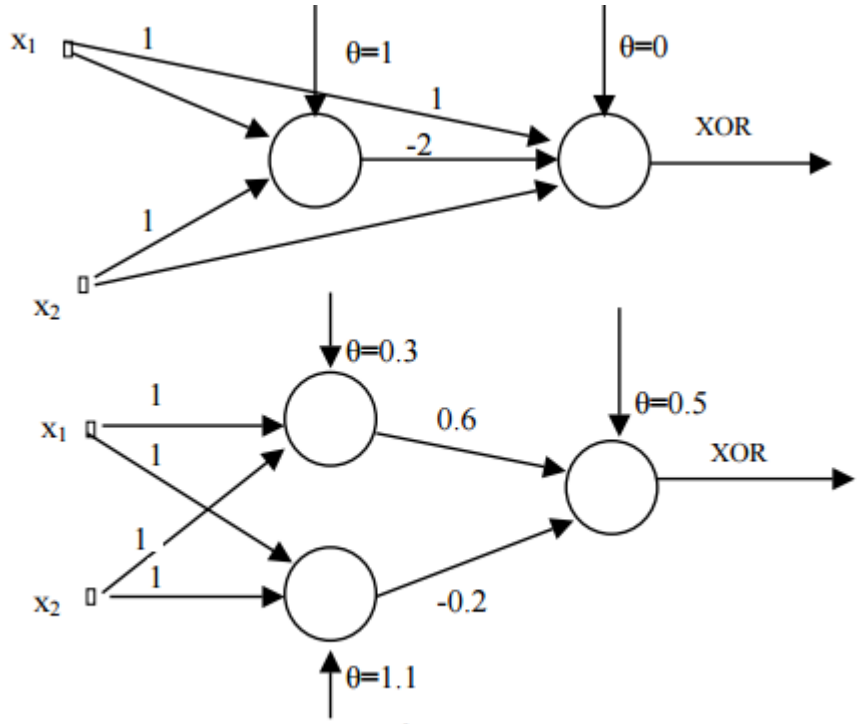
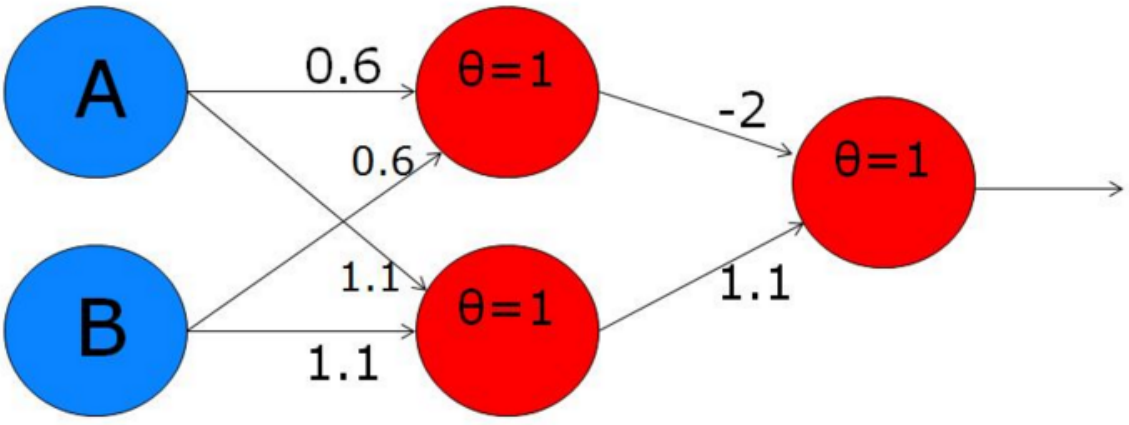
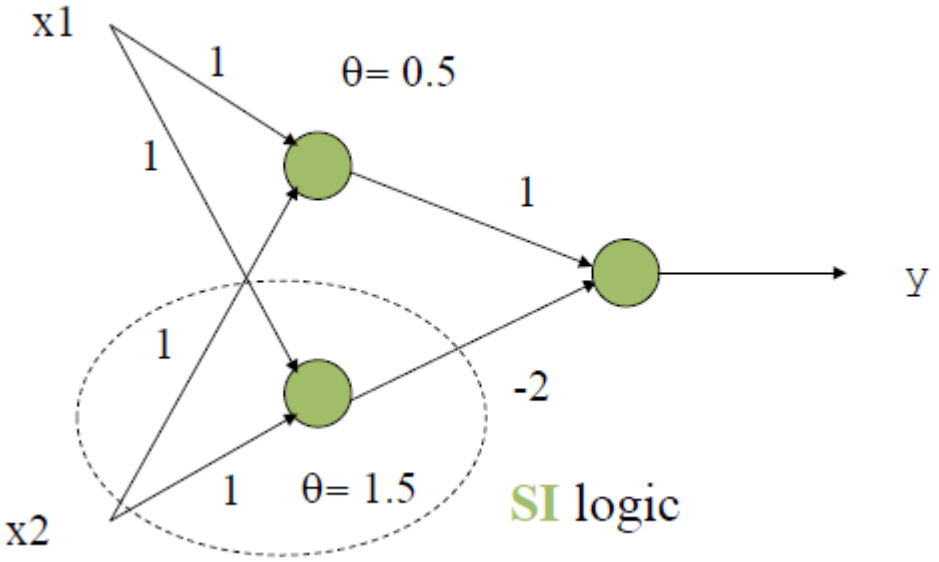


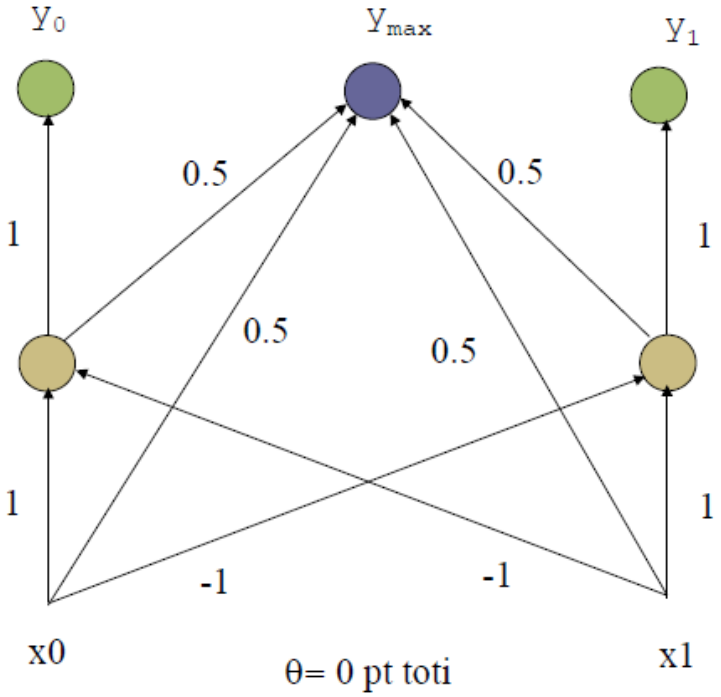
Fig.3 Două rețele pentru învățarea funcției logice XOR





Asta de Si logic e bun??? cat e teta pt stratul de iesire?
Desenul este pentru XOR. Teta pt stratul de iesire este 0.

Retea care selecteaza maximum
a doua intrari reale



- $f_3(t) = t$

- f_1 functie de transfer treapta

- $f_2(t) =$ t daca $t \geq 0$
  -t daca $t < 0$

https://docs.google.com/document/d/1bQJZpO-EfHW9Ve0PqQIZS84By_hZwO0zEUVEMq8qIwM/edit

Bafta!

P.S. Puteti sa contribuiti si cu alte intrebari daca mai aveti + rezolvari.

Pt lucrare 2 (va urma):
https://docs.google.com/document/d/1-iNsYsFwm4SupaWsxr3ipWCbxOTCieSQZBZGGUjNqNw/edit

---

“Subiecte din folclor” sem 1, IA

Obs: Oferiti si explicatii acolo unde nu e neaparat evident

-1. care sunt criteriile de selectie pt SBR?

- **Selectia primei reguli aplicabile**
- **Alegerea unei reguli din multimea de conflicte**
  - **Preferinte bazate pe natura regulilor**
    - **Specificitate**
    - **Momentului folosirii anterioare**
  - **Preferinte bazate pe obiectele identificate**
  - **Preferinte bazate pe natura starilor**
  - **Utilizarea metaregulilor**
- **Aplicarea tuturor regulilor din multimea de conflicte**

0. Ce înseamnă rezolvent a două clauze ?
Rezolventul a doua clauze C1 si C2 este disjunctia dintre C1 \ {L1} si C2 \ {L2} atunci cand L1 (apartine C1) si L2 (apartine C2) sunt 2 literali iar L1 = ~L2
ex: fie C1 = P1 V P2 V … V Pn
C2 = Q1 V Q2 V … V Qj V … V Qm
Pi = ~Qj
atunci Rez(C1, C2) = (C1 \ {Pi}) V (C2 \ {Qj}) (spunem ca C1 si C2 se rezolva)

1. CSP: Cand e potrivita o euristica ce alege prima data nodul cel mai restrictionat si cand cea care alege nodul cel mai putin restrictionat?
R: Pentru a alege nodul cel mai restrictionat - un joc de tip sudoku unde vrei sa mai eliberezi din restrictii. Nodul cel mai putin restrictionat - problema damelor.
(Sau) Vom alege cel mai restricționat când dorim să aflăm toate soluțiile, iar cel mai puțin restricționat când dorim să aflăm o soluție cât mai repede.

2. Cum arata un operator in STRIPS. Scrieti un operator care inverseaza valorile a doua variabile V1 si V2. Se poate folosi acest operator pt a asigna o valoare anume unei variabile?
R: Un operator strips vine insotit de 3 liste(preconditii, adaugari, eliminari) fiecare lista fiind formata din mai multe predicate.
Definim invers(V1, V2) ca:
preconditii: is_var(V1) ^ is_var(V2) ^ has_value(V1, a) ^ has_value(V2, b)
adaugari:has_value(V1, b) ^ has_value(V2, a)
eliminari:has_value(V1, a) ^ has_value(V2, b)

Se poate folosi ex: ai variabila V cu valoarea 4 si vrei sa o faci sa aiba valoarea 5. Iti creezi o variabila noua Vaux cu valoarea 5 si executi operatia invers(V, Vaux).

3. De scris o gramatica DCG (subjective, objective) in Prolog

```
sentence(S,R) :- noun_phrase(S,S2), verb_phrase(S2,R).
noun_phrase(S,R) :- det(S,S2), noun(S2,R).
verb_phrase(S, R) :- verb(S,S2), noun_phrase(S2,R).
det([the|X], X).
det([a|X], X).
noun([cat|X], X).
noun([bat|X], X).
verb([eats|X], X).
```

(https://en.wikipedia.org/wiki/Definite_clause_grammar#Example)

Cred ca e ce trebuie in cursul 12, slide-urile 62-63.

4. Cum se angajeaza agentii BDI ?
R: Blind / Limited / Open -> Cursul de Agenti

- Blind Commitment (angajare oarbă)
- Single Minded Commitment (angajare limitată)
- Open Minded Commitment (angajare deschisă

5. Ce este o retea semantica si care sunt inferentele specifice care exista (inclusiv semnificatia lor) intr-o astfel de retea? Dati un astfel de exemplu pentru fiecare tip de inferenta.
R:
O retea semantica este un graf orientat cu:

- Relatii/Arce (ISA & AKO)
- proprietati/atribute care leaga obiectele/instantele de valoare
- nodurile pot fi: clase, instante sau valori de proprietati. (Scris de mine la curs)

Inferente specifice se bazeaza pe mostenirea atributelor si asta poate fi de 2 feluri : mostenirea atributelor(se mostenesc atributele de la clasa superioara, ex: Fifi ISA Strut, Strut are atributul Penaj cu valoarea pistrit, => Fifi are penajul pistrit) si gasesc ceva despre mostenire multipla, dar nu reusesc sa imi dau seama care ar fi mai multe...
(Adaugat Ian 2017) In cazul modelului unitatilor (folosit pentru descrierea retelelor semantice) pot exista mosteniri multiple de atribute, unde este recomandat sa se foloseasca distanta inferentiala (care spune ca: Clasa 1 este mai aproape de Clasa 2 decat de Clasa 3 daca Clasa 2 este intre Clasa 1 si Clasa 3 de-a lungul unui lant de relatii ierarhice)

In curs mai zice de “Forma taxonomiei de unitati este un graf orientat aciclic, in care exista o relatie de ordine partiala impusa de relatiile MemberOf (ISA) sau Subclass/Superclass (AKO)”. Cred ca se refera la inferente de genul “Este Fifi o instanta (ISA) de Strut?” sau “Este Strut un tip (AKO) de Pasare?”.

6. Care este ciclul de control de baza al unui sistem bazat pe reguli de productie? Explicati fiecare etapa a acestui ciclu.
Algoritm:
Functionarea unui sistem bazat pe reguli
1. ML ← Date de caz
2. repeta
2.1. Executa identificare intre ML si BC si construieste multimea
de conflicte a regulilor aplicabile (MC)
2.2. Selecteaza o regula dupa un criteriu de selectie
2.3. Aplica regula prin executia partii drepte a regulii
pana nu mai sunt reguli aplicabile sau
memoria de lucru satisface conditia de stare scop sau
o cantitate predefinita de efort a fost epuizata
sfarsit.
(Curs 5, slide 9)

7. Fie urmatoarea baza de reguli:
R1: daca A si B atunci C
R2: daca A si B si C atunci D
R3: daca A atunci E
R4: daca A si D atunci F

Fie un sistem bazat pe reguli care functioneaza cu inlantuire inainte si inferenta bazata pe specificitatea regulilor si continutul memoriei de lucru (ML) initial este (A,B,C).
Ptr acest caz particular indicati:
a) Multimea de conflicte
b) Care sunt regulile selectate ptr executie
c) Continutul final al ML dupa terminarea functionarii sistemului

Rezolvare
a) MC = {R1, R2, R3}
Pentru ca in memoria de conflicte pui toate regulile care se pot realiza la inceput tinand cont de continutul ML.

b) Regulile selectate sunt in ordinea: R2, apoi random intre R1 si R4, si R3(de ce?)
// deoarce: e important sa se utilizeze cat mai multe fapte cu putinta. Nu consider corect random deoarece regula R1 este redundanta (C este deja in ML) => ordinea : R2, R4, R3
Pentru ca se foloseste selectia pe baza regulii de specificitate.
c) Daca nu exista un scop, ML = (A, B, C, D, E, F) //daca ultima selectata la b) este R3, consider ca ML = (A,B,C,D,F,E)

8. Se considera evenimentele A si B (variabile aleatoare boolene) si probabilitatile: P(A)=0.4 , P(B)=0.3 , P(A sau B)=0.5. Determinati P(A si B) , P(~A si B).
R:
varianta 1:

P(A sau B) = P(A) + P(B) - P(A si B) => P(A si B) = P(A) + P(B) - P(A sau B)
P(~A si B) = P(B) * P(~A|B) = P(B) * (1 - P(A|B)) = P(B) * (1- P(A si B)/P(B))
= P(B) - P(A si B) :)
v2:
P(B) = P(A si B) + P(~A si B) => P(~A si B) = P(B) - P(A si B)
Loris

9. Fie regula “daca A=a2 si B=b1 atunci C=c1 0.6” si continutul memoriei de lucru:

(A a2 0.8) (B b1 0.5) (C c1 0.7)

Considerind modelul coeficientilor de certitudine din sistemul MYCIN, care va fi valoarea si CF-ul corespunzator lui C dupa aplicarea regulii? Justificare.

R: curs 6, slide 59
CF[premisa] = min(0,8; 0,5) = 0,5
CF[concluzie] = 0,5 * 0.6 = 0.3

Aici nu trebuie combinat cu valoarea lui C deja existenta in memorie?.
adica CF[concluzie] = 0.3 + 0.7 - 0.3 * 0.7 << Corect! (curs 6, slide 56)

10. Definit notiunile de ambiguitate lexicala, sintactica si referentiala. Dati un exemplu pentru fiecare.
R: (curs 10, ultimul slide)
Ambiguitate:
Lexicala – acelasi cuvant diverse intelesuri ex: mare
Sintactica – arbori diferiti de analiza : Am lovit un om cu umbrela ← in romana nu cred ca e ambiguu. Mai bine merge “Am lovit un om cu o umbrela”
Referentiala – referire la obiecte anterioare : Mihai i-a spus lui Tudor ca a luat examenul

11. Diferenta intre PDA si LRTA*. ???
R: O diferență ar fi că în PDA fiecare nod i are asociat un proces i care își tot actualizează valorile în funcție de celelalte noduri vecine, pe când la LRTA* se pleacă dintr-un nod și se actualizează o tabelă a valorilor funcțiilor euristice în timp ce algoritmul “se plimbă” prin graf.

12. Care sunt operatorii de modificare a planului in metoda de planificare neliniara si in ce cazuri sunt folositi ?
R:
(1) adaugarea de pasi este operatia prin care se creaza noi pasi care se adauga la plan;
(2) promovarea este operatia de stabilire a unei ordonari (temporale) intre doi pasi de plan;
(3) legarea simpla este operatia de atribuire de valori variabilelor pentru a valida preconditiile unui pas de plan;
(4) separarea este operatia de impiedicare a atribuirii anumitor valori unei variabile;

(5) eliminarea destructivitatii este operatia de introducere a unui pas S3 (un pas deja existent in plan sau un pas nou) intre pasii S1 si S2, in scopul de a adauga un fapt invalidat de pasul S1 si necesar in pasul S2 (S1 amenintare pt S2).e

13. Importanta pasului de selectie in MCTS.

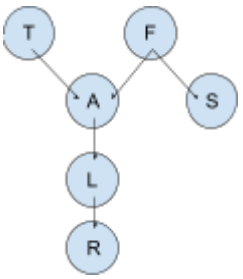
R: Pasul de selectie este important pentru rezultatul final al algoritmului, deoarece daca in pasul de selectie este aleasa o mutare neinteresanta atunci efortul irosit pe aceasta mutare nu va fi justificat de aportul mic adus de aceasta in strategia de joc, acest lucru rezultand intr-o strategie de joc care nu estimeaza corect cea mai buna miscare.

14. De transformat din logica cu predicat in forma clauzala
V x, V y,(controlat(x,y) ^ vip(y)) => (exista z supervizor(z,x) ^ ~parinte(z,y)))
R:

~controlat(x,y) v ~vip(y) v supervizor(f(x,y), x)
~controlat(x,y) v ~vip(y) v ~parinte(f(x,y), y)

mie mi-a dat aici asa:
~C(x,y) V ~V(y) V S(a,x)
~C(x,y) V ~V(y) V ~P(a,y)

15) Retea bayesiana T->A,F->A,F->S,A->L, L->R
De indicat formula de calcul: P(R, L, ,A, ~S, ~F, T) , P(A|T)



R:

P(A|T) = P(A| F ^ T) * P(F | T) + P(A| T ^ ~F) * P(~F | T)
curs 6 slide 34

P(R, L, A, ~S, ~F, T) =
= P(R ^ L ^ A ^ ~S ^ ~F ^ T)
= P(R|L) * P(L|A) * P(A|T ^ ~F) * P(~S|~F) * P(~F) * P(T)

16) Metode de constructie a unei clase in OWL
R:

1. Prin specificarea unui nume de clasa <owl::Class …>
2. Prin specificarea unui nume + descendenta
3. Prin folosirea de operatori logici pe clase deja existente owl:intersectionOf/unionOf/ sau enumerarea indivizilor owl:oneOf.
4. Prin aplicarea unor r1estrictii asupra unor proprietati. Obiectele care satisfac o restrictie formeaza o clasa anonima.

17) Descrieti metoda de subsumare a agentilor reactivi
R:
Arhitectura de subsumare
-> Un TAB este reprezentat de un modul de competenta (c.m.)
-> Fiecarte c.m. executa un task simplu c.m. opereaza in paralel

-> Nivele inferioare au prioritate fata de cele superioare
-> c.m. la nivel inferior monitorizeaza si influenteaza intrarile si iesirile c.m. la nivel superior (curs 11, slide 32)

18) Explicati fiecare pas din MCTS si indicati care este pasul critic din punct de vedere al eficientei. Justificare

R: MCTS are 4 pasi: **Selectie, Expandare, Simulare, Backpropagation.**

Selectie - pornind de la radacina, si mergand recursiv la copii se alege cel mai INTERESANT nod nexpandat **E**.

Expandare - Se adauga in arbore unul sau mai multe noduri copii ale nodului selectat anterior **E**

Simulare - se simuleaza jocul pornind de la nodurile adaugate pentru a obtine un rezultat **R**

Backpropagation - se propaga spre radacina si se actualizeaza nodurile din cale cu rezultatul simularii

Pasul cel mai critic este cel de Selectie, deoarece selectarea unui nod neinteresant duce la pierderea efortului de calcul si scaderea aproximarii spre cea mai buna miscare.

19. Diferentele intre realizarea arc-consistentei si d-arcconsistentei.

R:

Arc-consistenta se realizeaza pentru un arc, iar d-arc-consistenta se realizeaza pentru un graf: un graf e d-arc-consistent daca fiecare arc din el cu directia d e arc-consistent.

Un arc (X i , X j) intr-un graf de restrictii orientat se numeste arc-consistent daca si numai daca pentru orice valoare x ∈ D i , domeniul variabilei X i , exista o valoare y ∈ D j , domeniul variabilei X j , astfel incat R ij (x,y). (Curs 3).

20. Slot-machine cu 3 sloturi independente. Fiecare slot putea avea valori A, B, C, D cu aceeasi probabilitate.
daca iesea A|A|A primeai 15 fise
B|B|B 3 fise
C|C|C 2 fise
D|_|_ 2 fisa (deci bagi o fisa, castigi o fisa, esti pe zero) => probabil aice era o fisa
D|D|_ 5 fise
D|D|D 7 fise
orice alt rezultat inseamna ca pierzi fisa bagata
Care era probabilitatea ca bagand o fisa sau castigi ceva?
Care era probabilitatea ca bagand o fisa sa castigi fix 2 fise?

R:

a) 5 / 4 * 4 * 4 in 5 cazuri poti castiga ceva, si sunt in total 4*4*4 = 64 de cazuri pe care poti sa le obti

- Nu sunt 5 cazuri in care poti castiga sunt cazurile A|A|A, B|B|B C|C|C D|_|_(ai 16 cazuri aici in care poti castiga si le excuzi pe celelalte de la final) deci 19 cazuri.
- In D|_|_ nu castigi nimic, esti pe 0. AAA, BBB, CCC, DDA, DDB, DDC, DDD ← in astea castigi (+1 7/64) ??? in CCC esti pe 0, cred ca e 6/64

b) 1 / 64

21. Sa se transforme in forma clauzala:
oricare X, oricare Y (stramos(x,y) -> parinte(x,z) si stramos(z,y))
R:
~stramos(x,y) v parinte(x,z)
~stramos(x,y) v stramos(z,y)

22. Distanta si distanta inferentiala. Cand e bine sa se aplice una, cand alta.
R:

Distanta dintre unitati - se foloseste lungimea caii intre unitatea curenta U pentru care se doreste aflarea valorii slotului S si unitatea U' unde s-a gasit aceasta valoare, considerind corecta valoarea slotului din unitatea cea mai apropiata de unitatea U.

Distanta inferentiala: Clasa1 este mai aproape de Clasa2 decat de Clasa3 daca si numai daca Clasa1 are o cale inferentiala care trece prin Clasa2 spre Clasa3.
Clasa1 este mai aproape de Clasa2 decat de Clasa3 daca Clasa2 este intre Clasa1 si Clasa3 de-a lungul unui lant de relatii ierarhice. (Curs 8)
E bine sa se aplice distanta inferentiala in cazul mostenirii multiple de valori.

23. Ce se invata in algoritmul Real Time A* ? De ce se invata?
R: memoreaza actiunea aleasa pentru o trecere Si -> Sj, invata solutia optima in timp

24. Comparati strategia Mini-Max cu strategia Alfa-Beta.

25. Transformati in forma clauzala oricare X oricare Y (cumpara(x, y) -> (ceva(y, x) ^ exista z pret(y,z)))
R:

~cumpara(x,y) v (ceva(y,x) ^ exista z, pret(y,z)) - primul pas
[~cumpara(x,y) v ceva(y,x)]^ [~cumpara(x,y) sau pret(y, f(x,y))]

26. Dezavantajele planificarii liniare. Anomalia lui Sussman si cum se poate rezolva.
R: Dezavantaje / limitari: la formarea rezolventului Ck+1 se utilizeaza rezolventul imediat anterior Ck si orice alt rezolvent obtinut, dar e obligatoriu cel de dinainte.
Sau, ca sa realizezi o tinta trebuie sa strici o tinta realizata in trecut

27. Descrieti arhitectura de subsumare a agentilor reactivi.
R: ca la 17.

28. Strategia rezolutiei liniare (demonstratie folosind respingerea prin rezolutie). Sa se precizeze in ce conditii este completa.

R:
The linear resolution strategy is a slight generalization that allows P and Q to be resolved together if either P is in the original KB or if P is an ancestor of Q in the proof tree. Linear resolution is complete. (AIMA) => mereu e completa.

29. Nebunie smecherie => trecut bam bam

30 - criteriul adevarului necesar NU SE DA LA EXAMEN
Criteriul adevarului necesar
O formula P este necesar adevarata intr-o stare S daca si numai daca se indeplinesc urmatoarele doua conditii:
(1) exista o stare T egala cu/sau necesar anterioara lui S in care P este necesar afirmata (adaugata);
(2) pentru fiecare pas C posibil de executat inaintea lui S si pentru fiecare formula Q care poate unifica cu P pe care C o infirma, exista un pas W necesar intre C si S care afirma R, R fiind o formula pentru care R si P unifica ori de cite ori P si Q unifica.
(Curs 9)

31 - de explicat structura retelelor Bayesiene
R: O RB este un DAG in care:
Nodurile reprezinta variabilele aleatoare
Legaturile orientate X→Y: X are o influenta directa asupra lui Y, X=Parinte(Y)
Fiecare nod are asociata o tabela de probabilitati conditionate care cuantifica efectul parintilor
asupra nodului P(X i | Parinti(X i))
(Curs 6)
MYCIN
32. Indicati cele 3 axiome ale teoriei probabilitatilor. Este rational pt un agent sa atribuie valorile P(A)=0.4, P(B)=0.3 si P(AVB)=0.5 (V=sau) pt 2 variabile booleene A si B? Justificati.
R:

1. 0 <= P(E) <= 1
2. P(Evenimentul sigur) = 1
3. P(A sau B) = P(A) + P(B) daca A si B sunt mutual exclusive

33. Fie regula:
daca A=a2 si B=b1 si C=c1 atunci D=d1 CF=0.9 si continutul memoriei de lucru:
(A a1 0.6) (A a2 0.8) (B b1 0.7) (C c1 0.9) (D d1 0.7)
Considerand modelul coeficientilor (factorilor) de certitudine MYCIN, care va fi continutul mem de lucru dupa aplicarea regulii? Justificare.
R: slide 60, curs 5
CF[premisa] = min(0,8; 0,7; 0,9) = 0,7
CF[concluzie] = 0,7 * 0.9 = 0.63

- combina cu valoare D din memorie:
CF[concluzie] = 0.63 + 0.7 - 0.63*0.7

34. Mijloace de imbogatire gramatica DCG si exemple
R:

- Imbogatesc neterminale cu argumente suplimentare
- Verifica corectitudinea gramaticala
- Ataseseaza semantica
- Adauga expresii / functii care se testeaza

Ex: :-??

a) S(sem) → NP(sem1) VP(sem2) {compose(sem1, sem2, sem)}
b) Acord subiect cu predicat

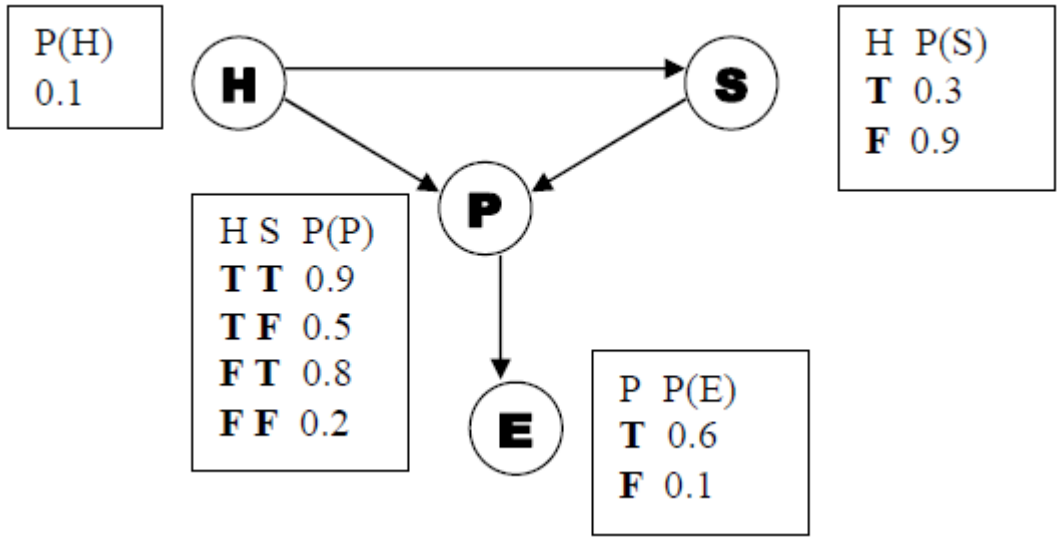
35. Explicati modul de functionare al unui SBR cu inlantuire inainte si al unui SBR cu inlantuire inapoi.

36. Sa se precizeze continutul stivei la planificarea neliniara. Exemplu de 2 eurisitci si sa se exemplifice cum ghideaza cautarea pentru planificarea neliniara.

37.Construiti o retea semantica care sa reprezinte afirmatia:
“Caii sunt animale. Capul unui cal este capul unui animal. Murgu este un cal cu capul alb”.
Indicati tipul relatiilor folosite, obiectele generice (clase) si instantele (obiecte).

38 prim)
Strategia rezolutiei liniare (demonstratie folosind respingerea prin rezolutie). Sa se precizeze in ce conditii este completa.??

38. Calculati P(~H,~S,P,E) pentru urmatoarea retea:



P(~H,~S,P,E) = P(~H ^ ~S ^ P ^ E) = P(~H) * P(~S | ~H) * P(P | ~H,~S) * P(E | P)
= 0.9 * 0.1 * 0.2 * 0.6 = 0.0108

39. . Tipuri de fatete la unitati

– fateta valoare
– fateta domeniu de valori
– fatete ce descriu restrictii
– fateta valoare implicita
– fateta mostenire
– fateta valoare activa
– fateta comentariu

40. Echilibrul nash, eficienta pareto si bunastarea sociala:

	Opera	Football
Opera	2,1	-2,0
Football	-2,0	-0,6

- Bunastare sociala (F, F).
- Pareto optimala: O O si F F sunt corecte
- Echilibru Nash (O, O), (F, F)

		J2 player	
		I	A
J1 player	I	2, 1	0, 0
	A	0, 0	1, 2

- Bunastare sociala ii, aa
- Pareto optimala: I I, A A
- Echilibru Nash (I, I), (A,A)

	J2 D	C
J1 D	2, 2	5, 0
C	0, 5	3, 3

-
- Bunastare sociala (C, C)
- Pareto optimala: (C, C), (C, D), (D, C)
- Echilibru Nash (D, D) (aici ar merge si (C, D) ?)

	Player 2 adopts strategy A	Player 2 adopts strategy B
Player 1 adopts strategy A	*4 / 4*	*1 / 3*
Player 1 adopts strategy B	*3 / 1*	*2 / 2*

- Bunastare sociala (A,A)
- Pareto optimala: a,a
- Echilibru Nash (A, A), (B, B)

41. Indicati si explicati tipuri de legaturi mutex(restrictii) intre actiuni, respectiv literali in metoda cu grafuri de planificare.

R :

a) Legaturi (restrictii) mutex intre actiuni:

-> postconditii inconsistente (PI) – o actiune neaga postconditia alteia

-> destructivitate/interferente (D) – postconditia unei actiuni este negarea preconditiei alteia

-> necesitati competitive (NC) – preconditia unei actiuni este mutual exclusiva cu preconditia alteia

b) Legaturi (restrictii) mutex intre literali:

-> un literal si acelasi literal negat

-> fiecare pereche de actiuni care pot adauga cei 2 literali sunt mutex